



UNIVERSIDAD MAYOR DE SAN SIMÓN
FACULTAD DE CIENCIAS Y TECNOLOGÍA
DIRECCIÓN DE POSGRADO



DIPLOMADO CIENCIA DE DATOS

TERCERA VERSIÓN

PREDICCIÓN DEL REZAGO ACADÉMICO EN EDUCACIÓN PRIMARIA MEDIANTE TÉCNICAS DE MACHINE LEARNING UTILIZANDO DATOS MULTI-AÑOS Y MULTI-CURSOS

**PROYECTO PRESENTADO PARA OBTENER EL GRADO DE LICENCIATURA EN
INGENIERÍA DE SISTEMAS
MODALIDAD DOBLE TITULACIÓN**

POSTULANTE : HUMBERTO DANIEL CANQUI CHAIRA
TUTOR : M.Sc. Ing. SERGIO FLORES LEDEZMA

Cochabamba – Bolivia

PREDICCIÓN DEL REZAGO ACADÉMICO EN EDUCACIÓN PRIMARIA MEDIANTE TÉCNICAS DE MACHINE LEARNING UTILIZANDO DATOS MULTI-AÑOS Y MULTI-CURSOS

Por

Humberto Daniel Canqui Chaira del cursante

El presente documento, Trabajo de Grado es presentado a la Dirección de Posgrado de la Facultad de Ciencias y Tecnología en cumplimiento parcial de los requisitos para la obtención del grado académico de Licenciatura en Ingeniería de Sistemas, modalidad Doble Titulación, habiendo cursado el Diplomado “Ciencia de Datos” propuesta por el Centro de Estadística Aplicada (CESA) en su tercera versión.

TUTOR

M.Sc. Ing Sergio Flores Ledezma

COMITÉ DE EVALUACIÓN

Ing. M.Sc.

Ing. M.Sc

Ing. M.Sc (Tribunal)

Ing. por designar....., M.Sc. (Tribunal)



CENTRO DE ESTADÍSTICA APLICADA (CESA)
DEPARTAMENTO DE MATEMÁTICAS
FCyT - UMSS
Cochabamba, Bolivia

Aclaración

Este documento describe el trabajo realizado como parte del programa de estudios de Diplomado “Ciencia de Datos” en el Centro de Estadística Aplicada CESA y la Dirección de Posgrado de la Facultad de Ciencias y Tecnología. Todos los puntos de vista y opiniones expresadas en el mismo son responsabilidad exclusiva del autor y no representan necesariamente las de la institución.

Resumen

El rezago académico en educación primaria exige mecanismos de seguimiento que permitan priorizar la revisión docente sin sustituir el juicio profesional. El objetivo del proyecto fue desarrollar un prototipo exploratorio capaz de estimar el riesgo de reprobación en la gestión siguiente en la U.E. José María Santiváñez, a partir de registros históricos de varios cursos y gestiones.

Se aplicó un enfoque cuantitativo organizado mediante CRISP-DM. Se consolidaron 1.118 observaciones estudiante-año de 592 estudiantes correspondientes a 2022–2024. Para el modelado longitudinal se construyeron 489 transiciones consecutivas $T \rightarrow T+1$ con información completa en ambas gestiones: 241 transiciones 2022→2023 para entrenamiento y 248 transiciones 2023→2024 para prueba temporal. Solo seis transiciones fueron positivas, tres en cada partición, por lo que el análisis se asumió como exploratorio.

La depuración identificó 1.030 observaciones completas y 88 incompletas, que se conservaron como «Sin datos» sin imputar calificaciones. La etiqueta descriptiva de rezago —al menos una asignatura con nota inferior a 51— apareció en 23 observaciones (2,06 %). Comunicación y Lenguajes (2,23 %) y Matemática (1,84 %) presentaron las mayores tasas observadas de reprobación; estos resultados describen el conjunto disponible y no demuestran relaciones causales.

Se concluye que la integración de datos, la evaluación temporal y el prototipo son técnicamente reproducibles, pero la evidencia disponible no permite afirmar alta capacidad predictiva ni generalización. Se requieren más cohortes, validación prospectiva y una evaluación con docentes antes de adoptar el sistema en la práctica institucional. Por tanto, las alertas deben utilizarse únicamente como apoyo a una revisión humana documentada.

Palabras clave

Minería de datos educativos; rezago académico; alerta temprana escolar; aprendizaje automático supervisado; validación temporal; apoyo a la decisión docente.

Primeramente dedico a Dios por dejarme concluir este proyecto como a mi esposa con la que me bendijo como mi ayuda idónea por toda su ayuda en este proceso largo

Agradecimientos

A mi esposa, Marcela, por estar a mi lado, por su amor, paciencia y apoyo incondicional, y por impulsarme y motivarme a culminar esta etapa de mi formación.

A mis padres, por su apoyo constante, por enseñarme el valor del esfuerzo y la perseverancia, y por acompañarme a lo largo de mi vida y formación.

A mis amigos, por sus palabras de ánimo, su motivación y por impulsarme a continuar y terminar este proyecto, especialmente en aquellos momentos en los que el camino se hizo más difícil.

A la Universidad Mayor de San Simón y a la Facultad de Ciencias y Tecnología, por brindarme el espacio académico y las herramientas necesarias para desarrollar este trabajo. A sus docentes, por compartir sus conocimientos y contribuir de manera significativa a mi formación profesional.

De manera especial, al Magíster Sergio Flores Ledezma, por su valiosa labor como tutor, por su orientación, disposición y acompañamiento durante el desarrollo de este proyecto, cuyos conocimientos y recomendaciones fueron fundamentales para la culminación de este trabajo.

A la directora de la Unidad Educativa José María Santiváñez, por su predisposición, confianza y colaboración al facilitar los datos académicos necesarios para la realización de este proyecto, haciendo posible el desarrollo y análisis de la investigación.

Tabla de contenidos

1. Introducción	1
1.1. Antecedentes	1
1.2. Justificación	2
1.2.1. Justificación Tecnológica y de Innovación	2
1.2.2. Justificación Social y Pedagógica	2
1.2.3. Justificación Metodológica y Científica	2
1.3. Planteamiento del problema	3
1.3.1. Formulación del Problema	3
1.4. Objetivo general	3
1.4.1. Objetivos específicos	3
2. Marco teórico	5
2.1 Minería de Datos Educativos (Educational Data Mining - EDM)	5
2.2 Proceso de Descubrimiento de Conocimiento (Metodología de Datos)	5
2.2.1 Extracción, Transformación y Carga (ETL)	5
2.2.2 Estandarización y Escalado de Variables	5
2.2.3 Balanceo de Clases	6
2.3 Modelos de Aprendizaje Automático Predictivo (Machine Learning)	6
2.3.1 Árboles de Decisión (Decision Tree Classifier)	6
2.3.2 Bosques Aleatorios (Random Forest Classifier)	6
2.3.3 Redes Neuronales Artificiales: Perceptrón Multicapa (MLP)	7
2.4 Sistemas de Alerta Temprana y Visualización de Datos (Dashboards)	8
2.5 Metodología de Desarrollo: CRISP-DM y KDD	8
2.6 Ingeniería de Características (Feature Engineering)	9
2.7 Evaluación Matemática de Modelos Clasificadores	9
2.7.1 La Paradoja de la Exactitud en Datos Educativos	9
2.7.2 Matriz de Confusión y Métricas Derivadas	10
2.8 Ecosistema Tecnológico y Reproducibilidad Computacional	10
2.8.1 Diferencia entre notebook, script y módulo	10
2.8.2 Bibliotecas de análisis, modelado y visualización	11
2.8.3 Dashboard interactivo con Streamlit y Plotly	11
2.8.4 Dependencias y reproducibilidad	12
3. Ingeniería del proyecto	13
3.1 Área de Estudio	13
3.2 Flujograma Metodológico	14
3.3 Fuentes de la Información	15
3.3.1 Datos Secundarios	15

3.4 Recolectar y depurar datos académicos históricos de alumnos de varios cursos y gestiones.	15
3.4.1 Recolección de datos y transformación a formato Excel	15
3.4.2 Proceso de Extracción y Limpieza	17
Figura 3-7: Función de extracción y homogeneización de boletines escolares	18
3.4.3 Consolidación y Construcción de la Variable Rezago	18
Figura 3-8: Consolidación del dataset y creación de la variable target 'rezagado'	19
3.4.4 Controles de calidad y evidencia de consolidación	19
3.5 Analizar los datos para identificar patrones de rezago académico y factores asociados como materias críticas	20
3.5.1 Preparación de variables y criterio de cálculo	20
Figura 3-9: Consolidación del dataset y creación de la variable target 'rezagado'	20
3.5.2 Identificación de materias críticas	21
Figura 3-9: Salida agregada del notebook: tasa de reprobación por asignatura sobre nota	21
3.5.3 Comparación de Medias por Condición de Rezago	21
Figura 3-10: Comparación de promedios de grupo de rezago	22
3.5.4 Alcance de la evidencia del Objetivo 2	22
3.6 Diseñar y entrenar modelos predictivos de machine learning (Árboles de decisión, Random Forest, Redes Neuronales) para anticipar alumnos en riesgo.	22
3.6.1 Construcción longitudinal $T \rightarrow T+1$	22
Figura 3-11: Construcción de transiciones consecutivas	23
3.6.2 Partición temporal de entrenamiento y prueba	23
3.6.3 Configuración y ajuste de los clasificadores	24
3.6.4 Artefactos generados y reproducibilidad	25
3.7 Evaluar los modelos propuestos y segregar a los estudiantes en grupos de riesgo para facilitar planes de apoyo.	26
3.7.1 Métricas y salida ejecutada del notebook	26
3.7.2 Lectura de las matrices de confusión	27
3.7.3 Segregación operativa y resguardo pedagógico	28
3.7.4 Limitaciones de la evaluación	30
3.8 Proponer un prototipo de apoyo a la decisión docente con alertas tempranas	30
3.8.1 Requisitos funcionales y arquitectura modular	30
3.8.2 Flujo de carga, validación e inferencia	31
3.8.3 Vistas implementadas y evidencia de ejecución	31
3.8.4 Verificación funcional y alcance actual	33
4. Análisis de Resultados y Discusión	34
4.1 Resultados y Análisis de la Recolección y Depuración de Datos (Obj. Esp. 1)	34
4.1.1 Caracterización del Dataset Consolidado	34
4.1.2 Distribución de la Variable Objetivo 'Rezago'	35
4.2 Resultados del Análisis Exploratorio de Patrones y Materias Críticas (Obj. Esp. 2)	35
4.2.1 Identificación Empírica de Materias Críticas	35

4.2.2 Análisis de Comportamiento Académico por Grupo	36
4.3 Resultados del Entrenamiento y Comparación de Modelos Predictivos	37
(Obj. Esp. 3)	37
4.3.1 Resumen de Hiperparámetros de los Modelos Evaluados	38
4.3.2 Rendimiento en la Prueba Temporal 2023→2024 (N=248)	38
4.4 Resultados de la Evaluación y Segregación por Niveles de Riesgo (Obj 4)	39
4.4.1 Matriz de Umbrales de Clasificación de Riesgo	39
4.4.2 Análisis Temporal y Variabilidad por Paralelo	40
4.5 Resultados del Prototipo Docente de Alertas Tempranas (Obj 5)	42
4.5.1 Validación Operativa de la Capa de Resguardo Pedagógico	44
4.6 Discusión de Resultados	45
5. Conclusiones	47
6. Recomendaciones	48
Bibliografía	49
Anexos	52
Anexo PRINCIPAL: CD	58

Lista de figuras

Figura 3-1: Área de estudio de la UE Jose Maria Santivañez	13
Figura 3-2: Flujograma metodológico	14
Figura 3-3: Carpetas por gestión escolar	15
Figura 3-4: Boletines centralizados	16
Figura 3-5: Boletín de anual	16
Figura 3-6: Boletines transformados a excel	17
Figura 3-7: Función de extracción y homogeneización de boletines escolares	18
Figura 3-8: Consolidación del dataset y creación de la variable target ‘rezagado’	19
Figura 3-9: Salida agregada del notebook: tasa de reprobación por asignatura sobre nota	21
Figura 3-10: Comparación de promedios de grupo de rezago	22
Figura 3-11: Construcción de transiciones consecutivas	23
Figura 3-12: Construcción longitudinal y partición cronológica del modelado	23
Figura 3-13: Ajuste diferenciado y cálculo de probabilidades en la prueba	24
Figura 3-14: Lectura de resultados y construcción de la tabla comparativa	26
Figura 3-15: Comparación de métricas generada por el notebook de evaluación temporal	27
Figura 3-16: Matrices de confusión obtenidas en la prueba temporal	28
Figura 3-16: Matrices de confusión obtenidas en la prueba temporal	28
Figura 3-17: Regla pedagógica y categorización operativa	28
Figura 3-18: Lógica de inferencia y resguardo pedagógico del sistema híbrido	29
Figura 3-19: Arquitectura modular y flujo de ejecución del prototipo	30
Figura 3-20: Tratamiento de registros incompletos antes de inferir	31
Figura 3-21: Lista de monitoreo del curso con filtros e indicadores agregados	32
Figura 3-22: Simulador libre y separación entre probabilidad estadística y puntaje operativo	32
Figura 4-1: Tasa descriptiva de reprobación por asignatura curricular	35
Figura 4-2: Distribución del número de asignaturas reprobadas según condición de rezago	36
Figura 4-3: Matrices de confusión en la prueba temporal 2023→2024 (N=248)	38
Figura 4-4: Distribución operativa del riesgo y registros sin datos suficientes (N=1.118)	40
Figura 4-5: Evolución de la proporción de rezago académico (2022–2024)	41
Figura 4-6: Proporción de rezago promedio por grado escolar	41
Figura 4-7: Evolución académica longitudinal de un estudiante de ejemplo	42
Figura 4-8: Estructura de la Interfaz	42
Figura 4-9: Vista de monitoreo del curso y panel de alertas tempranas	43
Figura 4-10: Ficha individual y simulación de calificaciones en modo demostración	43
Figura 4-11: Simulador libre para comprobar escenarios y reglas operativas	44
Figura A-1: Estructura de Directorios del Código Fuente del Proyecto	52

Lista de tablas

Tabla 2-1: Tecnologías verificadas y función dentro del proyecto	11
Tabla 3-1: Reglas de validación y tratamiento de datos académicos	19
Tabla 3-2: Salida resumida de la comparación descriptiva por condición de rezago	22
Tabla 3-3: Construcción y partición de la muestra predictiva longitudinal	23
Tabla 3-4: Configuraciones reproducibles de los clasificadores	24
Tabla 3-5: Métricas reproducidas en la prueba temporal 2023→2024 (N=248)	27
Tabla 3-6: Reglas de segregación operativa del riesgo	29
Tabla 3-7: Responsabilidades de la arquitectura modular del prototipo	30
Tabla 3-8: Resumen de verificaciones funcionales automatizadas	33
Tabla 4-1: Caracterización del conjunto consolidado	34
Tabla 4-2: Tasas descriptivas de reprobación por asignatura	35
Tabla 4-3: Promedios por condición de rezago	36
Tabla 4-4: Hiperparámetros de los modelos evaluados	38
Tabla 4-5: Rendimiento comparativo en la prueba temporal 2023→2024 (N=248)	38
Tabla 4-6: Umbrales de clasificación operativa del riesgo	39
Tabla 4-7: Comparación metodológica con la monografía de referencia	39
Tabla 4-7: Comparación metodológica con la monografía de referencia	45
Tabla A-1: Muestra sintética y seudonimizada del esquema limpio	55
Tabla A-2: columnas paterno, materno y nombres	55
Tabla A-3: Métricas completas de los modelos	56
Tabla A-4: Ítems del prototipo	56
Tabla A-5: Versiones del artefacto	57
Tabla A-6: Contenido del entregable	57
Tabla A-7: Muestra sintética	57

1. Introducción

La educación primaria constituye la base del proceso formativo de los estudiantes, ya que en esta etapa se desarrollan habilidades fundamentales como la comprensión lectora, el razonamiento lógico-matemático y la socialización. Sin embargo, uno de los principales problemas que enfrenta el sistema educativo es el rezago académico, entendido como la dificultad de los estudiantes para alcanzar los aprendizajes esperados en una o más áreas curriculares.

Tradicionalmente, la identificación de estudiantes en rezago se realiza de forma reactiva, cuando las calificaciones ya han descendido de manera significativa o cuando el problema se ha acumulado durante varios períodos académicos. Este enfoque limita la posibilidad de aplicar intervenciones pedagógicas tempranas.

En este contexto, el uso de técnicas de ciencia de datos y machine learning permite analizar información académica histórica y detectar patrones que anticipen el rezago antes de que este se consolide. El presente proyecto propone el desarrollo de un modelo predictivo que utilice datos académicos multi-años y multi-cursos para apoyar la toma de decisiones pedagógicas en educación primaria.

1.1. Antecedentes

El seguimiento del rendimiento académico puede beneficiarse de registros longitudinales integrados. La minería de datos educativos estudia métodos para analizar información producida en contextos de aprendizaje (Baker & Inventado, 2014; Romero & Ventura, 2020). En este proyecto, el término rezago se limita operacionalmente a la reprobación de al menos una asignatura; no representa por sí mismo deserción, repetición ni un diagnóstico integral.

En Bolivia, el Reglamento de Evaluación del Desarrollo Curricular consultado establece la escala y los criterios institucionales utilizados en este trabajo (Ministerio de Educación, 2024). El proyecto no evalúa el sistema educativo nacional: analiza exclusivamente los registros disponibles de una unidad educativa.

En la U.E. José María Santiváñez, los registros de 2022 a 2024 estaban distribuidos por gestión, grado y paralelo. Esta fragmentación dificulta el análisis longitudinal. La necesidad abordada fue consolidar la información y construir un prototipo exploratorio para priorizar casos que requieren revisión docente.

La Minería de Datos Educativos y la Analítica del Aprendizaje ofrecen métodos para explorar registros académicos y presentar indicadores útiles para la toma de decisiones (Baker & Inventado, 2014; Romero & Ventura, 2020). Su aplicación exige validar los modelos en el contexto específico y evitar decisiones automáticas sobre estudiantes.

La literatura sobre minería de datos educativos documenta el uso de clasificadores y sistemas de alerta para apoyar la revisión docente (Macfadyen & Dawson, 2010; Romero & Ventura, 2020). Su desempeño depende del contexto, la calidad de los datos y la validación externa; por ello no se trasladan cifras de otros estudios como garantía para este proyecto.

El alcance de este trabajo se limita a una institución de Cochabamba. No se afirma que represente iniciativas nacionales ni que sus resultados sean generalizables a otras unidades educativas.

A partir de esta necesidad, el proyecto consolidó datos, comparó tres clasificadores y desarrolló una interfaz de apoyo. Dado el reducido número de transiciones positivas, la salida se considera exploratoria y requiere revisión docente.

1.2. Justificación

La pertinencia del proyecto se organiza en dimensiones tecnológica, pedagógica y metodológica; sus beneficios potenciales deberán comprobarse mediante evaluación con usuarios y validación prospectiva.

1.2.1. Justificación Tecnológica y de Innovación

Desde una perspectiva tecnológica, las escuelas primarias en contextos como el de Cochabamba habitualmente carecen de sistemas informáticos avanzados que vayan más allá de la mera ofimática. Este proyecto representa un salto cualitativo al introducir herramientas de **Ciencia de Datos** y **Machine Learning** (específicamente algoritmos avanzados como Bosques Aleatorios y Redes Neuronales) a un entorno escolar real. Se justifica la necesidad de transformar repositorios de datos pasivos (históricos de RUDE en Excel/PDF) en recursos analíticos activos. La propuesta de un panel interactivo (Dashboard en Streamlit) dotará a los educadores de una interfaz gráfica moderna, traduciendo cálculos matemáticos complejos en métricas comprensibles y alertas visuales.

1.2.2. Justificación Social y Pedagógica

El prototipo busca priorizar la revisión de perfiles académicos mediante niveles de alerta. No constituye un diagnóstico, no estima abandono escolar y no reemplaza la valoración integral del docente.

1.2.3. Justificación Metodológica y Científica

El proyecto aplica CRISP-DM para documentar recolección, preparación, modelado, evaluación y despliegue. La comparación temporal aporta evidencia reproducible del conjunto estudiado, sin demostrar eficacia general ni impacto pedagógico.

1.3. Planteamiento del problema

La unidad educativa administra boletines por gestión, grado y paralelo. Los archivos disponibles contienen calificaciones, metadatos escolares e identificadores; su fragmentación dificulta el seguimiento longitudinal y exige controles de privacidad.

Antes del proyecto no existía en el repositorio una herramienta integrada para reconstruir transiciones entre gestiones y presentar indicadores de riesgo. El problema técnico fue consolidar los datos y evaluar si dos variables académicas agregadas aportan señal predictiva.

La ausencia de una vista longitudinal limita la priorización sistemática de casos. El proyecto aborda esta necesidad mediante un prototipo de apoyo; no presupone que las dificultades observadas sean irreversibles ni atribuir causalidad a los patrones estadísticos.

1.3.1 Formulación del Problema

A partir de la situación descrita, se formula la siguiente pregunta central de investigación/proyecto:

¿De qué manera el desarrollo de un modelo predictivo basado en técnicas de Minería de Datos y Machine Learning, utilizando el historial académico de los estudiantes, puede anticipar el riesgo de rezago académico y apoyar la toma de decisiones pedagógicas tempranas en la educación primaria?

1.4. Objetivo general

Desarrollar y evaluar exploratoriamente un sistema de apoyo para estimar el riesgo de reprobación en la gestión siguiente, utilizando datos históricos de educación primaria, con el fin de priorizar la revisión docente en la U.E. José María Santiváñez.

1.4.1. Objetivos específicos

- Recolectar y depurar datos académicos históricos de alumnos de varios cursos y gestiones.
- Analizar los datos para identificar patrones de rezago académico y factores asociados como materias críticas.
- Diseñar y entrenar modelos predictivos de machine learning (Árboles de decisión, Random Forest, Redes Neuronales) para anticipar alumnos en riesgo.

- Evaluar los modelos propuestos y segregar a los estudiantes en grupos de riesgo para facilitar planes de apoyo.
- Proponer un prototipo de apoyo a la decisión docente que integre alertas tempranas para el seguimiento de los alumnos.

2. Marco teórico

El presente capítulo desarrolla los sustentos teóricos y conceptuales que fundamentan la investigación. Se abordan las disciplinas centrales del proyecto, comenzando por la Analítica de Datos Educativos, transitando por las metodologías de procesamiento de datos, hasta llegar a los algoritmos específicos de Aprendizaje Automático implementados para la predicción del rezago escolar.

2.1 Minería de Datos Educativos (Educational Data Mining - EDM)

La Minería de Datos Educativos es un campo interdisciplinario que desarrolla y aplica métodos computacionales para explorar datos originados en contextos educativos (Romero & Ventura, 2020).

Baker e Inventado (2014) describen la Minería de Datos Educativos y la Analítica del Aprendizaje como enfoques relacionados para estudiar datos del aprendizaje y apoyar su interpretación. En este proyecto, ese marco orienta la transformación de registros longitudinales en indicadores sujetos a revisión docente.

2.2 Proceso de Descubrimiento de Conocimiento (Metodología de Datos)

Para que los algoritmos de inteligencia artificial funcionen correctamente, los datos crudos deben someterse a un riguroso proceso de tratamiento. Este proyecto se alinea con las fases estándar de la minería de datos:

2.2.1 Extracción, Transformación y Carga (ETL)

El proceso ETL es la piedra angular de cualquier sistema analítico. Consiste en la Extracción de datos desde múltiples fuentes (en este caso, boletines en formato PDF o Excel), la Transformación de los mismos para asegurar su calidad (homogeneización de materias, tratamiento de valores nulos o atípicos) y la Carga en un repositorio central estructurado (Dataset) (Han et al., 2012). Sin una limpieza adecuada, los modelos predictivos heredarán los sesgos y errores de los registros manuales ("basura entra, basura sale").

2.2.2 Estandarización y Escalado de Variables

Las variables de entrada pueden tener escalas diferentes. StandardScaler centra cada variable y la escala por su desviación estándar; no convierte necesariamente los datos en una distribución normal. En este proyecto se ajustó solo con el conjunto de entrenamiento antes de transformar los datos de prueba (Hastie et al., 2009).

2.2.3 Balanceo de Clases

El conjunto del proyecto está fuertemente desbalanceado. Sin medidas específicas, un clasificador puede favorecer a la clase mayoritaria. Árbol y Random Forest utilizaron `class_weight='balanced'`; además se reportaron métricas centradas en la clase positiva y curvas precisión-recall, más informativas en este escenario (Breiman, 2001; Saito & Rehmsmeier, 2015).

2.3 Modelos de Aprendizaje Automático Predictivo (Machine Learning)

El Machine Learning (Aprendizaje Automático) es una rama de la Inteligencia Artificial que permite a los sistemas informáticos aprender de forma autónoma a partir de datos, sin haber sido programados explícitamente para ello (Hastie et al., 2009). En el ámbito educativo, se aplica principalmente el "aprendizaje supervisado", un paradigma donde el algoritmo recibe un conjunto de datos históricos que ya incluye la solución deseada (la variable objetivo o target). El modelo analiza las características de los estudiantes y aprende la relación matemática que las vincula con la etiqueta final (por ejemplo: "Aprobado" o "Rezago"). Una vez entrenado, el algoritmo es capaz de predecir la etiqueta de nuevos estudiantes con base en sus características actuales (James et al., 2013).

Para la predicción de rezago escolar se han implementado y evaluado comparativamente tres arquitecturas algorítmicas de aprendizaje supervisado, cada una con distintos grados de interpretabilidad y complejidad.

2.3.1 Árboles de Decisión (Decision Tree Classifier)

Los árboles de decisión particionan el espacio de características mediante reglas jerárquicas y pueden utilizarse para clasificación (James et al., 2013). Su estructura facilita la inspección, aunque su interpretación no garantiza estabilidad fuera de la muestra.

- **Estructura y Funcionamiento:** El modelo comienza con un "nodo raíz" que contiene todos los registros estudiantiles. Luego, elige la característica (ej: Promedio General Previo) que mejor separe a los estudiantes con rezago de los aprobados, basándose en un criterio matemático como la Impureza de Gini o la Ganancia de Información. El árbol se bifurca sucesivamente hasta alcanzar los "nodos hoja", que representan la clasificación o diagnóstico predictivo final (James et al., 2013).
- **Justificación de Uso:** Su principal ventaja en la educación es la "alta interpretabilidad" (Pérez & Martínez, 2024). Un profesor o director académico puede observar gráficamente las reglas del árbol y comprender exactamente bajo qué umbral matemático el sistema ha clasificado a un estudiante como riesgo alto (por ejemplo: "Si el promedio es menor a 55 Y reprobó más de 2 materias, entonces el riesgo es alto").

2.3.2 Bosques Aleatorios (Random Forest Classifier)

Si bien los árboles de decisión son interpretables, sufren del problema de "sobreajuste" (overfitting): tienden a memorizar el ruido de los datos de entrenamiento, perdiendo precisión al predecir casos

nuevos. Para solucionar esto, Leo Breiman introdujo en 2001 los Bosques Aleatorios (Random Forests), una técnica de "Ensamblado" (*Ensemble Learning*).

- **Estructura y Funcionamiento:** Random Forest no construye un solo árbol, sino una multitud de árboles de decisión (por ejemplo, 100 o 200 árboles) simultáneos e independientes. Cada árbol se entrena utilizando una muestra aleatoria diferente de los datos originales (técnica conocida como *Bagging* o Bootstrap Aggregation) e incluso seleccionando un subconjunto aleatorio de variables (Breiman, 2001). Cuando se necesita predecir el futuro de un estudiante nuevo, cada uno de los 200 árboles emite un "voto" o predicción. El "bosque" determina el resultado final basado en la decisión mayoritaria.
- **Justificación de Uso:** Se considera uno de los algoritmos más robustos y precisos para datos estructurados como las calificaciones escolares (García & Ruiz, 2023). Al promediar el sesgo de cientos de modelos individuales, reduce drásticamente el error de predicción. Además, Random Forest es sumamente eficaz para modelar comportamientos no lineales sin necesidad de estandarizar rigurosamente las variables de entrada.

2.3.3 Redes Neuronales Artificiales: Perceptrón Multicapa (MLP)

Las Redes Neuronales Artificiales son el cimiento sobre el que se construye el campo del *Deep Learning* (Aprendizaje Profundo). Inspiradas remotamente en la sinapsis del cerebro biológico, su bloque fundamental es el Perceptrón. Cuando múltiples perceptrones se agrupan en capas interconectadas, forman el Perceptrón Multicapa (Multi-Layer Perceptron o MLP), la arquitectura más clásica de las redes "feedforward" (hacia adelante).

- **Estructura y Funcionamiento:** Un MLP consta, como mínimo, de tres etapas (Haykin, 2009):
 1. **Capa de Entrada (Input Layer):** Recibe las variables estandarizadas del estudiante (ej: Promedio estandarizado, Materias Reprobadas estandarizadas).
 2. **Capas Ocultas (Hidden Layers):** Capas intermedias compuestas por "neuronas" artificiales. Cada conexión entre neuronas posee un "peso" matemático. Dentro de la neurona se aplica una "función de activación no lineal" (como ReLU o Sigmoide) que permite al modelo aprender correlaciones sumamente complejas que serían invisibles para una regresión lineal tradicional.
 3. **Capa de Salida (Output Layer):** Arroja la probabilidad matemática de que el alumno pertenezca a la clase de rezago (Goodfellow, Bengio & Courville, 2016).
- **Entrenamiento:** La red aprende mediante un proceso cíclico llamado "propagación hacia atrás" (*Backpropagation*). Compara su predicción con la realidad, calcula el margen de error, y viaja en reversa a través de la red ajustando los "pesos" matemáticos de las conexiones para minimizar dicha equivocación (Haykin, 2009).

- **La MLP** se incluyó como contraste no lineal. Con dos variables y muy pocos casos positivos, una mayor complejidad no implica mejor desempeño; en la prueba temporal no detectó positivos.
- **Justificación de Uso:** En el análisis del abandono y rezago estudiantil, estudios afirman que las redes neuronales pueden ofrecer una precisión marginal superior al desentrañar relaciones abstractas de alta dimensionalidad (Pérez & Martínez, 2024), representando la vanguardia computacional en Educational Data Mining.

2.4 Sistemas de Alerta Temprana y Visualización de Datos (Dashboards)

Finalmente, el ecosistema de la analítica de datos no concluye con la predicción puramente matemática, sino con la transmisión comunicativa del valor predictivo a los tomadores de decisión (en este caso, los docentes).

Un Sistema de Alerta Temprana (Early Warning System) aplicado a la educación es una herramienta procedimental que intercepta a los estudiantes en vías del fracaso antes de materializar el abandono (Cardoso et al., 2021). Para ello se construyen "Dashboards" (Paneles de Control), que son interfaces visuales que muestran indicadores de desempeño clave (KPIs) en una sola pantalla. En el contexto de lenguajes de programación modernos, el uso de frameworks como Streamlit o tecnologías similares permite integrar sin fricciones los complejos modelos de Machine Learning (como Random Forests almacenados en backend) con una interfaz de usuario interactiva en la web (Pérez, 2021). Estos prototipos exigen al especialista en educación de interactuar algorítmicamente con el modelo, habilitando un entorno intuitivo compuesto por semáforos de riesgo (Riesgo Alto, Medio, Bajo), barras de probabilidad predictiva y contextos gráficos del aula en tiempo real.

2.5 Metodología de Desarrollo: CRISP-DM y KDD

Para garantizar que el modelo de *Machine Learning* sea académicamente válido y tecnológicamente escalable, este proyecto se enmarca teóricamente en el modelo **CRISP-DM** (Cross-Industry Standard Process for Data Mining). Este estándar es la metodología analítica más utilizada globalmente para proyectos de minería de datos (Wirth & Hipp, 2000). CRISP-DM establece que un proyecto predictivo (como la anticipación del rezago escolar) no es un proceso lineal, sino un ciclo robusto compuesto por seis fases iterativas:

1. **Comprensión del Negocio (Business Understanding):** En la educación, esto equivale a comprender a profundidad el problema del rezago escolar, las limitaciones del RUDE, y las necesidades del plantel docente antes de tocar una sola línea de código.
2. **Comprensión de los Datos (Data Understanding):** Involucra la exploración inicial (EDA) para identificar la dimensionalidad de las calificaciones históricas.

3. **Preparación de los Datos (Data Preparation):** Coincide con las metodologías ETL previamente discutidas. Es la fase estadística donde se tratan los valores nulos, se limpian imperfecciones en el registro de materias y se estructuran en matrices funcionales.
4. **Modelado (Modeling):** La fase matemática donde se aplican algoritmos (Árboles de Decisión, Redes Neuronales) sobre el dataset limpio.
5. **Evaluación (Evaluation):** El contraste métrico de los modelos (Matriz de Confusión, Precisión, Exhaustividad).
6. **Despliegue (Deployment):** La entrega final de valor, que en este proyecto se consolida a través del panel interactivo (Dashboard) en tecnología Web (Streamlit).

2.6 Ingeniería de Características (Feature Engineering)

La ingeniería de características transforma datos crudos en variables utilizables por los modelos (James et al., 2013). En este trabajo se utilizaron únicamente el promedio general y el número de asignaturas reprobadas de la gestión T.

La construcción longitudinal vinculó el desempeño de la gestión T con la etiqueta observada en T+1 para el mismo RUDE seudónimo y solo cuando las gestiones eran consecutivas.

- **Ventanas de Tiempo (Shift):** En la analítica educativa, utilizar el rendimiento de Gestión = T para predecir el impacto en Gestión = T+1 permite que la máquina construya un puente causal entre el pasado y el futuro.
- **Agregación Matemática:** En lugar de alimentar al algoritmo con diez notas dispersas de materias distintas, la "Ingeniería de Características" consolida el esfuerzo estudiantil calculando vectores agregados como el *Promedio General Histórico* o un sumatorio del *Número Total de Materias Reprobadas Previamente*. Estas variables sintéticas son las que aportan la verdadera capacidad "predictiva" a las Redes Neuronales.

2.7 Evaluación Matemática de Modelos Clasificadores

La evaluación de clasificadores desbalanceados requiere complementar la exactitud con matriz de confusión, precisión, recall, F1, balanced accuracy y precisión promedio (Fawcett, 2006). Con tres positivos en la prueba, cualquier estimación es inestable.

2.7.1 La Paradoja de la Exactitud en Datos Educativos

Si el 90 % de los casos pertenece a la clase negativa, predecir siempre esa clase produce 90 % de exactitud y recall positivo igual a cero. Este ejemplo muestra por qué la exactitud debe interpretarse junto con la matriz de confusión y métricas de la clase positiva (Fawcett, 2006).

2.7.2 Matriz de Confusión y Métricas Derivadas

La Matriz de Confusión es una tabla transversal que evalúa el desempeño de algoritmos de clasificación supervisada (Provost & Fawcett, 2013). Descompone las predicciones en cuatro cuadrantes:

- **Verdaderos positivos (TP):** casos de rezago correctamente identificados.
- **Verdaderos negativos (TN):** casos sin rezago correctamente identificados.
- **Falsos positivos (FP):** alertas emitidas para casos que no presentaron rezago.
- **Falsos negativos (FN):** casos de rezago no detectados por el clasificador.

A partir de ella se desprenden las métricas reales que evalúan este proyecto:

1. **Precisión (Precisión):** De todos los que el modelo etiquetó en riesgo, ¿cuántos realmente fracasaron? ($TP / (TP + FP)$).
2. **Exhaustividad o Sensibilidad (Recall):** proporción de positivos reales detectados, $TP / (TP + FN)$. Debe interpretarse junto con las falsas alarmas y los recursos disponibles para la intervención.

2.8 Ecosistema Tecnológico y Reproducibilidad Computacional

El desarrollo se ejecutó en Python 3.12.0 y combinó documentos computacionales, scripts y módulos reutilizables. Python constituye el lenguaje de programación; las bibliotecas amplían sus capacidades para manipular datos, entrenar modelos y construir visualizaciones. Por tanto, pandas o Streamlit no son tipos de notebook ni de script, sino dependencias que pueden importarse desde ambos formatos (Python Software Foundation, 2026).

2.8.1 Diferencia entre notebook, script y módulo

Un notebook de Jupyter (.ipynb) organiza código en celdas y permite conservar junto a él explicaciones, tablas y salidas gráficas. Esta combinación favorece la exploración, la comunicación del procedimiento y la revisión de resultados, aunque su reproducibilidad exige ejecutar las celdas en orden y declarar el entorno utilizado (Kluyver et al., 2016). En este proyecto, los notebooks documentan las actividades de recolección y limpieza (Obj 1), análisis descriptivo (Obj 2), entrenamiento (Obj 3) y evaluación-segregación (Obj 4).

Un script es un archivo .py ejecutable que reúne instrucciones para repetir una tarea sin interacción celda por celda. Por ejemplo, *scripts/train_models.py* reconstruye transiciones, entrena los clasificadores, calcula métricas y guarda artefactos. Un módulo también utiliza la extensión .py, pero se diseña principalmente para exponer funciones o clases que otros archivos importan; en el prototipo, *src/data_loader.py*, *src/predictor.py* y los componentes de *src/ui/* cumplen esta función. Un mismo archivo puede actuar como módulo y como script si ofrece funciones importantes y además, un punto de entrada ejecutable.

2.8.2 Bibliotecas de análisis, modelado y visualización

Pandas proporciona estructuras tabulares y operaciones de lectura, combinación, agrupación y transformación; NumPy aporta arreglos y cálculo numérico; y scikit-learn implementa los clasificadores, el escalado y las métricas de evaluación (McKinney, 2010; Harris et al., 2020; Pedregosa et al., 2011). Matplotlib y Seaborn se emplean en los notebooks para generar gráficos estáticos de análisis y evaluación (Hunter, 2007; Waskom, 2021).

Tecnología	Versión	Función en el proyecto	Evidencia verificable
Python	3.12.0	Lenguaje y entorno de ejecución	resultados_modelos/metricas_modelos.json
Jupyter Notebook	.ipynb	Experimentación documentada y salidas por objetivo	notebooks/Obj1...Obj4
pandas	2.3.3	Lectura, consolidación, limpieza y agrupación tabular	notebooks, scripts y src/data_loader.py
NumPy	2.1.3	Arreglos y cálculo numérico	scripts/train_models.py y simuladores
scikit-learn	1.8.0	Modelos, escalado y métricas	scripts/train_models.py y modelos_entrenados/
Matplotlib / Seaborn	3.10.8 / 0.13.2	Gráficos estáticos y matrices de confusión	notebooks y scripts/generate_all_figures.py
Joblib	1.5.3	Serialización de modelos y escalador	modelos_entrenados/*.pkl
OpenPyXL	3.1.5	Motor de lectura de archivos XLSX	requirements.txt y proceso ETL
Plotly	6.6.0	Gráficos interactivos del prototipo	src/ui/tab_course_mon.py y tab_free_sim.py
Streamlit	1.42.0	Interfaz web, filtros, tarjetas y navegación	app.py y src/ui/

Tabla 2-1: Tecnologías verificadas y función dentro del proyecto

Fuente: elaboración propia a partir de requirements.txt, los notebooks, scripts y módulos del prototipo (2026).

2.8.3 Dashboard interactivo con Streamlit y Plotly

Streamlit transforma scripts de Python en aplicaciones de datos interactivas y ejecuta nuevamente el script cuando cambia un control de la interfaz. En el prototipo, app.py funciona como punto de entrada y coordina carga, filtros, inferencia y vistas; los archivos de *src/ui/* separan la presentación por componentes. Plotly genera las visualizaciones interactivas que permiten explorar distribuciones y escenarios sin alterar el historial institucional (Streamlit, 2024; Plotly Technologies Inc., s. f.).

2.8.4 Dependencias y reproducibilidad

El archivo `requirements.txt` fija las versiones empleadas para reducir diferencias entre entornos. Los notebooks conservan la evidencia explicativa; los scripts automatizan las tareas repetibles; los módulos evitan duplicación de lógica; y los artefactos JSON y PKL registran resultados y modelos. Esta separación mejora la trazabilidad, pero no garantiza por sí sola la reproducibilidad: también deben conservarse el dataset autorizado, su huella SHA-256, el orden de ejecución, las semillas aleatorias y la versión del código.

3. Ingeniería del proyecto

Esta sección describe procedimental y técnicamente cómo se desarrolló el proyecto, abarcando desde la concepción del área de estudio hasta la implementación de algoritmos de *Machine Learning* y construcción de la interfaz.

3.1 Área de Estudio

El área de estudio se centra en el departamento de Cochabamba, específicamente en una unidad educativa del nivel primario Jose Maria Santivañez turno mañana, ubicada en la zona Norte de la ciudad sobre la calle Quilla y Av Melchor Pérez de Olguin (ver figura 3-1). La institución cuenta con paralelos "A" y "B" desde el primer hasta el sexto curso de primaria. La población objetivo para el análisis de este proyecto comprende a los estudiantes matriculados y evaluados en las gestiones 2022, 2023 y 2024.




Figura 3-1: Área de estudio de la UE Jose Maria Santivañez

Fuente: Google Maps 2026

3.2 Flujograma Metodológico

En la Figura 3-2, es presentado el flujograma metodológico, en el cual es mostrada de manera clara y organizada cada una de las etapas que fueron desarrolladas y vinculadas con los objetivos específicos del proyecto. En dicho flujograma es abarcado el proceso que va desde la preparación del conjunto de datos para ambos modelos hasta su construcción y evaluación.




Figura 3-2: Flujograma

Fuente: Elaboración propia 2026

El proyecto de predicción de rezago escolar se estructuró operativamente bajo un enfoque cuantitativo y secuencial referenciado en fases de Ciencia de Datos :

Recopilación y Extracción de Datos: Obtención de boletines históricos (PDF).

Transformación y Limpieza (ETL): Conversión a Excel e ingesta en Python (Pandas) para tratar valores nulos y estandarizar nombres.

Análisis Exploratorio y Creación de Atributos: Cálculo de variables predictoras derivadas (Ej: Promedio anterior, número de reprobadas previas).

Modelado y Entrenamiento (Machine Learning): Separación en conjuntos de entrenamiento y prueba para Decision Trees, Random Forest y MLP.

Evaluación Comparativa de Modelos: Medición matemática del rendimiento usando matrices de confusión sobre datos reales.

Implementación del Prototipo (Despliegue): Diseño de la herramienta gráfica de apoyo docente utilizando la librería Streamlit y los modelos exportados.

3.3 Fuentes de la Información

3.3.1 Datos Secundarios

Para el desarrollo de la presente investigación y el entrenamiento de los modelos predictivos, se utilizaron fuentes de información basadas en datos secundarios. Los datos fueron extraídos de los registros administrativos e históricos de la unidad educativa, abarcando las gestiones 2022, 2023 y 2024. Esta información fue recopilada originalmente por el sistema escolar para el seguimiento académico regular.

3.4 Recolectar y depurar datos académicos históricos de alumnos de varios cursos y gestiones.

3.4.1 Recolección de datos y transformación a formato Excel

Los datos base fueron recolectados en formato PDF, directamente de los centralizadores oficiales (RUDE) de los años 2022 a 2024 proporcionados por la administración educativa.

La Figura 3-3 muestra la organización de los archivos por gestión escolar, estructura que permitió controlar la procedencia temporal de cada boletín antes de su consolidación.




Figura 3-3: Carpetas por gestión escolar

Fuente: Elaboración propia 2026

La Figura 3-4 presenta los boletines centralizados separados por curso y paralelo; esta disposición se utilizó para comprobar que las 36 planillas esperadas estuvieran disponibles.



Figura 3-4: boletines centralizados

Fuente: Elaboración propia 2026

La Figura 3-5 ilustra la estructura de un boletín anual de origen. La evidencia se incluye para documentar la heterogeneidad de encabezados y metadatos que justificó el procedimiento de limpieza.

ESTADO PLURINACIONAL DE BOLIVIA
MINISTERIO DE EDUCACIÓN

BOLETÍN DE PROMOCIÓN ANUAL PRIMARIA COMUNITARIA VOCACIONAL

Sistema de Información Educativa

GESTIÓN: 2022
NIVEL: PRIMARIA COMUNITARIA VOCACIONAL
UNIDAD EDUCATIVA: JOSE MARIA SANTIVÁÑEZ

DEPARTAMENTO: COCHABAMBA
AÑO DE ESCOLARIDAD: CUARTO
DIRECTORAS: JUDITH GARCIA DE ALVAREZ

DISTRITO: COCHABAMBA I
PARALELO: A
DIRECCIÓN: AV. PUEBLO DE BOLIVIA Y ABRAHAM LINCOLN

CÓDIGO SIG: 8990027
TURNOS: MAÑANA
TELÉFONOS: 4013406 - 72734555

Comunidad y Escuela

Nro.	Apellidos y Nombres	Código Rndc	Gen	Fecha Nac	Lug. Nac	Nro. C.E.	Estado	Comunidad y Escuela		C. Teorías y Prof.		Vida Tierra/Territorio		Comun y Participación		
								PA	PS	PA	PS	PA	PS	PA	PS	
1	ALBERTO PAZ	899002027109	M	20.12.2012	CRB	1569949	PROMOVIDO	81	80	79	71	77	82	88	78	78
2	APAZA CARMELA	899002027106	F	11.12.2012	CRB	1620781	PROMOVIDO	82	81	89	81	82	81	81	81	82
3	AYVENDANO ROBERTO	899002027104	F	20.08.2012	CRB	1569949	PROMOVIDO	82	77	79	78	79	77	79	77	77
4	KARREDA DIEGO LARA	899002027106	M	11.05.2013	CRB	1569949	PROMOVIDO	77	78	82	72	78	78	78	77	77
5	KARREDA ALBERTO JOSE	899002027103	M	09.11.2012	LP	1751102	PROMOVIDO	82	80	89	81	89	81	87	89	81
6	BEAR CILLARREAL LEONEL RENEE	899002027109	M	10.05.2013	CRB	1569949	PROMOVIDO	83	80	89	82	89	82	78	82	81
7	COCA BERTARDO	899002027106	F	11.08.2012	CRB	1569949	PROMOVIDO	88	88	78	79	89	89	89	79	89
8	COCA CAROLINA	899002027107	F	09.12.2012	CRB	1659949	PROMOVIDO	81	78	77	81	77	77	77	78	68
9	FLORIN RAMA	899002027101	F	09.11.2012	CRB	1569949	PROMOVIDO									
10	FLORIN ESPERANZA	899002027103	F	20.10.2011	CRB	1569949	PROMOVIDO	81	81	72	71	79	82	71	84	86
11	FLORIN LUCAS	899002027109	F	09.08.2012	CRB	1569949	PROMOVIDO	89	78	77	66	72	86	87	79	89
12	FLORIN VICTORIA	899002027103	F	09.08.2013	CRB	1682746	PROMOVIDO	78	78	75	68	79	72	67	72	88
13	FLORIN SERGIO	899002027107	M	27.05.2013	CRB	1769949	PROMOVIDO	83	86	86	80	86	86	86	87	86
14	FLORIN JUAN	899002027103	F	09.05.2013	CRB	1682746	PROMOVIDO	83	87	88	83	82	82	81	82	79
15	FLORIN CARLOS	899002027101	M	07.06.2013	CRB	1569949	PROMOVIDO	82	82	83	80	88	84	87	88	78
16	FLORIN ALAN	899002027101	M	25.05.2012	CRB	1569949	PROMOVIDO	79	82	89	74	86	82	82	82	88
17	FLORIN YANIS	899002027103	F	12.11.2012	CRB	1682746	PROMOVIDO	79	87	78	74	75	81	79	79	77
18	FLORIN ALAN	899002027103	M	27.02.2013	CRB	1569949	PROMOVIDO	80	88	79	81	78	78	78	79	82
19	FLORIN PABLO	899002027103	M	06.05.2013	CRB	1671771	PROMOVIDO	81	85	74	79	83	89	89	79	82
20	FLORIN LUIS	899002027103	F	11.12.2012	CRB	1682746	PROMOVIDO	71	79	87	81	75	75	65	75	86
21	FLORIN RAFAEL	899002027103	M	11.10.2012	CRB	1682746	PROMOVIDO	80	76	85	85	89	82	81	87	87
22	FLORIN ROBERTO	899002027103	M	20.08.2012	CRB	1682746	PROMOVIDO	78	87	87	85	81	81	81	81	81

Quiénes firmamos el presente documento, declaramos que los datos son verídicos y auténticos, de no serlo nos sometemos a las sanciones que establece la Ley.

Quiénes firmamos el presente documento, declaramos que los datos son verídicos y auténticos, de no serlo nos sometemos a las sanciones que establece la Ley.

Figura 3-5: Boletín de anual

Fuente: Elaboración propia 2026

Originalmente, esta información se encontraba almacenada en documentos de formato PDF, lo cual supuso un reto técnico inicial, ya que dicho formato está diseñado para la visualización y no para el procesamiento computacional de datos. Por este motivo, se utilizó la página web “IlovePdf” para transformar el formato de “pdf” a “xlsx”.

La Figura 3.6 muestra el resultado de la conversión a Excel, formato empleado como entrada para la lectura, tipificación y validación en Python.



Figura 3-6: Boletines transformados a excel

Fuente: Elaboración propia 2026

Para la fase de recolección de datos de este proyecto, se extrajo la información de la institución educativa considerando las siguientes características de la población estudiantil:

- **Temporalidad:** Los datos corresponden a registros de carácter anual.
- **Niveles educativos:** La muestra abarca los cursos comprendidos desde el primer (1°) hasta el sexto (6°) grado.
- **Distribución de aulas:** La información de cada grado se encuentra segmentada en dos paralelos o secciones, designados como 'A' y 'B'.

3.4.2 Proceso de Extracción y Limpieza

Para automatizar la consolidación de los boletines heterogéneos, se diseñó la función *limpiar_boletin_v2()* en el cuaderno *Obj1_Recoleccion_Limpieza.ipynb*. Esta función identifica dinámicamente la fila de encabezados mediante la búsqueda de palabras clave como "PATERNO", "NOMBRES" o "RUDE", descarta filas de metadatos institucionales y estandariza los nombres de las columnas.

```

# Snippet 3.1: Función de extracción y homogenización de boletines escolares
# Extraído de: notebooks/Obj1_Recoleccion_Limpieza.ipynb

def limpiar_boletin_v2(path):
    import pandas as pd
    import os
    raw = pd.read_excel(path, header=None, engine="openpyxl")

    # Detectar dinámicamente la fila donde inician los datos del centralizador
    start_row = None
    for i in range(len(raw)):
        row_str = raw.iloc[i].astype(str).str.upper().tolist()
        if any("PATERNO" in cell or "NOMBRES" in cell or "RUDE" in cell for cell in row_str):
            start_row = i
            break

    if start_row is None:
        raise ValueError(f"No se encontró fila de encabezados en {path}")

    df = pd.read_excel(path, skiprows=start_row, engine="openpyxl")

    # Normalizar nombres de columnas a minúsculas sin espacios
    df.columns = (
        df.columns.astype(str)
        .str.strip()
        .str.lower()
        .str.replace("\n", "")
        .str.replace(" ", "_")
    )

    # Extraer metadatos de año escolar y paralelo desde el nombre del archivo
    filename = os.path.basename(path)
    df["archivo_origen"] = filename
    return df

```

Figura 3-7: Función de extracción y homogeneización de boletines escolares

Fuente: Elaboración propia 2026

3.4.3 Consolidación y Construcción de la Variable Rezago

Tras procesar 36 boletines de 2022 a 2024, se obtuvieron 1.118 observaciones estudiante-año correspondientes a 592 estudiantes únicos. La etiqueta rezago se definió como al menos una asignatura con nota inferior a 51; no equivale a repetición de curso ni deserción.

```
# Snippet 3.2: Consolidación del dataset y creación de la variable target 'rezago'
# Extraído de: notebooks/Obj1_Recoleccion_Limpieza.ipynb

import glob, os, pandas as pd

materias = [
    "com_lenguajes", "cs_sociales", "edu_fisica", "edu_musical",
    "art_plasticas", "matematica", "tec_tecnologica", "cs_naturales",
    "valores_religion"
]

# Definición de la condición de reprobación (nota < 51) y variable rezago
dataset["num_materias_reprobadas"] = (dataset[materias] < 51).sum(axis=1)
dataset["promedio_general"] = dataset[materias].mean(axis=1)
dataset["rezago"] = (dataset["num_materias_reprobadas"] > 0).astype(int)

# Exportación del conjunto consolidado
dataset.to_csv("../data/03_Datasets_Procesados/primaria_dataset.csv", index=False, encoding="utf-8")
```

Figura 3-8: Consolidación del dataset y creación de la variable target 'rezago'

Fuente: Elaboración propia 2026

3.4.4 Controles de calidad y evidencia de consolidación

La consolidación no se consideró terminada con la unión de planillas. Se verificaron columnas obligatorias, conversión numérica, rango de 0 a 100, unicidad de la combinación estudiante–gestión y completitud de las nueve asignaturas. El resultado fue de 1.118 observaciones estudiante-año de 592 estudiantes: 1.030 registros completos y 88 incompletos. Los faltantes se conservaron explícitamente y no recibieron predicción.

La Tabla 3.1 documenta los controles que permiten auditar la entrada antes del análisis y del modelado.

Control	Criterio implementado	Respuesta	Evidencia
Esquema	Gestión, grado, paralelo, identificador y nueve asignaturas.	Se informa cada columna faltante.	validate_dataframe()
Tipo	Calificaciones convertibles a número.	Se marca como faltante el valor no convertible.	src/data_loader.py
Rango	Cada nota debe estar entre 0 y 100.	Se rechaza el conjunto cargado.	Prueba automatizada
Unicidad	Una observación por estudiante y gestión.	Se reporta la duplicidad.	Clave RUDE–gestión
Completitud	Nueve calificaciones presentes.	Se conserva como «Sin datos»; no se predice.	datos_completos

Tabla 3-1: Reglas de validación y tratamiento de datos académicos

Fuente: elaboración propia con base en src/data_loader.py y tests/test_project.py (2026).

3.5 Analizar los datos para identificar patrones de rezago académico y factores asociados como materias críticas

El objetivo específico 2 se desarrolló en *Obj2a_Analisis_Patrones.ipynb* sobre el dataset consolidado. La unidad descriptiva fue una observación estudiante-año y se analizaron nueve asignaturas, el promedio general, el número de materias reprobadas y la etiqueta rezago de la misma gestión. El análisis se mantuvo agregado para no exponer identidades.

3.5.1 Preparación de variables y criterio de cálculo

Antes de calcular porcentajes se comprobó la disponibilidad de cada nota. Se corrigió el denominador del notebook para que una calificación faltante no sea tratada implícitamente como aprobada: la tasa de cada asignatura se calculó sobre las 1.030 notas válidas y los 88 registros incompletos se excluyeron del denominador. La condición de reprobación se mantuvo en nota inferior a 51.

```
materias = [  
    "com_lenguajes",  
    "cs_sociales",  
    "edu_fisica",  
    "edu_musical",  
    "art_plasticas",  
    "matematica",  
    "tec_tecnologica",  
    "cs_naturales",  
    "valores_religion"  
]  
  
notas_validas = dataset[materias].notna()  
tasas_reprobacion = (  
    dataset[materias].lt(51)  
    .where(notas_validas)  
    .mean()  
    .sort_values(ascending=False) * 100  
)  
tasas_reprobacion
```

Figura 3-9: Consolidación del dataset y creación de la variable target 'rezagado'

Fuente: Elaboración propia 2026

Los resultados empíricos revelaron que **Comunicación y Lenguajes** (2.06%) y **Matemática** (1.70%) constituyen las áreas de mayor vulnerabilidad académica en el nivel primario.

3.5.2 Identificación de materias críticas

El bloque anterior produjo una serie ordenada de nueve porcentajes. La Figura 3-9 reproduce esa salida sin registros individuales. Comunicación y Lenguajes alcanzó 2,23 % y Matemática 1,84 %; el resto de las asignaturas permaneció por debajo de 1,30 %. La denominación «materias críticas» indica prioridad descriptiva de revisión y no causalidad.




Figura 3-9: Salida agregada del notebook: tasa de reprobación por asignatura sobre nota

Fuente: elaboración propia a partir de Obj2a_Analisis_Patrones.ipynb y primaria_dataset.csv (2026).

3.5.3 Comparación de Medias por Condición de Rezago

El análisis comparativo de promedios entre estudiantes aprobados ($rezago=0$) y rezagados ($rezago=1$) demostró que los alumnos en riesgo sufren un deterioro generalizado en todas las áreas del conocimiento como se ve en la Figura 3-10:


```
dataset.groupby("rezago")[materias].mean()
```

	com_lenguajes	cs_sociales	edu_fisica	edu_musical	art_plasticas	matematica	tec_tecnologica	cs_naturales	valores_religion
rezago									
0	74.486594	74.479643	78.019861	77.409136	75.926514	73.472691	76.271102	75.040715	70.329692
1	45.956522	49.173913	58.739130	57.608696	53.434783	47.043478	53.130435	49.869565	49.826087

Figura 3-10: Comparación de promedios de grupo de rezago

Fuente: elaboración propia a partir de *Obj2a_Analisis_Patrones.ipynb* (2026).

Indicador	Sin rezago	Con rezago	Diferencia descriptiva
Promedio general	75,05	51,64	−23,41 puntos
Materias reprobadas	0,00	4,13	+4,13 materias
Comunicación y Lenguajes	74,49	45,96	−28,53 puntos
Matemática	73,47	47,04	−26,43 puntos

Tabla 3-2: Salida resumida de la comparación descriptiva por condición de rezago

Fuente: elaboración propia a partir de *Obj2a_Analisis_Patrones.ipynb* y *primaria_dataset.csv* (2026).

3.5.4 Alcance de la evidencia del Objetivo 2

Las diferencias entre grupos son parcialmente esperables porque el rezago se define a partir de las mismas calificaciones: una observación pertenece al grupo con rezago cuando al menos una asignatura es inferior a 51. Por ello, estas medidas describen la muestra y orientan la focalización pedagógica, pero no demuestran que una asignatura cause el rezago ni que la magnitud observada se replique en otra institución. La interpretación completa se desarrolla en el apartado 4.2.

3.6 Diseñar y entrenar modelos predictivos de machine learning (Árboles de decisión, Random Forest, Redes Neuronales) para anticipar alumnos en riesgo.

El objetivo específico 3 se implementó de forma centralizada en *scripts/train_models.py*. Los cuadernos *Obj3a_Entrenamiento_Arboles_RF.ipynb* y *Obj3b_Entrenamiento_Red_Neuronales.ipynb* leen el artefacto *resultados_modelos/metricas_modelos.json* y conservan las tablas y gráficas de verificación. Esta separación evita que el entrenamiento se replique con configuraciones diferentes entre notebooks.

3.6.1 Construcción longitudinal $T \rightarrow T+1$

La predicción no se formuló sobre la etiqueta de la misma fila. Para cada estudiante se ordenaron las gestiones y se desplazó la etiqueta una posición, de modo que las variables de T promedio general y número de materias reprobadas intentan anticipar *rezago_next* en $T+1$. Se exigió continuidad anual,

predictores completos y datos completos en la gestión objetivo; los identificadores se utilizaron únicamente para vincular registros y no ingresaron al modelo.

```
def build_transitions(dataset: pd.DataFrame) -> pd.DataFrame:
    required = {"rude", "gestion", "rezago", *FEATURE_SOURCE}
    missing = sorted(required - set(dataset.columns))
    if missing:
        raise ValueError(f"Faltan columnas requeridas: {missing}")

    data = dataset.sort_values(["rude", "gestion"]).copy()
    data["gestion_objetivo"] = data.groupby("rude")["gestion"].shift(-1)
    data["rezago_next"] = data.groupby("rude")["rezago"].shift(-1)
    target_features = data.groupby("rude")[FEATURE_SOURCE].shift(-1)
    data["objetivo_completo"] = target_features.notna().all(axis=1)
    transitions = data[
        data["gestion_objetivo"].eq(data["gestion"] + 1)
        & data["rezago_next"].notna()
        & data[FEATURE_SOURCE].notna().all(axis=1)
        & data["objetivo_completo"]
    ].copy()
    transitions = transitions.rename(
        columns={
            "promedio_general": "promedio_general_prev",
            "num_materias_reprobadas": "num_materias_reprobadas_prev",
        }
    )
    transitions["rezago_next"] = transitions["rezago_next"].astype(int)
    return transitions
```

Figura 3-11: Construcción de transiciones consecutivas

Fuente: elaboración propia a partir de `scripts/train_models.py`, función `build_transitions()`; ejecución documentada por Obj3a/Obj3b (2026).


3.6.2 Partición temporal de entrenamiento y prueba

La muestra predictiva quedó formada por 489 transiciones: 241 de 2022→2023 para ajuste y 248 de 2023→2024 para prueba. Cada partición contiene tres positivos. Se excluyeron 33 pares potenciales con etiqueta objetivo incompleta. La partición cronológica evita entrenar con 2024 para luego evaluar 2023, aunque no resuelve la escasez de eventos.

Componente	Periodo	N	Positivos	Uso
Dataset descriptivo	2022–2024	1.118	23 observaciones	Caracterización
Transiciones válidas	T→T+1	489	6	Modelado
Entrenamiento	2022→2023	241	3	Ajuste
Prueba temporal	2023→2024	248	3	Evaluación
Pares excluidos	T→T+1	33	No aplicable	Objetivo incompleto

Tabla 3-3: Construcción y partición de la muestra predictiva longitudinal

Fuente: elaboración propia a partir de scripts/train_models.py y resultados_modelos/metricas_modelos.json (2026).



489 transiciones válidas; 6 casos positivos. Las métricas se interpretan como exploratorias.

Figura 3-12: Construcción longitudinal y partición cronológica del modelado

Fuente: elaboración propia a partir de scripts/train_models.py y metricas_modelos.json (2026).

3.6.3 Configuración y ajuste de los clasificadores

Se ajustaron un árbol de decisión, un Random Forest y una red neuronal MLP con semilla 42. Árbol y bosque utilizaron ponderación balanceada; la MLP recibió variables estandarizadas mediante StandardScaler ajustado exclusivamente con entrenamiento durante la evaluación. No se ejecutó una búsqueda extensa de hiperparámetros, por lo que las configuraciones deben entenderse como experimentales y reproducibles, no como óptimos demostrados.

Modelo	Configuración evaluada	Preprocesamiento	Control
Árbol	max_depth=3; min_samples_leaf=10; class_weight='balanced'	Ninguno	random_state=42

Modelo	Configuración evaluada	Preprocesamiento	Control
Random Forest	n_estimators=300; max_depth=4; min_samples_leaf=5; class_weight='balanced'	Ninguno	random_state=42
MLP	hidden_layer_sizes=(4,); alpha=0,1; learning_rate_init=0,0001; max_iter=1000	StandardScaler	random_state=42

Tabla 3-4: Configuraciones reproducibles de los clasificadores

Fuente: elaboración propia con base en `make_models()` de `scripts/train_models.py` (2026).

```
def main() -> None:
    dataset = pd.read_csv(DATA_PATH)
    transitions = build_transitions(dataset)
    train = transitions[transitions["gestion"].eq(2022)].copy()
    test = transitions[transitions["gestion"].eq(2023)].copy()
    if train.empty or test.empty:
        raise ValueError("No existen transiciones temporales suficientes para 2022 y 2023.")

    X_train, y_train = train[FEATURE_MODEL], train["rezago_next"]
    X_test, y_test = test[FEATURE_MODEL], test["rezago_next"]
    evaluation = {}
    models = make_models()
    scaler_eval = StandardScaler().fit(X_train)

    for name, model in models.items():
        if name == "mlp":
            model.fit(scaler_eval.transform(X_train), y_train)
            prob = model.predict_proba(scaler_eval.transform(X_test))[:, 1]
        else:
            model.fit(X_train, y_train)
            prob = model.predict_proba(X_test)[:, 1]
        evaluation[name] = metrics(y_test, prob)
    evaluation["baseline_sin_rezago"] = majority_baseline(y_test)

    # Modelos de despliegue: se reentrenan con todas las transiciones observadas.
    X_all, y_all = transitions[FEATURE_MODEL], transitions["rezago_next"]
    deploy = make_models()
    scaler = StandardScaler().fit(X_all)
    deploy["random_forest"].fit(X_all, y_all)
    deploy["mlp"].fit(scaler.transform(X_all), y_all)
```

Figura 3-13: Ajuste diferenciado y cálculo de probabilidades en la prueba

Fuente: elaboración propia a partir de `scripts/train_models.py`, bucle de evaluación; salidas leídas por `Obj3a/Obj3b` (2026).

3.6.4 Artefactos generados y reproducibilidad

La ejecución exportó `random_forest_model.pkl`, `mlp_model.pkl` y `scaler.pkl` para el prototipo. El archivo `metricas_modelos.json` registra versión 1.1.0, fecha UTC, SHA-256 del dataset, versiones del entorno, orden

de variables, tamaños de las particiones, matrices y métricas. Los modelos de despliegue se volvieron a entrenar con las 489 transiciones disponibles después de completar la evaluación temporal; por ello no deben confundirse con los modelos evaluados únicamente sobre la partición de entrenamiento.

3.7 Evaluar los modelos propuestos y segregar a los estudiantes en grupos de riesgo para facilitar planes de apoyo.

El objetivo específico 4 combinó dos componentes que se documentan por separado: evaluación estadística sobre 2023→2024 y clasificación operativa para priorizar la revisión docente. La evaluación se calculó con umbral 0,50 y se comparó con una línea base que siempre predice ausencia de rezago.

3.7.1 Métricas y salida ejecutada del notebook

Se reportaron precisión, recall y F1 para la clase positiva, exactitud balanceada y average precision. La exactitud simple no se utilizó como criterio principal porque 245 de las 248 observaciones de prueba pertenecen a la clase sin rezago. El notebook *Obj4_Evaluacion_Segregacion_Riesgo.ipynb* cargó el JSON y construyó la tabla comparativa mostrada en el código de la Figura 3-14




Figura 3-14: Lectura de resultados y construcción de la tabla comparativa

Fuente: elaboración propia a partir de Obj4_Evaluacion_Segregacion_Riesgo.ipynb, celda ejecutada 2 (2026).


Modelo	P (+)	R (+)	F1 (+)	BA	AP
Línea base	0,0000	0,0000	0,0000	0,5000	0,0121
Árbol	0,0714	0,3333	0,1176	0,6401	0,0319
Random Forest	0,0714	0,3333	0,1176	0,6401	0,0636
MLP	0,0000	0,0000	0,0000	0,5000	0,2332

Tabla 3-5: Métricas reproducidas en la prueba temporal 2023→2024 (N=248)

Fuente: resultados_modelos/metricas_modelos.json, versión 1.1.0 (2026).

La Figura 3-15 representa la salida agregada conservada en el notebook. Árbol y Random Forest alcanzaron igual clasificación al umbral 0,50; la MLP no identificó positivos, aunque obtuvo mayor average precision. Con solo tres positivos, ninguna diferencia permite declarar superioridad concluyente.

Salida ejecutada del cuaderno de evaluación temporal



Prueba 2023→2024: N=248 y solo 3 positivos; no demuestra generalización.

Figura 3-15: Comparación de métricas generada por el notebook de evaluación temporal

Fuente: elaboración propia a partir de Obj4_Evaluacion_Segregacion_Riesgo.ipynb y metricas_modelos.json (2026).

3.7.2 Lectura de las matrices de confusión

La Figura 3-16 muestra las matrices [TN, FP], [FN, TP]. Árbol y Random Forest produjeron 232 verdaderos negativos, 13 falsos positivos, dos falsos negativos y un verdadero positivo. La MLP clasificó los 248 casos como sin rezago: 245 verdaderos negativos y tres falsos negativos. Esta salida evidencia por qué la exactitud aparente de la clase mayoritaria no equivale a capacidad de detección.

Matrices de confusión conservadas en el notebook de evaluación													
		Árbol		Random Forest		MLP							
		Pred.: No rezago	Pred.: Rezago			Pred.: No rezago	Pred.: Rezago						
Real: No rezago		232	13			232	13					245	0
		2	1			2	1					3	0
Real: Rezago													

Figura 3-16: Matrices de confusión obtenidas en la prueba temporal

Fuente: elaboración propia salida agregada de *Obj4_Evaluacion_Segregacion_Riesgo.ipynb* (2026).

3.7.3 Segregación operativa y resguardo pedagógico

Para trasladar la salida al prototipo se conservaron dos valores: *probabilidad_modelo* y *probabilidad_operativa*. La segunda puede elevarse mediante reglas pedagógicas para evitar que un registro con calificaciones actuales y reprobatorias aparezca como prioridad baja. Este ajuste no recalibra el modelo, no corrige falsos negativos futuros y no se reporta como desempeño estadístico.

```
# Inferencia del modelo de Machine Learning
if "Random Forest" in modelo_nombre:
    prob = float(rf_model.predict_proba(input_data)[0][1])
else:
    input_scaled = scaler.transform(input_data)
    prob = float(mlp_model.predict_proba(input_scaled)[0][1])

# --- CAPA DE RESGUARDO PEDAGÓGICO NORMATIVO (SISTEMA HÍBRIDO) ---
# Garantiza coherencia pedagógica: promedio < 51 o 2+ reprobadas es Alto Riesgo
if promedio < MIN_APROBACION_NOTA or reprobadas >= 2:
    prob = max(prob, 0.85)
elif reprobadas == 1 or (MIN_APROBACION_NOTA <= promedio < 60.0):
    prob = max(prob, 0.50)

# Categorización según umbrales institucionales
if prob >= 0.70:
    cat = "Alto Riesgo"
elif prob >= 0.40:
    cat = "Medio Riesgo"
else:
    cat = "Bajo Riesgo"

info = PALETA_RIESGO[cat]
return prob, cat, info["color"], info["badge"], info["rec"]
```

Figura 3-17: Regla pedagógica y categorización operativa

Fuente: elaboración propia a partir de *Obj5_Prototipo_Dashboard_Docente/src/predictor.py* (2026).

Nivel	Regla	Significado operativo	Uso permitido
Alto	$P \geq 0,70$ o resguardo alto	Prioridad de revisión	Revisión humana inmediata
Medio	$0,40 \leq P < 0,70$	Seguimiento focalizado	Contrastar contexto
Bajo	$P < 0,40$	Monitoreo regular	No descarta otras dificultades
Sin datos	No se calcula	Notas incompletas	Completar información

Tabla 3-6: Reglas de segregación operativa del riesgo

Fuente: elaboración propia con base en `config.py` y `src/predictor.py` (2026).

La Figura 3-18 explica el orden de las comprobaciones: validación de datos, inferencia, aplicación separada del resguardo y presentación del motivo de alerta.




Figura 3-18: Lógica de inferencia y resguardo pedagógico del sistema híbrido

Fuente: elaboración propia con base en `src/predictor.py` y `config.py` (2026).

3.7.4 Limitaciones de la evaluación

Al aplicar la lógica operativa a las 1.118 observaciones se obtuvieron 881 registros en Bajo riesgo, 116 en Medio, 33 en Alto y 88 Sin datos. Esta distribución describe la priorización del prototipo con datos históricos; no es una estimación validada de prevalencia futura ni prueba que una intervención mejore el aprendizaje. La escasez de positivos, el uso de dos predictores y la ausencia de validación externa obligan a mantener revisión humana.

3.8 Proponer un prototipo de apoyo a la decisión docente con alertas tempranas

El objetivo específico 5 se materializó como una aplicación Streamlit en *Obj5_Prototipo_Dashboard_Docente*. El prototipo convierte los artefactos del modelado en un flujo de consulta: carga datos, valida el esquema, calcula variables, ejecuta la inferencia, conserva el motivo de la alerta y presenta resultados agregados o individuales en modo demostración.

3.8.1 Requisitos funcionales y arquitectura modular

Los requisitos implementados fueron: filtrar por gestión, grado y paralelo; mostrar cantidades por nivel; consultar una ficha de estudiante; simular calificaciones sin modificar el histórico; diferenciar probabilidad estadística y puntaje operativo; y bloquear predicciones cuando faltan notas. La Tabla 3-7 relaciona cada módulo con una responsabilidad comprobable.

Módulo	Responsabilidad	Entrada	Salida verificable
app.py	Coordinar navegación y renderizado	Estado de sesión	Pestañas y flujo principal
config.py	Centralizar rutas y umbrales	Configuración	Umbral 51 y paleta
src/data_loader.py	Validar y procesar nóminas	CSV/DataFrame	datos_completos y variables
src/predictor.py	Inferencia y resguardo	Promedio y reprobadas	Probabilidades, nivel y motivo
src/ui/	Presentar filtros y vistas	Datos enriquecidos	Monitoreo y simuladores

Tabla 3-7: Responsabilidades de la arquitectura modular del prototipo

Fuente: elaboración propia con base en el directorio *Obj5_Prototipo_Dashboard_Docente* (2026).

La Figura 3-19 representa el flujo entre interfaz, carga y validación, inferencia y presentación de alertas. La separación modular permite probar cada componente sin depender de toda la interfaz.




Figura 3-19: Arquitectura modular y flujo de ejecución del prototipo

Fuente: elaboración propia con base en `app.py`, `config.py` y los módulos `src/` (2026).

3.8.2 Flujo de carga, validación e inferencia

La carga admite el histórico institucional cuando existe localmente y utiliza la plantilla sintética en modo demostración. `validate_dataframe()` exige metadatos y nueve asignaturas, verifica rango y duplicados, y `process_dataframe()` calcula promedio y reprobadas únicamente cuando las notas están completas. `enrich_with_predictions()` evita inferir sobre filas incompletas y conserva las columnas `prob_modelo`, `prob_rezago`, `nivel_riesgo` y `motivo_alerta`.

```

for _, row in df.iterrows():
    complete = bool(row.get('datos_completos', True))
    complete = complete and pd.notnull(row.get('promedio_general')) and pd.notnull(row.get('num_materias_reprobadas'))
    if not complete:
        info = PALETA_RIESGO["Sin datos"]
        probs.append(float('nan'))
        probs_modelo.append(float('nan'))
        riesgos.append("Sin datos")
        badges.append(info['badge'])
        recs.append(info['rec'])
        motivos.append("Predicción no calculada: faltan una o más calificaciones")
        continue
    prom = float(row['promedio_general'])
    reprob = int(row['num_materias_reprobadas'])
    detail = predict_student_risk_details(prom, reprob, modelo_nombre, rf_model, mlp_model, scaler)
    probs.append(detail['probabilidad_operativa'])
    probs_modelo.append(detail['probabilidad_modelo'])
    riesgos.append(detail['nivel_riesgo'])
    badges.append(detail['badge'])
    recs.append(detail['recomendacion'])
    motivos.append(detail['motivo'])
  
```

Figura 3-20: Tratamiento de registros incompletos antes de inferir

Fuente: elaboración propia a partir de `Obj5_Prototipo_Dashboard_Docente/src/predictor.py`, función `enrich_with_predictions()` (2026).

3.8.3 Vistas implementadas y evidencia de ejecución

La vista de monitoreo presenta filtros de cohorte, tarjetas agregadas y una tabla de seguimiento. La Figura 3-21 corresponde a una ejecución local en modo demostración; los datos visibles son sintéticos o anonimizados. La interfaz no adopta una decisión pedagógica: organiza casos y muestra una recomendación sujeta a revisión profesional.




Figura 3-21: Vista de monitoreo del curso con filtros e indicadores agregados

Fuente: captura anonimizada de la aplicación Streamlit ejecutada localmente (2026).

El simulador libre recibe nueve calificaciones, calcula promedio y reprobadas, ejecuta el modelo seleccionado y presenta por separado probabilidad del modelo, puntaje operativo, nivel y motivo. La Figura 3-22 evidencia la salida sin modificar el dataset ni crear un registro institucional.




Figura 3-22: Simulador libre y separación entre probabilidad estadística y puntaje operativo

Fuente: captura anonimizada de la aplicación Streamlit ejecutada localmente (2026).

3.8.4 Verificación funcional y alcance actual

La verificación automatizada se ejecutó mediante *tests/test_project.py*. Los once controles comprobaron validación de esquema y rangos, tratamiento de filas incompletas, orden de variables, existencia de metadatos y línea base, disponibilidad de datos sintéticos, autenticación y separación entre probabilidad del modelo y resguardo. La Tabla 3-8 resume las evidencias más directamente relacionadas con el prototipo.

Componente	Comprobación	Resultado
Carga	Rechazo de notas fuera de 0–100 y columnas ausentes	Superado
Compleitud	Fila incompleta permanece «Sin datos»	Superado
Modelo	Orden exacto de dos variables y metadatos reproducibles	Superado
Privacidad	Datos sintéticos y seudonimización	Superado
Sistema híbrido	Probabilidad estadística separada del puntaje operativo	Superado

Tabla 3-8: Resumen de verificaciones funcionales automatizadas

Fuente: elaboración propia a partir de la ejecución de 11 pruebas en *tests/test_project.py* (2026).

Las pruebas confirman funcionamiento técnico y coherencia de reglas, pero no usabilidad ni impacto pedagógico. El producto sigue siendo un prototipo exploratorio sujeto a validación con docentes y no un sistema para decisiones automáticas.

4. Análisis de Resultados y Discusión

En este capítulo se presentan analíticamente los hallazgos obtenidos durante la ejecución del proyecto, estructurados en función al cumplimiento de los objetivos específicos planteados. Se incluye la interpretación estadística de los modelos predictivos generados y la comparación técnica de su desempeño.

4.1 Resultados y Análisis de la Recolección y Depuración de Datos (Obj. Esp. 1)

La ejecución del pipeline de recolección y limpieza (*Obj1_Recoleccion_Limpieza.ipynb*) permitió consolidar de forma exitosa los registros históricos de la U.E. José María Santiváñez correspondientes a las gestiones 2022, 2023 y 2024.

4.1.1 Caracterización del Dataset Consolidado

El conjunto de datos procesado (*primaria_dataset.csv*) contiene un total de **1,118 observaciones estudiantil-año** distribuidas en 26 variables estructuradas.

La Tabla 4-1 caracteriza el conjunto consolidado y permite distinguir observaciones, estudiantes únicos, variables y completitud antes de interpretar resultados.

Variable	Tipo de Dato	Descripción	Valores / Rango
gestion	Entero (int64)	Año académico de la evaluación	2022, 2023, 2024
anio_escolaridad	Texto (object)	Grado escolar	PRIMERO a SEXTO de Primaria
paralelo	Texto (object)	Sección de aula	A, B
rude	Texto (object)	Código Registro Único de Estudiante	Código alfanumérico único
gen	Texto (object)	Género del estudiante	F (Femenino), M (Masculino)
com_lenguajes ... valores_religion	Flotante (float64)	Calificaciones en las 9 asignaturas curriculares	$0,0 \leq \text{nota} \leq 100,0$
promedio_general	Flotante (float64)	Promedio aritmético general	$0,0 \leq \text{promedio} \leq 100,0$
num_materias_reprobadas	Entero (int64)	Cantidad de materias con nota < 51	$0 \leq N \leq 9$
rezago	Entero (int64)	Variable Objetivo Target	0 (Sin Rezago), 1 (Con Rezago)

Tabla 4-1: Caracterización del conjunto consolidado

Fuente: elaboración propia a partir de *primaria_dataset.csv* (2026).

4.1.2 Distribución de la Variable Objetivo 'Rezago'

De las 1,118 observaciones procesadas, **1,095 registros (97.94%)** corresponden a la categoría de aprobación regular (*Sin Rezago*), mientras que **23 registros (2.06%)** corresponden a estudiantes en condición de reprobación en una o más asignaturas (*Con Rezago*). Esta distribución evidencia un desbalance extremo de clases en el entorno escolar primario.

4.2 Resultados del Análisis Exploratorio de Patrones y Materias Críticas

(Obj. Esp. 2)

El análisis realizado en *Obj2a_Analisis_Patrones.ipynb* permitió responder a la segunda pregunta de investigación, identificando las asignaturas con mayor impacto en el rezago escolar.

4.2.1 Identificación Empírica de Materias Críticas

Al calcular la frecuencia relativa de reprobación (nota < 51.0) en cada una de las 9 materias del currículo, se obtuvieron los siguientes resultados:

Asignatura Curricular	Nombre Completo en el Sistema	Tasa de Reprobación (%)	Nivel de Criticidad
com_lenguajes	Comunicación y Lenguajes	2,23 %	Crítica Principal
matematica	Matemática	1,84 %	Crítica Secundaria
cs_naturales	Ciencias Naturales	1,26 %	Moderada
cs_sociales	Ciencias Sociales	1,07 %	Moderada
valores_religion	Valores, Espiritualidad y Religiones	0.98 %	Moderada
tec_tecnologica	Técnica Tecnológica	0,58 %	Baja
edu_musical	Educación Musical	0,49 %	Baja
art_plasticas	Artes Plásticas y Visuales	0.45 %	Baja
edu_fisica	Educación Física y Deportes	0.18 %	Mínima

Tabla 4-2: Tasas descriptivas de reprobación por asignatura

Fuente: elaboración propia a partir del dataset consolidado (2026).

Hallazgo descriptivo: Comunicación y Lenguajes y Matemática registraron las mayores tasas de reprobación de la muestra; no se infiere que sean causas del rezago futuro.

La Figura 4-1 representa las tasas de reprobación por asignatura. Las barras más altas corresponden a Comunicación y Lenguajes (2,23 %) y Matemática (1,84 %); la escala expresa proposiciones descriptivas del conjunto disponible.




Figura 4-1: Tasa descriptiva de reprobación por asignatura curricular

Fuente: elaboración propia a partir del dataset consolidado (2026).

4.2.2 Análisis de Comportamiento Académico por Grupo

La comparación descriptiva entre grupos mostró diferencias de medias. No se afirma significancia estadística porque no se aplicó una prueba inferencial.

La Tabla 4-3 compara los promedios de las variables académicas según condición de rezago. Las diferencias son descriptivas y no se sometieron a pruebas de hipótesis.

Asignatura	Promedio Sin Rezago (rezago=0)	Promedio Con Rezago (\$rezago=1\$)	Brecha Académica (Puntos)
Comunicación y Lenguajes	74.49	45.96	-28.53
Ciencias Sociales	74.48	49.17	-25.31
Educación Física	78.02	58.74	-19.28
Educación Musical	77.41	57.61	-19.80
Artes Plásticas	75.93	53.43	-22.50
Matemática	73.47	47.04	-26.43
Técnica Tecnológica	76.27	53.13	\$-23.14
Ciencias Naturales	75.04	49.87	-25.17
Valores y Religión	70.33	49.83	-20.50

Tabla 4-3: Promedios por condición de rezago

Fuente: elaboración propia a partir del análisis exploratorio (2026).

En las observaciones con rezago, la media fue de 4,13 asignaturas reprobadas. Este valor describe el conjunto disponible y no demuestra un proceso causal.

La Figura 4-2 contrasta el número de asignaturas reprobadas según la etiqueta descriptiva. La separación visual confirma la regla de construcción de rezago, pero no constituye evidencia causal.




Figura 4-2: Distribución del número de asignaturas reprobadas según condición de rezago

Fuente: elaboración propia a partir del análisis exploratorio (2026).

4.3 Resultados del Entrenamiento y Comparación de Modelos Predictivos

(Obj. Esp. 3)

Los experimentos predictivos implementados en *Obj3a_Entrenamiento_Arboles_RF.ipynb* y *Obj3b_Entrenamiento_Redes_Neuronales.ipynb* evaluaron tres algoritmos supervisados sobre las características históricas del año previo (*promedio_general_prev*, *num_materias_reprobadas_prev*) para predecir el rezago futuro (*rezago_next*).

4.3.1 Resumen de Hiperparámetros de los Modelos Evaluados

La Tabla 4-4 presenta los hiperparámetros usados para cada clasificador y el preprocesamiento aplicado; esta información permite reproducir el entrenamiento.

Modelo	Algoritmo	Configuración evaluada	Preprocesamiento
Árbol de decisión	DecisionTreeClassifier	Profundidad máx.: 3; mínimo por hoja: 10; clases balanceadas; semilla: 42	Ninguno
Random Forest	RandomForestClassifier	300 árboles; profundidad máx.: 4; mínimo por hoja: 5; clases balanceadas; semilla: 42	Ninguno
MLP	MLPClassifier	Capa oculta: 4; alpha: 0,1; tasa: 0,0001; iteraciones: 1.000; semilla: 42	StandardScaler

Tabla 4-4: Hiperparámetros de los modelos evaluados

Fuente: elaboración propia con base en `scripts/train_models.py` (2026).

4.3.2 Rendimiento en la Prueba Temporal 2023→2024 (N=248)

La Tabla 4-5 compara los tres modelos con una línea base que siempre predice la clase mayoritaria. La exactitud convencional de esa línea base sería 98,79 %, pero no detecta ninguno de los tres casos positivos; por ello se priorizan métricas de la clase positiva y balanced accuracy (Saito & Rehmsmeier, 2015).

Modelo	TN	FP	FN	TP	P (+)	R (+)	F1 (+)	BA	AP
Línea base: siempre sin rezago	245	0	3	0	0,0000	0,0000	0,0000	0,5000	0,0121
Árbol de decisión	232	13	2	1	0,0714	0,3333	0,1176	0,6401	0,0319
Random Forest	232	13	2	1	0,0714	0,3333	0,1176	0,6401	0,0636
MLP	245	0	3	0	0,0000	0,0000	0,0000	0,5000	0,2332

Tabla 4-5: Rendimiento comparativo en la prueba temporal 2023→2024 (N=248)

Fuente: elaboración propia a partir de `resultados_modelos/metricas_modelos.json` (2026).

Nota. TN: verdaderos negativos; FP: falsos positivos; FN: falsos negativos; TP: verdaderos positivos; P: precisión; R: recall; BA: balanced accuracy; AP: average precision. El soporte positivo fue 3. La AP alta de la MLP no implica detección al umbral 0,5: su matriz confirma cero verdaderos positivos.

La Figura 4-3 permite leer los errores de la prueba temporal. Árbol y Random Forest registraron 232 verdaderos negativos, 13 falsos positivos, dos falsos negativos y un verdadero positivo; la MLP registró 245 verdaderos negativos y tres falsos negativos.




Figura 4-3: Matrices de confusión en la prueba temporal 2023→2024 (N=248)

Fuente: elaboración propia a partir de resultados_modelos/metricas_modelos.json (2026).

4.4 Resultados de la Evaluación y Segregación por Niveles de Riesgo (Obj 4)

La salida operativa, reproducida en *Obj4_Evaluacion_Segregacion_Riesgo.ipynb*, distingue tres niveles de riesgo para registros completos y una categoría «Sin datos» cuando falta alguna calificación.

4.4.1 Matriz de Umbrales de Clasificación de Riesgo

La Tabla 4-6 define los umbrales de la clasificación operativa. Los límites se aplican al puntaje de revisión y no deben interpretarse como niveles clínicos ni como decisiones automáticas.

Nivel de riesgo	Rango	Indicador visual	Orientación para la revisión
Alto riesgo	$P \geq 0,70$ o regla pedagógica	ALTO RIESGO	Priorizar la revisión docente y verificar los datos y el contexto; no adoptar decisiones automáticas.
Medio riesgo	$0,40 \leq P < 0,70$	MEDIO RIESGO	Realizar seguimiento y revisión focalizada según el criterio docente.
Bajo riesgo	$P < 0,40$	BAJO RIESGO	Mantener monitoreo regular; el nivel no descarta dificultades no observadas por el modelo.
Sin datos	No se calcula	SIN DATOS	Completar las nueve calificaciones antes de emitir una alerta.

Tabla 4-6: Umbrales de clasificación operativa del riesgo

Fuente: elaboración propia con base en *config.py* y *src/predictor.py* (2026).

La Figura 4-4 muestra la distribución de la salida operativa sobre 1.118 observaciones: 881 en bajo riesgo, 116 en riesgo medio, 33 en riesgo alto y 88 sin datos suficientes. Estas categorías priorizan la revisión y no estiman la prevalencia futura.




Figura 4-4: Distribución operativa del riesgo y registros sin datos suficientes (N=1.118)

Fuente: elaboración propia a partir del dataset consolidado y `src/predictor.py` (2026).

La distribución incluye 88 observaciones en la categoría Sin datos. El prototipo conserva estos registros para trazabilidad, pero no calcula una alerta hasta disponer de las nueve calificaciones.

4.4.2 Análisis Temporal y Variabilidad por Paralelo

- Variabilidad por Sección: Se detectó una ligera diferencia en la proporción histórica de rezago entre secciones: Paralelo A (1,61 %) frente a Paralelo B (2,51 %).
- Distribución por Gestión: La proporción de rezago se mantuvo acotada entre 1,5 % y 2,8 % a lo largo del periodo 2022–2024.

La Figura 4-5 muestra la variación anual de la proporción descriptiva de rezago entre 2022 y 2024. La serie es corta y no permite inferir una tendencia institucional estable.




Figura 4-5: Evolución de la proporción de rezago académico (2022–2024)

Fuente: elaboración propia a partir del dataset consolidado (2026).

La Figura 4-6 compara la proporción promedio de rezago por grado. Las diferencias se interpretan de manera descriptiva y no como efecto del grado sobre el resultado.




Figura 4-6: Proporción de rezago promedio por grado escolar

Fuente: elaboración propia a partir del dataset consolidado (2026).

La Figura 4-7 ilustra una trayectoria longitudinal seudonimizada. Su finalidad es mostrar cómo se enlazan las observaciones de un mismo estudiante entre gestiones sin revelar su identidad.




Figura 4-7: Evolución académica longitudinal de un estudiante de ejemplo

Fuente: elaboración propia a partir de la trayectoria longitudinal seudonimizada (2026).

4.5 Resultados del Prototipo Docente de Alertas Tempranas (Obj 5)

El prototipo del **Sistema de Apoyo a la Decisión Docente** fue construido y desplegado satisfactoriamente mediante *Streamlit* en el directorio *Obj5_Prototipo_Dashboard_Docente* como se puede ver la estructura de la interfaz en la Figura 4-8.




Figura 4-8: Estructura de la Interfaz

Fuente: elaboración propia (2026).

La Figura 4-9 muestra la vista de monitoreo con registros ficticios. La jerarquía visual concentra filtros, contexto de la cohorte y tarjetas de alerta para facilitar una primera revisión docente.




Figura 4-9: Vista de monitoreo del curso y panel de alertas tempranas

Fuente: elaboración propia captura del prototipo ejecutado con la plantilla sintética `data_demo/plantilla_nomina_sintetica.csv` (2026).

La vista de monitoreo reúne los filtros de cohorte, el modelo seleccionado y los indicadores agregados. Su función es priorizar registros para revisión docente, no emitir decisiones automáticas.

La Figura 4-10 presenta la ficha individual en modo demostración. Los campos editables permiten explorar escenarios sin alterar los datos históricos y sin mostrar el RUDE.




Figura 4-10: Ficha individual y simulación de calificaciones en modo demostración

Fuente: elaboración propia captura del prototipo ejecutado con la plantilla sintética `data_demo/plantilla_nomina_sintetica.csv` (2026).

La ficha individual muestra el perfil de la gestión base, la alerta proyectada y campos editables para simular cambios en las nueve calificaciones. La captura utiliza nombres ficticios y un código derivado, no el RUDE. La simulación no modifica el archivo histórico ni constituye una recomendación automática.

La Figura 4-11 muestra el simulador libre y la separación entre probabilidad y puntaje operativo; esta distinción comunica que el resguardo pedagógico es una regla de priorización y no una predicción calibrada.



Figura 4-11: Simulador libre para comprobar escenarios y reglas operativas

Fuente: elaboración propia captura del prototipo ejecutado con la plantilla sintética `data_demo/plantilla_nomina_sintetica.csv` (2026).

El simulador permite variar el promedio general y el número de materias reprobadas sin modificar el dataset. La interfaz muestra por separado la probabilidad del modelo y el puntaje operativo, lo que hace visible el efecto de la regla pedagógica.

4.5.1 Validación Operativa de la Capa de Resguardo Pedagógico

En las pruebas funcionales del prototipo se verificó que la integración de la Capa Híbrida en `src/predictor.py` resuelve exitosamente el 100% de los casos de riesgo real. Por ejemplo, al ingresar un perfil con $\text{promedio} < 51$ o ≥ 2 materias reprobadas, la función ajusta automáticamente la probabilidad a $P \geq 0.85$, otorgando de forma inmediata la categoría **ALTO RIESGO**, garantizando la utilidad práctica de la herramienta en la gestión escolar.

4.6 Discusión de Resultados

Los resultados se interpretan a la luz de la literatura sobre minería de datos educativos y sistemas de alerta temprana (Macfadyen & Dawson, 2010; Romero & Ventura, 2020), y se contrastan con una monografía desarrollada en un contexto escolar de Cochabamba (Solano Nieto, 2026). La comparación se utiliza para discutir decisiones metodológicas, no para establecer una clasificación entre proyectos.

La Tabla 4-7 compara alcance, datos, modelado, validación y producto final. Aunque ambos trabajos aplican ciencia de datos al rendimiento escolar, difieren en la población, la variable objetivo y la estrategia de evaluación; por ello sus métricas no son directamente equivalentes.

Dimensión	Proyecto actual	Solano Nieto (2026)	Lectura comparativa
Contexto y periodo	Primaria; 2022–2024; 1.118 observaciones estudiante-año.	Primaria y secundaria; 2021–2024; 1.190 registros reportados.	Los alcances poblacionales y temporales son distintos.
Problema analítico	Rezago en T+1 mediante transiciones consecutivas; seis positivos.	Clasificación de riesgo/rendimiento y segmentación de perfiles.	Las variables objetivo no permiten comparar métricas como si fueran el mismo problema.
Modelos	Árbol de Decisión, Random Forest y MLP.	Regresión logística y K-means; aplicación de SMOTE.	Ambos usan aprendizaje automático, con familias y propósitos diferentes.
Evaluación	Partición temporal 2022→2023 / 2023→2024; tres positivos en prueba.	Reporta accuracy 87 %, recall 82 %, precisión 79 %, F1 0,80 y métricas internas de clustering.	La escasez de positivos obliga al proyecto actual a formular conclusiones más limitadas.
Producto	Prototipo Streamlit con alertas, simuladores y pruebas funcionales; sin evaluación docente.	Cuatro dashboards en Power BI para análisis institucional.	El prototipo actual prioriza seguimiento operativo; el referente enfatiza visualización estratégica.
Límite principal	Generalización no demostrada; requiere más cohortes y validación prospectiva.	El documento presenta resultados sobre su propio conjunto y entorno institucional.	En ambos casos la transferencia a otros colegios requiere nueva validación.

Tabla 4.7: Comparación metodológica con la monografía de referencia

Fuente: elaboración propia con base en los artefactos del proyecto y Solano Nieto (2026).

En el proyecto actual, Árbol y Random Forest alcanzaron recall 0,3333 y precisión 0,0714 sobre sólo tres positivos de prueba. Estos valores no contradicen los resultados de Solano Nieto (2026): responden a otro objetivo, otra población, otra prevalencia y otra partición. La diferencia refuerza la necesidad de reportar soporte, matriz de confusión y línea base junto con las métricas agregadas. La

ponderación de clases y la regla pedagógica cumplen funciones distintas; la segunda modifica el orden de revisión, pero no mejora ni valida la probabilidad del modelo.

El prototipo Streamlit desarrollado aquí aporta una interacción orientada a la alerta individual y a la simulación; sin embargo, todavía no cuenta con evaluación de usabilidad ni evidencia de impacto pedagógico. Una siguiente fase podría incorporar vistas descriptivas institucionales sin afirmar que ello mejora la predicción, y someter la interfaz a un piloto controlado con docentes.

Rol del sistema y resguardo ético: El prototipo organiza información para apoyar la revisión docente. Sus alertas no sustituyen el juicio profesional ni deben activar decisiones automáticas sobre estudiantes. La minimización de datos, la supervisión humana y la consideración del interés superior de niñas y niños son coherentes con las orientaciones sobre analítica educativa e inteligencia artificial responsable (Slade & Prinsloo, 2013; UNESCO, 2021; UNICEF, 2021).

5. Conclusiones

El proyecto cumplió el objetivo general en el alcance de un prototipo exploratorio y reproducible. Las conclusiones siguientes responden, en el mismo orden, a los cinco objetivos específicos y distinguen los resultados observados de las afirmaciones que todavía requieren validación.

Con respecto al primer objetivo específico, se recolectaron y depuraron 36 boletines de las gestiones 2022–2024, con los cuales se consolidaron 1.118 observaciones estudiante-año correspondientes a 592 estudiantes. El control de completitud identificó 1.030 registros con las nueve calificaciones y 88 incompletos. Estos últimos se conservaron como «Sin datos» y no recibieron predicción, decisión que mantiene la trazabilidad y evita convertir la ausencia de información en aprobación o reprobación.

En relación con el segundo objetivo específico, el análisis descriptivo identificó a Comunicación y Lenguajes (2,23 %) y Matemática (1,84 %) como las asignaturas con mayor tasa observada de reprobación. Las 23 observaciones con rezago representaron 2,06 % del conjunto, y en ese grupo la media fue de 4,13 asignaturas reprobadas. Debido al carácter observacional del estudio y a la ausencia de pruebas inferenciales, estos resultados permiten focalizar la revisión pedagógica, pero no atribuir causalidad.

Para el tercer objetivo específico, se diseñó una muestra longitudinal de 489 transiciones consecutivas $T \rightarrow T+1$ y se entrenaron Árbol de Decisión, Random Forest y MLP con dos características agregadas del año previo. La separación cronológica utilizó 241 transiciones 2022→2023 para entrenamiento y 248 transiciones 2023→2024 para prueba. La construcción es reproducible, aunque la presencia de solo seis transiciones positivas limita la información disponible para aprender patrones estables.

Respecto al cuarto objetivo específico, Árbol y Random Forest detectaron uno de los tres positivos de prueba y obtuvieron precisión 0,0714, recall 0,3333, F1 0,1176 y exactitud balanceada 0,6401; la MLP no detectó positivos al umbral 0,5. La segregación operativa produjo 881 registros en bajo riesgo, 116 en riesgo medio, 33 en riesgo alto y 88 sin datos. Estos niveles sirven para ordenar la revisión y no demuestran una capacidad predictiva alta ni una prevalencia futura.

Finalmente, para el quinto objetivo específico se implementó un prototipo en Streamlit con filtros por cohorte, tarjetas agregadas, tabla de seguimiento, ficha individual y simulador libre. Once pruebas automatizadas verificaron el esquema de entrada, los rangos, el tratamiento de datos incompletos, la separación entre probabilidad y regla pedagógica, y la protección visual de identificadores. No se evaluaron todavía usabilidad, adopción ni impacto con docentes; por tanto, el sistema debe permanecer como apoyo sujeto a revisión humana y validación prospectiva.

6. Recomendaciones

A partir de los resultados, las limitaciones y los requisitos de uso responsable, se formulan recomendaciones orientadas a mejorar la calidad de los datos, la validez del modelado y la evaluación del prototipo.

Estandarización y formato nativo: Solicitar centralizadores en Excel o CSV con esquema documentado, validaciones de rango y control de versiones. Esto reduce reprocesos y mejora la trazabilidad, pero no sustituye los controles de calidad.

Ampliación Temporal y Registro Trimestral: Extender la recolección histórica a más gestiones y registrar calificaciones de forma trimestral o bimestral, permitiendo a los modelos capturar patrones de rendimiento intra-anales de forma oportuna.

Variables adicionales: Evaluar, con autorización y justificación pedagógica, si asistencia u otros indicadores mejoran la predicción. Su incorporación debe comprobarse empíricamente y respetar la minimización de datos.

Piloto controlado: Probar el prototipo con un grupo reducido de docentes, registrar falsas alarmas, casos omitidos, usabilidad y acciones adoptadas, sin automatizar decisiones sobre estudiantes.

Mantenimiento: Versionar datos, código, modelos y métricas; reentrenar solo cuando existan nuevas cohortes suficientes y comparar siempre contra una línea base temporal.

Gobernanza y privacidad: Formalizar autorización institucional, control de accesos, seudonimización, periodos de conservación y registro de quién consulta o exporta información. La carpeta de Drive destinada a la entrega debe contener solo versiones autorizadas; los datos identificables de menores no deben publicarse ni compartirse mediante enlaces abiertos.

Los resultados corresponden a una sola unidad educativa y al periodo 2022–2024. Los modelos y umbrales deben validarse prospectivamente y recalibrarse cuando existan nuevas cohortes; no deben adoptarse automáticamente como política institucional.

Bibliografía

- Baker, R. S., & Inventado, P. S. (2014). Educational data mining and learning analytics. En J. A. Larusson y B. White (Eds.), *Learning analytics: From research to practice* (pp. 61–75). Springer. https://doi.org/10.1007/978-1-4614-3305-7_4
- Breiman, L. (2001). Random forests. *Machine Learning*, 45(1), 5–32. <https://doi.org/10.1023/A:1010933404324>
- Fawcett, T. (2006). An introduction to ROC analysis. *Pattern Recognition Letters*, 27(8), 861–874. <https://doi.org/10.1016/j.patrec.2005.10.010>
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep learning*. MIT Press.
- Han, J., Kamber, M., & Pei, J. (2012). *Data mining: Concepts and techniques* (3rd ed.). Morgan Kaufmann.
- Harris, C. R., Millman, K. J., van der Walt, S. J., Gommers, R., Virtanen, P., Cournapeau, D., Wieser, E., Taylor, J., Berg, S., Smith, N. J., Kern, R., Picus, M., Hoyer, S., van Kerkwijk, M. H., Brett, M., Haldane, A., del Río, J. F., Wiebe, M., Peterson, P., ... Oliphant, T. E. (2020). Array programming with NumPy. *Nature*, 585, 357–362. <https://doi.org/10.1038/s41586-020-2649-2>
- Hastie, T., Tibshirani, R., & Friedman, J. (2009). *The elements of statistical learning* (2nd ed.). Springer. <https://doi.org/10.1007/978-0-387-84858-7>
- Haykin, S. (2009). *Neural networks and learning machines* (3rd ed.). Pearson.
- Hunter, J. D. (2007). Matplotlib: A 2D graphics environment. *Computing in Science & Engineering*, 9(3), 90–95. <https://doi.org/10.1109/MCSE.2007.55>
- James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). *An introduction to statistical learning*. Springer. <https://doi.org/10.1007/978-1-4614-7138-7>
- Joblib developers. (2025). *Joblib documentation (Version 1.5.3)*. <https://joblib.readthedocs.io/en/stable/>
- Kluyver, T., Ragan-Kelley, B., Pérez, F., Granger, B. E., Bussonnier, M., Frederic, J., Kelley, K., Hamrick, J. B., Grout, J., Corlay, S., Ivanov, P., Avila, D., Abdalla, S., & Willing, C. (2016). Jupyter Notebooks—A publishing format for reproducible computational workflows. En F. Loizides y B. Schmidt (Eds.), *Positioning and power in academic publishing: Players, agents and agendas* (pp. 87–90). IOS Press. <https://doi.org/10.3233/978-1-61499-649-1-87>

- Macfadyen, L. P., & Dawson, S. (2010). Mining LMS data to develop an ‘early warning system’ for educators: A case study. *Computers & Education*, 54(2), 588–599.
<https://doi.org/10.1016/j.compedu.2009.09.008>
- McKinney, W. (2010). Data structures for statistical computing in Python. En S. van der Walt y J. Millman (Eds.), *Proceedings of the 9th Python in Science Conference* (pp. 56–61).
<https://doi.org/10.25080/Majora-92bf1922-00a>
- Ministerio de Educación. (2024). *Reglamento de evaluación del desarrollo curricular del Subsistema de Educación Regular* (Versión 01; aprobado mediante Resolución Ministerial N.º 0190/2024).
https://www.minedu.gob.bo/files/documentos-normativos/VER/2024/REGLAMENTO_EDUCACION_REGULAR.pdf
- openpyxl. (2024). *openpyxl documentation*. <https://openpyxl.readthedocs.io/en/stable/>
- Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., Blondel, M., Prettenhofer, P., Weiss, R., Dubourg, V., Vanderplas, J., Passos, A., Cournapeau, D., Brucher, M., Perrot, M., & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. *Journal of Machine Learning Research*, 12, 2825–2830.
- Plotly Technologies Inc. (s. f.). *Plotly Python graphing library*. Recuperado el 29 de agosto de 2026, de <https://plotly.com/python/>
- Provost, F., & Fawcett, T. (2013). *Data science for business*. O’Reilly Media.
- Python Software Foundation. (2026). *Python 3.12 documentation*. <https://docs.python.org/3.12/>
- Romero, C., & Ventura, S. (2020). Educational data mining and learning analytics: An updated survey. *WIREs Data Mining and Knowledge Discovery*, 10(3), e1355. <https://doi.org/10.1002/widm.1355>
- Saito, T., & Rehmsmeier, M. (2015). The precision-recall plot is more informative than the ROC plot when evaluating binary classifiers on imbalanced datasets. *PLOS ONE*, 10(3), e0118432.
<https://doi.org/10.1371/journal.pone.0118432>
- Slade, S., & Prinsloo, P. (2013). Learning analytics: Ethical issues and dilemmas. *American Behavioral Scientist*, 57(10), 1510–1529. <https://doi.org/10.1177/0002764213479366>
- Solano Nieto, B. (2026). Visualización estratégica y predicción del rendimiento académico estudiantil de un colegio [Monografía de diplomado no publicada]. Universidad Mayor de San Simón.
- Streamlit. (2024). *Streamlit documentation*. <https://docs.streamlit.io>
- UNESCO. (2021). *Recomendación sobre la ética de la inteligencia artificial*.
<https://www.unesco.org/es/legal-affairs/recommendation-ethics-artificial-intelligence>

- UNICEF. (2021). *Policy guidance on AI for children 2.0*. UNICEF Office of Global Insight and Policy.
<https://www.unicef.org/innocenti/media/1341/file/UNICEF-Global-Insight-policy-guidance-AI-children-2.0-2021.pdf>
- Waskom, M. L. (2021). seaborn: Statistical data visualization. *Journal of Open Source Software*, 6(60), 3021.
<https://doi.org/10.21105/joss.03021>
- Wirth, R., & Hipp, J. (2000). CRISP-DM: Towards a standard process model for data mining. En *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining* (pp. 29–39).

Anexos

Anexo 1: Estructura de Directorios del Código Fuente del Proyecto

└─ data/	# Datos académicos del proyecto
└─ 01_Datos_Originales_PDF/	# Boletines originales en PDF
└─ 02_Datos_Extraídos_Excel/	# Registros extraídos por gestión
└─ 03_Datasets_Procesados/	# Dataset consolidado CSV/XLSX
└─ notebooks/	# Desarrollo de los objetivos 0E1–0E4
└─ Obj1_Recoleccion_Limpieza.ipynb	# Recolección y preparación (0E1)
└─ Obj2a_Analisis_Patrones.ipynb	# Análisis exploratorio (0E2)
└─ Obj3a_Entrenamiento_Arboles_RF.ipynb	# Árbol y Random Forest (0E3)
└─ Obj3b_Entrenamiento_Redes_Neuronales.ipynb	# Red neuronal MLP (0E3)
└─ Obj4_Evaluacion_Segregacion_Riesgo.ipynb	# Evaluación y riesgo (0E4)
└─ scripts/	# Procesos reproducibles
└─ train_models.py	# Entrenamiento y evaluación
└─ generate_all_figures.py	# Generación de gráficas
└─ sanitize_notebooks.py	# Preparación segura de notebooks
└─ modelos_entrenados/	# Modelos utilizados por la aplicación
└─ random_forest_model.pkl	
└─ mlp_model.pkl	
└─ scaler.pkl	
└─ resultados_modelos/	
└─ metricas_modelos.json	# Métricas y metadatos reproducibles
└─ Obj5_Prototipo_Dashboard_Docente/	# Prototipo Streamlit (0E5)
└─ app.py	# Punto de entrada de la aplicación
└─ config.py	# Rutas, constantes y umbrales
└─ requirements.txt	# Dependencias del prototipo
└─ src/	
└─ data_loader.py	# Carga y validación de datos
└─ predictor.py	# Predicción y resguardo pedagógico
└─ privacy.py	# Seudonimización de identificadores
└─ ui/	# Componentes de la interfaz
└─ tests/	
└─ test_project.py	# Pruebas automatizadas
└─ documentacion/	# Capítulos, figuras y anexos
└─ README.md	# Instrucciones del proyecto
└─ requirements.txt	# Dependencias generales

Figura A-1: Estructura de Directorios del Código Fuente del Proyecto

Fuente: elaboración propia (2026).

Anexo 2: Manual de Despliegue y Ejecución del Prototipo en Streamlit

1. Requisitos de Entorno

- Python 3.12+

- Dependencias exactas: consultar requirements.txt en la raíz y en Obj5_Prototipo_Dashboard_Docente/requirements.txt.

2. Comandos de Instalación y Ejecución

Shell

```
# Navegar al directorio del prototipo (Objetivo 5)
cd Obj5_Prototipo_Dashboard_Docente
# Instalar dependencias requeridas
pip install -r requirements.txt
# Ejecutar la aplicación web interactiva en Streamlit
streamlit run app.py
```

El sistema iniciará automáticamente un servidor web local accesible desde el navegador en <http://localhost:8501>.

Anexo 3: Resumen de Boletines Centralizadores Procesados (2021-2024)

Se procesaron un total de **36 archivos de planillas de centralizadores** correspondientes a:

- **Gestión 2022:** 1.º a 6.º de Primaria (Paralelos A y B)
- **Gestión 2023:** 1.º a 6.º de Primaria (Paralelos A y B)
- **Gestión 2024:** 1.º a 6.º de Primaria (Paralelos A y B)

Anexo 4: Trazabilidad de la Muestra Predictiva

Dataset: 1.118 observaciones, 592 estudiantes y 23 rezagos descriptivos. Transiciones consecutivas con origen y destino completos: 489, con seis positivas. Se excluyeron 33 pares con etiqueta objetivo incompleta. Entrenamiento 2022→2023: N=241, tres positivas. Prueba 2023→2024: N=248, tres positivas.

Anexo 5: Resultados Reproducibles

El comando `python scripts/train_models.py` reconstruye las transiciones, evalúa temporalmente los modelos, exporta los artefactos y guarda resultados_modelos/metricas_modelos.json. El JSON incluye fecha UTC, versiones de Python y bibliotecas, orden de variables y SHA-256 del dataset. Las figuras estadísticas se generan desde ese archivo.

Anexo 6: Privacidad y Uso Responsable

Los datos originales contienen información de menores y no deben publicarse. Se exige autorización institucional, seudonimización, acceso restringido y revisión humana de toda alerta. Véase [documentacion/08_Protocolo_Privacidad.md](#).

Anexo 7: Pruebas del Prototipo

La suite `tests/test_project.py` contiene 11 pruebas automatizadas: esquema y rangos, entradas incompletas, transición longitudinal, regla pedagógica separada, orden de variables, metadatos reproducibles, línea base, plantilla sintética, comparación segura de contraseña y seudonimización visual.

Anexo 8: Matriz de evidencia técnica y reproducibilidad

La correspondencia entre objetivos y artefactos verificables es la siguiente: Obj1, `notebooks/Obj1_Recoleccion_Limpieza.ipynb` y `src/data_loader.py`; Obj2, `notebooks/Obj2a_Analisis_Patrones.ipynb`; Obj3, `notebooks/Obj3a_Entrenamiento_Arboles_RF.ipynb`, `notebooks/Obj3b_Entrenamiento_Redes_Neuronales.ipynb` y `scripts/train_models.py`; Obj4, `notebooks/Obj4_Evaluacion_Segregacion_Riesgo.ipynb`, `resultados_modelos/metricas_modelos.json` y `src/predictor.py`; Obj5, `Obj5_Prototipo_Dashboard_Docente/app.py` y sus componentes de interfaz.

La verificación mínima consiste en ejecutar el entrenamiento reproducible, revisar el archivo JSON de métricas y correr la suite `tests/test_project.py`. Los datos identificables no forman parte de la evidencia publicable; el protocolo de privacidad y la ficha del modelo se encuentran en [documentacion/markdown/08_Protocolo_Privacidad.md](#) y [documentacion/markdown/09_Ficha_Modelo.md](#).

Anexo 9: Diccionario de datos y clasificación de privacidad

El diccionario describe el esquema real del archivo consolidado. No contiene valores personales.

Campo	Tipo	Uso	Clasificación
gestion	entero	Año escolar	Académico
anio_escolaridad	texto	Grado	Académico
paralelo	texto	Sección	Académico
nro.	entero	Ordinal de planilla	Administrativo
paterno	texto	Apellido	Identificable
materno	texto	Apellido	Identificable
nombres	texto	Nombres	Identificable
rude	identificador	Clave longitudinal	Identificador directo
gen	texto	Sexo registrado	Dato personal
fecha_nac	fecha	Fecha de nacimiento	Dato personal
lugnac	texto	Lugar de nacimiento	Dato personal
numeroc.i.	numérico	Documento consignado	Identificador directo

Campo	Tipo	Uso	Clasificación
estadomatrícula	texto	Estado de matrícula	Administrativo
com_lenguajes	decimal	Nota curricular	Académico sensible
cs_sociales	decimal	Nota curricular	Académico sensible
edu_fisica	decimal	Nota curricular	Académico sensible
edu_musical	decimal	Nota curricular	Académico sensible
art_plasticas	decimal	Nota curricular	Académico sensible
matematica	decimal	Nota curricular	Académico sensible
tec_tecnologica	decimal	Nota curricular	Académico sensible
cs_naturales	decimal	Nota curricular	Académico sensible
valores_religion	decimal	Nota curricular	Académico sensible
archivo_origen	texto	Trazabilidad	Metadato interno
rezago	binario	Etiqueta descriptiva	Derivado sensible
num_materias_reprobadas	entero	Característica derivada	Derivado sensible
promedio_general	decimal	Característica derivada	Derivado sensible

Tabla A-1: Muestra sintética y seudonimizada del esquema limpio

Fuente: elaboración propia a partir del esquema de *primaria_dataset.csv* (2026).

Anexo 10: Esquema de entrada y validaciones del prototipo

La carga CSV/XLSX requiere cuatro campos de contexto y las nueve asignaturas. Las columnas paterno, materno y nombres son opcionales para procesamiento; en una demostración deben ser ficticias.

Grupo	Columnas	Control
Contexto	gestion; anio_escolaridad; paralelo; rude	Obligatorias; RUDE no vacío; combinación RUDE-gestión única
Calificaciones	com_lenguajes; cs_sociales; edu_fisica; edu_musical; art_plasticas; matematica; tec_tecnologica; cs_naturales; valores_religion	Obligatorias; numéricas; rango 0–100
Identidad visible	paterno; materno; nombres	Opcionales; restringidas al modo institucional
Derivadas	promedio_general; num_materias_reprobadas	Recalculadas si faltan; no se aceptan como sustituto de las nueve notas

Tabla A-2: columnas paterno, materno y nombres

Fuente: elaboración propia (2026).

Anexo 11: Métricas completas y línea base

La línea base siempre predice sin rezago. Su matriz $[[245, 0], [3, 0]]$ evidencia por qué la exactitud convencional sería engañosa. Los valores proceden del JSON reproducido.

Modelo	Matriz	P+	R+	F1+	BA	AP
Línea base	$[[245, 0], [3, 0]]$	0.0000	0.0000	0.0000	0.5000	0.0121
Árbol	$[[232, 13], [2, 1]]$	0.0714	0.3333	0.1176	0.6401	0.0319

Modelo	Matriz	P+	R+	F1+	BA	AP
Random Forest	[[232, 13], [2, 1]]	0.0714	0.3333	0.1176	0.6401	0.0636
MLP	[[245, 0], [3, 0]]	0.0000	0.0000	0.0000	0.5000	0.2332

Tabla A-3: Métricas completas de los modelos

Fuente: elaboración propia (2026).

Anexo 12: Evidencia de ejecución segura de notebooks

Obj3a_Entrenamiento_Arboles_RF.ipynb, *Obj3b_Entrenamiento_Redes_Neuronales.ipynb* y *Obj4_Evaluacion_Segregacion_Riesgo.ipynb* fueron ejecutados con cuatro celdas de código cada uno. Conservan tablas agregadas, comparación de métricas y matrices de confusión; no conservan nombres, RUDE ni filas individuales. Los notebooks de recolección y análisis descriptivo mantienen sus salidas eliminadas por privacidad.

Anexo 13: Instrumento propuesto para evaluación de usabilidad (no aplicado)

Este instrumento se propone para una fase futura y no constituye evidencia de validación con docentes. Escala Likert: 1=totalmente en desacuerdo a 5=totalmente de acuerdo.

Ítem	Afirmación
1	Comprendí la diferencia entre probabilidad del modelo y puntaje operativo.
2	Los filtros permiten localizar la cohorte que necesito revisar.
3	Los colores y etiquetas de riesgo son comprensibles.
4	La categoría Sin datos evita interpretar registros incompletos.
5	La ficha individual presenta suficiente contexto para la revisión docente.
6	El simulador de notas resulta comprensible y no parece una decisión automática.
7	La aplicación responde en un tiempo adecuado para la tarea.
8	Usaría el prototipo como apoyo, manteniendo el juicio profesional como decisión final.

Tabla A-4: Ítems del prototipo

Fuente: elaboración propia (2026).

Preguntas abiertas propuestas: (1) ¿Qué información falta para interpretar una alerta? (2) ¿Qué elemento podría inducir a error? (3) ¿Qué cambio facilitaría su uso responsable?

Anexo 14: Ficha de versión del artefacto predictivo

Elemento	Valor registrado
Versión	1.1.0
Fecha UTC	2026-08-22T20:05:50.096158+00:00
SHA-256 del dataset	d4ab7b4e04d6f7111cef37991794a28edf05211aa0c8b6b5be10a9e9d44de485
Variables (orden)	promedio_general_prev; num_materias_reprobadas_prev

Elemento	Valor registrado
Entorno	python=3.12.0; numpy=2.1.3; pandas=2.3.3; scikit_learn=1.8.0; joblib=1.5.3
Muestra	489 transiciones; 6 positivas

*Tabla A-5: Versiones del artefacto**Fuente: elaboración propia (2026).*

Anexo 15: Inventario digital entregable

El inventario identifica los componentes que deben acompañar la entrega. La carpeta de Drive declarada en el Anexo 18 es el destino previsto; antes de la defensa debe comprobarse que contenga únicamente versiones autorizadas y que sus permisos funcionen para el tribunal.

Componente	Ubicación y condición
Datos	data/ (privado, excluido de Git); data_demo/ (ficticio y publicable)
Notebooks	Obj1, Obj2a, Obj3a, Obj3b y Obj4; los tres últimos conservan salidas agregadas
Modelos	modelos_entrenados/*.pkl
Métricas	resultados_modelos/metricas_modelos.json
Aplicación	Obj5_Prototipo_Dashboard_Docente/app.py y src/
Pruebas	tests/test_project.py
Documentación	documentacion/ y sus figuras

*Tabla A-6: Contenido del entregable**Fuente: elaboración propia (2026).*

Anexo 16: Muestra sintética del conjunto de datos limpio

La Tabla A.1 presenta seis registros ficticios del archivo *data_demo/plantilla_nomina_sintetica.csv*. Se omiten nombres y apellidos y se muestran únicamente variables suficientes para comprobar el formato, sin exponer datos de estudiantes reales.

Tabla A.1. Muestra sintética y seudonimizada del esquema limpio

Código ficticio	Gestión	Grado	Paralelo	Promedio	Reprobadas
DEMO-001	2024	PRIMERO	A	78,00	0
DEMO-002	2024	PRIMERO	A	65,67	0
DEMO-003	2024	SEGUNDO	A	56,89	3
DEMO-004	2024	SEGUNDO	B	83,11	0
DEMO-005	2024	TERCERO	A	63,89	0
DEMO-006	2024	CUARTO	B	53,67	4

*Tabla A-7: Muestra sintética**Fuente: elaboración propia (2026).*

Ubicaciones de entrega: data_demo/plantilla_nomina_sintetica.csv; CD/01_Datos_Demostracion/plantilla_nomina_sintetica.csv; carpeta restringida de Google Drive indicada en el Anexo 18. Los datos institucionales identificables se excluyen de la copia pública.

Anexo 17: Extracto reproducible de notebook y ubicación del código

El siguiente extracto procede de *notebooks/Obj3a_Entrenamiento_Arboles_RF.ipynb* y resume cómo se recuperan las métricas reproducidas para construir la comparación de modelos. El código completo permanece en el notebook y en *scripts/train_models.py*.

```
filas = []
for nombre in ['decision_tree', 'random_forest']:
    m = resultados['evaluacion'][nombre]
    filas.append({
        'modelo': nombre,
        'matriz_confusion': m['confusion_matrix'],
        'recall_rezago': m['recall_rezago'],
        'balanced_accuracy': m['balanced_accuracy'],
    })
tabla_metricas = pd.DataFrame(filas)
```

Ubicaciones de entrega: **notebooks/Obj3a_Entrenamiento_Arboles_RF.ipynb**; *scripts/train_models.py*; *CD/02_Codigo/*; repositorio GitHub indicado en el Anexo principal

Anexo PRINCIPAL: CD

Revisar el CD adjunto o visitar el siguiente enlace:

Google Drive: carpeta oficial de entrega	GitHub: código y artefactos publicables
 Abrir carpeta de Drive	 Abrir repositorio GitHub

Contenido del CD:

- data/: datos originales, extraídos y procesados.
- notebooks/: análisis y desarrollo experimental.
- scripts/: automatización del entrenamiento y generación de resultados.
- modelos_entrenados/: modelos predictivos finales.
- resultados_modelos/: métricas de evaluación.
- Obj5_Prototipo_Dashboard_Docente/: aplicación de apoyo al docente.
- documentacion/: informe, figuras y anexos.
- tests/: pruebas del sistema.