



UNIVERSIDAD MAYOR DE SAN SIMON
FACULTAD DE CIENCIAS Y TECNOLOGIA
DIRECCIÓN DE POSGRADO



VISUALIZACIÓN ESTRATÉGICA Y PREDICCIÓN DEL RENDIMIENTO ACADÉMICO ESTUDIANTIL DE UN COLEGIO

**MONOGRAFÍA PRESENTADA PARA OBTENER EL CERTIFICADO DE
DIPLOMADO CIENCIA DE DATOS**

POSTULANTE : Benjamin Solano Nieto
TUTOR : Lic. Gabriel Gualberto Camacho Zapata

Cochabamba – Bolivia
2026

VISUALIZACIÓN ESTRATÉGICA Y PREDICCIÓN DEL RENDIMIENTO ACADÉMICO ESTUDIANTIL DE UN COLEGIO

Por

Benjamin Solano Nieto

El presente documento, Trabajo de Grado es presentado a la Dirección de Posgrado de la Facultad de Ciencias y Tecnología en cumplimiento parcial de los requisitos para la obtención del grado académico de Licenciatura en Ingeniería Industrial, modalidad Doble Titulación, habiendo cursado el Diplomado “Ciencia de Datos” propuesta por el Centro de Estadística Aplicada (CESA) en su tercera versión.

ASESOR/TUTOR

Lic. Camacho Zapata Gabriel Gualberto

COMITÉ DE EVALUACIÓN

Ing. M.Sc. Jazmín G. Rocabado Quiroga (Presidente)

Ing. M.Sc. Guillen Salvador Roxana (Coordinadora)

Ing. M.Sc. Julio Marcelo Torrejón Rocabado (Tribunal)



CENTRO DE ESTADÍSTICA APLICADA (CESA)

DEPARTAMENTO DE MATEMÁTICAS

FCyT - UMSS

Cochabamba, Bolivia

Aclaración

Este documento describe el trabajo realizado como parte del programa de estudios de Diplomado “Ciencia de Datos” en el centro de Estadística Aplicada CESA y la Dirección de Posgrado de la Facultad de Ciencias y Tecnología. Todos los puntos de vista y opiniones expresadas en el mismo son responsables exclusiva del autor y no representan necesariamente las de la institución.

Resumen

El rendimiento académico de los estudiantes constituye un aspecto fundamental para la toma de decisiones pedagógicas y la planificación institucional. Bajo este contexto, el presente proyecto tuvo como finalidad implementar modelos predictivos y de visualización que permitan anticipar el rendimiento estudiantil y aportar conocimiento útil para la gestión educativa, consolidando un sistema analítico defendible y aplicable en la práctica escolar.

La metodología utilizada se basó en el enfoque CRISP-DM, que contempló la recopilación y depuración de información académica, la transformación de los datos en estructuras consistentes, la implementación de modelos supervisados y no supervisados, y finalmente el diseño de dashboards interactivos en Power Bi.

En el desarrollo del proyecto se recopilaron registros académicos dispersos en múltiples archivos Excel con estructuras distintas según curso y año escolar, los cuales fueron homogenizados y depurados mediante la eliminación de columnas irrelevantes y el tratamiento de 576 valores nulos en calificaciones, logrando reducirlos en más del 95% y consolidar un conjunto único de datos de calidad; posteriormente, se aplicó el algoritmo K-Means para segmentar a los estudiantes en grupos de desempeño académico, la validación del modelo se realizó con métricas internas como Silhouette Score, Davies-Bouldin Index y Calinski-Harabasz, confirmando que la segmentación obtenida es moderada pero defendible.

Los resultados obtenidos evidenciaron la efectividad de los modelos aplicados. La regresión logística alcanzó un accuracy del 87%, con un recall del 82%, un precision del 79%, mientras que el f1-score se situó en 0.80, un ROC-AUC de 0,99 y Log-Loss de 0,022 , confirmando la calidad global del modelo. El algoritmo K-means permitió segmentar a los estudiantes en tres clústeres principales: alto desempeño (42%), desempeño medio (38%) y bajo desempeño (20%). La validación arrojó un Silhouette Score de 0.19, un índice de Davies-Bouldin de 1.70 y un valor de 231,35 en Calinski-Harabasz , esto indica una segmentación moderada de los grupos. Además, la aplicación de SMOTE mejoró el recall en un 12%, equilibrando las clases y asegurando que más estudiantes en riesgo fueran correctamente identificados. Finalmente, los dashboards interactivos en Power Bi mostraron indicadores clave como promedios de notas, tasas de asistencia y segmentaciones de riesgo académico. Se evidenció que el 20% de los estudiantes se encontraban en riesgo, mientras que el 42% mantenía un desempeño alto.

Se concluye que el proyecto contribuyó no solo con un análisis comparativo de distintos enfoques predictivos aplicados al ámbito escolar, sino también con la validación de modelos defendibles y la construcción de herramientas de visualización con potencial de ser implementadas en la gestión institucional.

Palabras Clave

Rendimiento académico, Estrategias pedagógicas, Tasas de rendimiento, Visualización estratégica, Modelos supervisados.

*A mis padres y mi hermano, por su apoyo incondicional y por acompañarme
en cada paso de mi formación académica.*

Agradecimientos

A mis padres, por su apoyo constante, por enseñarme el valor del esfuerzo y la perseverancia, y por acompañarme en cada etapa de mi formación. A mi familia, por su cariño y comprensión, que han sido un pilar fundamental en la culminación de este proyecto.

A mis amigos, por su motivación y compañía en los momentos más exigentes, brindándome ánimo y confianza para seguir adelante.

A la Universidad Mayor de San Simón y a la Facultad de Ciencias y Tecnología, por brindarme el espacio académico y las herramientas necesarias para desarrollar este trabajo. A sus docentes, por compartir sus conocimientos y orientaciones, que han enriquecido mi aprendizaje y han sido clave en la construcción de este proyecto.

Tabla de contenidos

1.	Introducción	1
1.1	Antecedentes	1
1.2	Justificación.....	4
1.3	Planteamiento del problema	4
1.4	Objetivo general.....	5
1.4.1	Objetivos específicos	5
2.	Marco teórico	6
2.1	Herramientas tecnológicas: Python y modelos supervisados y no supervisados.....	6
2.1.1	Python: limpieza, transformación y análisis de datos	6
2.1.2	Modelos de Machine Learning.....	7
2.1.3	Power BI: diseño de dashboards interactivos para instituciones educativas	9
2.2	Metodologías de validación y evaluación de modelos predictivos.....	10
2.2.1	Métricas para modelos supervisados.....	10
2.2.2	Métricas para modelos no supervisados	13
2.2.3	Importancia de la validación en educación	14
2.3	Criterios avanzados y herramientas complementarias en ciencia de datos educativos	14
2.3.1	Curva ROC y AUC en modelos supervisados.....	14
2.3.2	Matriz de confusión y análisis de errores	15
2.3.3	Visualización estratégica y rol de Power BI en la investigación aplicada	16
2.4	Ciencia de datos en la educación	16
2.4.1	Casos de uso: predicción de rendimiento, segmentación de estudiantes, detección de riesgo académico.....	16
3.	Marco metodológico	20
3.1	Área de estudio.....	20
3.2	Flujograma metodológico.....	20
3.3	Fuentes de información	21
3.4	Recopilación e identificación de registros académicos de estudiantes de la unidad educativa mediante la identificación y consolidación de fuentes de datos	22
3.4.1	Recopilación de los datos.....	22

3.4.2	Identificación del set de datos.....	22
3.5	Aplicación de técnicas de limpieza y transformación de datos con el propósito de preparar conjuntos consistentes para el desarrollo de modelos predictivos y dashboards.....	23
3.6	Desarrollo de modelos de aprendizaje supervisado (Regresión logística) y no supervisado (K-means), validando su eficacia mediante métricas de rendimiento estandarizadas.....	27
3.6.1	Modelo supervisado: Regresión Logística.....	27
3.6.2	Modelo no supervisado: K-Means	31
3.7	Diseño de un sistema de visualización estratégica que facilite la interpretación de datos para la toma de decisiones pedagógicas	33
3.7.1	Transformación de datos en Power Bi	33
3.7.2	Creación de dashboards en Power Bi.....	36
4.	Análisis de Resultados y Discusión	47
4.1	Resultados y análisis de recopilación e identificación de registros académicos de estudiantes de la unidad educativa mediante la identificación y consolidación de fuentes de datos	47
4.2	Resultado y análisis de aplicación de técnicas de limpieza y transformación de datos con el propósito de preparar conjuntos consistentes para el desarrollo de modelos predictivos y dashboards.....	48
4.3	Resultados y análisis del desarrollo de modelos de aprendizaje supervisado (Regresión logística) y no supervisado (K-means), validando su eficacia mediante métricas de rendimiento estandarizadas.....	50
4.3.1	Modelo supervisado: Regresión Logística.....	51
4.3.2	Modelo no supervisado: K-Means	55
4.4	Resultados y análisis del diseño de un sistema de visualización estratégica que facilite la interpretación de datos para la toma de decisiones pedagógicas	58
4.4.1	Dashboard general	58
4.4.2	Dashboard para nivel primaria	60
4.4.3	Dashboard para nivel secundaria.....	62
4.4.4	Dashboard estudiantil por materia.....	64
4.5	Discusión de resultados	69
5.	Conclusiones.....	73
6.	Recomendaciones	75
	Bibliografía	76
	ANEXOS	80
	Anexo 1. Recopilación de datos	80

Anexo 2. Unificación de los datos	81
Anexo 3. Tratamiento y limpieza de los datos	82
Anexo 4. Modelo Supervisado: Regresión Logística.....	83
Anexo 5. Modelo no supervisado: K-means.....	84
Anexo 6. Cuadro de la variación porcentual por materia.....	85
Anexo 7. Dashboards realizados en Power Bi.....	86
Anexo PRINCIPAL: CD	87

Lista de figuras

Figura 3-1: Ubicación en tiempo real de la Unidad Educativa	20
Figura 3-2: Flujograma metodológico CRISP-DM	21
Figura 3-3: Recopilación de datos.....	22
Figura 3-4 Conversión y unión de datos	23
Figura 3-5: Separación entre nivel primario y secundario.....	24
Figura 3-6: Gráfica de la distribución de promedio de primaria.....	25
Figura 3-7: Gráfico de barras para nivel primario.....	26
Figura 3-8: Gráfico boxplot para nivel secundario	27
Figura 3-9: Carga de datos para el modelo.....	28
Figura 3-10: Entrenamiento del modelo supervisado.....	29
Figura 3-11: Técnica SMOTE.....	29
Figura 3-12: Métricas de evaluación ROC-AUC y Log-Loss	30
Figura 3-13: Estandarización y Método K-Means	31
Figura 3-14: Entrenamiento del modelo no supervisado.....	32
Figura 3-15: Técnica Silhouette Score y Davies-Bouldin para la validación del modelo	33
Figura 3-16: Creación de la columna del nivel estudiantil.....	34
Figura 3-17: Eliminación de columnas sobrantes	35
Figura 3-18: Desnormalización de la columna de materias	36
Figura 3-19: Medida DAX para hallar el promedio general	37
Figura 3-20: Clasificación de promedios.....	38
Figura 3-21: Medida DAX para hallar la tasa de destacados	39
Figura 3-22: Dashboard general.....	39
Figura 3-23: Dashboard para nivel primario	40
Figura 3-24: Dashboard para nivel secundario	42
Figura 3-25: Dashboard. del rendimiento por materia	43
Figura 3-26: Medida DAX para hallar el promedio en función al año anterior	45
Figura 3-27: Medida DAX para hallar la Variación porcentual.....	46
Figura 4-1: Verificación de la unión de los Excels.....	47
Figura 4-2: Cambio del tipo de dato del dataset.....	49

Figura 4-3: Resultado de la Regresión Logística.....	51
Figura 4-4: Coeficientes para cada asignatura	52
Figura 4-5: Resultado de la técnica SMOTE.....	53
Figura 4-6: Resultados de las métricas ROC-AUC y Log-Loss	54
Figura 4-7: Gráfica de clusters mediante PCA.....	56
Figura 4-8: Resultado de la técnica Silhoutte Score, Davies-Bouldin y Calinski-Harabasz	57
Figura 4-9: Resultados de la tasa de rendimiento entre el año 2021-2024	59
Figura 4-10: Resultados de la tasa de rendimiento del año 2024	59
Figura 4-11: Resultado general del rendimiento del nivel primario.....	60
Figura 4-12: Resultado general del rendimiento del nivel secundario	63
Figura 4-13: Rendimiento académico por materia durante los 4 años.....	65
Figura 4-14: Rendimiento académico por materia durante el año 2022	66
Figura 4-15: Rendimiento académico por materia durante el año 2024	68
Figura 4-16: Vista de la base de datos SQL.....	70
Figura 4-17: Resultados del dashboard de los estudiantes de programación II.....	71
Figura 4-18: Resultado del dashboard de los estudiantes del colegio de Cochabamba.....	71

Lista de tablas

Tabla 4-1: Variación del rendimiento en el colegio.....	61
Tabla 4-2: Rendimiento porcentual por nivel primario y secundario.....	63
Tabla 4-3: Rendimiento porcentual por materias	67

1. Introducción

En el contexto educativo actual, el uso de herramientas de análisis de datos se ha consolidado como un recurso fundamental para comprender el rendimiento académico de los estudiantes y tomar decisiones informadas que contribuyan a mejorar la calidad educativa. Diversos autores han señalado que la ciencia de datos aplicada a la educación permite transformar grandes volúmenes de información en conocimiento estratégico, facilitando la identificación de patrones y la anticipación de riesgos académicos (Soto, 2019). En este sentido, los colegios generan cada gestión una cantidad considerable de datos, pero estos suelen estar dispersos en archivos Excel sin una estructura que permita su análisis sistemático, lo que limita su aprovechamiento pedagógico (Gómez L. , 2025).

Este proyecto surge como respuesta a dicha necesidad, proponiendo la centralización, limpieza y análisis de las calificaciones escolares de 12 cursos entre los años 2021 y 2024, con el propósito de identificar patrones de desempeño, visualizar la evaluación académica y generar predicciones que orienten a los estudiantes en su futura elección universitaria. La literatura reciente confirma que la integración de modelos predictivos en educación contribuye a mejorar la orientación vocacional y a fortalecer la equidad en los procesos formativos, ya que permite construir perfiles más precisos a partir del historial académico de los estudiantes (Sahlaoui, 2023; Carpio-Mendoza, 2024).

La decisión de trabajar con este tema responde tanto a la necesidad de generar un impacto social directo como a la aplicación práctica de metodologías modernas de ciencia de datos. Por un lado, se busca brindar a la institución educativa una herramienta que facilite el seguimiento académico y la orientación vocacional, lo cual coincide con las recomendaciones de organismos internacionales que promueven el uso de datos para apoyar la toma de decisiones pedagógicas (CEUB, 2023). Por otro lado, se pretende demostrar la aplicabilidad de herramientas como Python y Power BI en un flujo completo que abarca desde la transformación de datos hasta la visualización estratégica, siguiendo experiencias documentadas en universidades latinoamericanas que han incorporado estas tecnologías en sus procesos académicos (Zurita, 2024). En consecuencia, este proyecto no solo busca resolver un problema técnico, sino también aportar valor educativo mediante el uso inteligente de los datos, alineándose con la tendencia global de integrar la analítica educativa en la gestión escolar.

1.1 Antecedentes

La ciencia de datos se ha consolidado en la última década como herramientas decisivas para transformar la educación. Diversas universidades y centros de investigación alrededor del mundo han demostrado que el análisis masivo de información académica permite anticipar el rendimiento estudiantil, personalizar estrategias pedagógicas y optimizar la gestión institucional. Estas tecnologías, además, han impulsado la creación de visualizaciones estratégicas que facilitan la interpretación de patrones y la toma de decisiones basadas en evidencia, convirtiéndose en un recurso indispensable para docentes y directivos en contextos globales (Alfonso, 2024).

En este marco, disciplinas como el Educational Data Mining y el Learning Analytics han emergido como campos de investigación consolidados, orientados a transformar datos educativos en conocimiento útil para la toma de decisiones. Ventura (Soto, 2019) destaca que el análisis masivo de información académica permite no solo anticipar el rendimiento estudiantil, sino también personalizar estrategias pedagógicas y mejorar la gestión institucional. De esta manera complementaria, Siemens y Long (Siemens & Long, 2011) señalan que el Learning Analytics constituye una disciplina emergente que conecta la investigación en ciencia de datos con la práctica educativa, aportando herramientas para la innovación pedagógica y la mejora continua.

Este movimiento también ha tenido un impacto significativo en el ámbito latinoamericano, donde instituciones de educación superior han comenzado a integrar metodologías de ciencia de datos en sus procesos académicos. Investigaciones de la Universidad Nacional Abierta y a Distancia de Colombia (Gómez J. M., 2025) evidencian cómo el análisis de datos contribuye a identificar tendencias y vacíos en la innovación pedagógica, mientras que el Instituto Politécnico Nacional de México ha documentado la aplicación de algoritmos para construir una educación inteligente orientada a la segmentación y acompañamiento estudiantil (Camacho, 2024). Estas experiencias regionales muestran que la visualización estratégica de información académica no solo mejora la eficiencia institucional, sino que también fortalece la orientación vocacional y el diseño de políticas educativas más inclusivas.

En países como Brasil y Argentina también se han desarrollado proyectos que aplican algoritmos de clustering y modelos predictivos para segmentar estudiantes y anticipar riesgos académicos. Según Vieira (Vieira & Soares, 2018), el uso de K-means en contextos escolares brasileños permitió identificar perfiles de desempeño y diseñar intervenciones pedagógicas diferenciadas. De manera similar, investigaciones en Argentina han demostrado que la integración de modelos supervisados y no supervisados mejora la capacidad de las instituciones para detectar estudiantes en riesgo y optimizar recursos educativos (Rodríguez & García, 2019). Estas experiencias refuerzan la pertinencia de aplicar metodologías de ciencia de datos en el ámbito latinoamericano.

Es importante señalar que el desarrollo de modelos predictivos y no supervisados, como los algoritmos de regresión logística y K-Means, respectivamente, representan un avance sustancial en el análisis del rendimiento académico. Estos modelos permiten no solo anticipar situaciones de riesgo escolar, sino también identificar grupos de estudiantes con patrones similares de desempeño, lo cual resulta fundamental para diseñar intervenciones pedagógicas diferenciadas. En consecuencia, la implementación de soluciones basadas en IA y ciencia de datos en el ámbito escolar boliviano constituye una oportunidad estratégica para elevar la calidad educativa, promover la equidad y fortalecer la toma de decisiones basadas en evidencia (Carpio-Mendoza, 2024).

Además de los avances en modelos supervisados y no supervisados, la literatura internacional ha resaltado la importancia de integrar técnicas de balanceo de datos en contextos educativos. Chawla (Chawla, 2002) introdujo el método SMOTE como una estrategia eficaz para enfrentar el desbalance de clases, generando instancias sintéticas de la clase minoritaria y mejorando la capacidad de los modelos para identificar estudiantes en riesgo. Investigaciones recientes han confirmado que la aplicación de SMOTE en educación incrementa la precisión y la interpretabilidad de los modelos, lo que lo convierte en una herramienta defendible para proyectos de predicción académica.

En el caso boliviano, la incorporación, la incorporación de estas tecnologías ha comenzado a consolidarse como una alternativa para el análisis del crecimiento pedagógico en la educación superior. Mendoza jurado destaca cómo la ciencia de datos puede generar resultados respaldados por métodos científicos, orientados específicamente en el ámbito educativo. De manera complementaria, la Universidad Franz Tamayo ha documentado el uso de algoritmos de inteligencia artificial para identificar patrones de riesgo, automatizar procesos y generar visualizaciones estratégicas que apoyan tanto a docentes como a directivos en la toma de decisiones (Zurita, 2024). Estas iniciativas se articulan con los esfuerzos del Comité Ejecutivo de la Universidad Boliviana (CEUB), que ha promovido guías de orientación vocacional para vincular la educación secundaria con la superior, reforzando la necesidad de contar con herramientas tecnológicas que faciliten el análisis de datos escolares (CEUB, 2023).

La incorporación de estas metodologías también se relaciona con la necesidad de garantizar la equidad en la educación. Según el informe de la UNESCO (UNESCO, 2025), el uso de analítica educativa y ciencia de datos puede contribuir a reducir brechas de aprendizaje, ya que permite identificar a los estudiantes que requieren apoyo adicional y diseñar políticas inclusivas. De manera similar, el Banco Mundial (Mundial, 2022) ha señalado que la integración de herramientas de inteligencia artificial en la educación latinoamericana representa una oportunidad para mejorar la calidad y pertinencia de los procesos formativos, siempre que se acompañe de estrategias de capacitación docente y de infraestructura tecnología adecuada.

En Cochabamba se observa un avance concreto en la integración de la ciencia de datos en la educación. La Universidad Mayor de San Simón ha impulsado programas de posgrado en ciencia de datos y machine learning, orientados a desarrollar competencias en análisis predictivo, limpieza de datos y visualización estratégica mediante herramientas como Power Bi. Estos programas buscan formar profesionales capaces de aplicar metodologías modernas en el ámbito educativo, fortaleciendo las capacidad de las instituciones para interpretar grandes volúmenes de información y transformarlos en decisiones pedagógicas efectivas. De esta manera, la región se posiciona como un referente nacional en la integración de la ciencia de datos en la educación, promoviendo un enfoque estratégico que conecta la investigación académica con la gestión escolar y universitaria.

Finalmente, es importante subrayar la validez de los métodos predictivos y de segmentación debe ser evaluada mediante métricas reconocidas internacionalmente, como el accuracy, el recall y el f1-score en el caso de modelos supervisados, y el Silhouette Score o el índice de Davies-Bouldin en el caso de modelos no supervisados, la incorporación de estas métricas garantiza que los resultados obtenidos no sean arbitrarios, sino estadísticamente defendibles, lo que fortalece la confiabilidad del análisis en contextos educativos. La integración de ciencia de datos en la educación no solo tiene un impacto técnico, sino también cultural e institucional. Según López (López, Vásquez, & Gonzáles, 2020), la adopción de tecnologías de análisis educativo fomenta una cultura institucional basada en evidencia, en la que las decisiones pedagógicas se fundamentan en datos y no en percepciones aisladas. Esta perspectiva coincide con los planteamientos de García (García, 2021), quien afirma que el uso de dashboards interactivos y modelos predictivos fortalece la transparencia y la rendición de cuentas en las instituciones educativas, promoviendo una gestión más eficiente y orientada a resultados.

1.2 Justificación

La transformación digital en el ámbito educativo ha generado una creciente necesidad de integrar herramientas de análisis de datos que permitan comprender el rendimiento académico de los estudiantes de forma más profunda y estratégica.

El uso de datos representa una oportunidad para mejorar la toma de decisiones pedagógicas, optimizar recursos institucionales y fortalecer la orientación vocacional.

Este proyecto se justifica por tres razones fundamentales:

1. Relevancia técnica: La aplicación técnica de Python y Power Bi permite automatizar procesos de limpieza, integración y visualización de datos escolares, facilitando el análisis del rendimiento académico entre 2021 y 2024.
2. Impacto educativo: Al centralizar y analizar las calificaciones de 12 cursos, se podría identificar patrones de desempeño, detectar casos de riesgo académico y generar predicciones que orienten a los estudiantes en su futura elección universitaria.
3. Valor social: La propuesta contribuye a democratizar el acceso a herramientas de análisis educativo, promoviendo una cultura institucional basada en evidencia y apoyando la equidad en la orientación vocacional.

Según el Ministerio de Educación de Bolivia (Bolivia, 2016), el uso educativo-científico de la tecnología “tiene un valor presente para el desempeño del estudiante, y más aún, para su futuro ingreso a la universidad”, ya que fortalece la investigación, el análisis y la discusión de ideas. Esta perspectiva respalda la necesidad de implementar soluciones automatizadas que conviertan los datos escolares en conocimiento útil para docentes, directivos y estudiantes, promoviendo una cultura institucional basada en evidencia y no en percepciones aisladas.

El proyecto no solo responde a una necesidad técnica, sino también se alinea con los objetivos del sistema educativo boliviano de mejorar la calidad, la pertinencia y la eficiencia del proceso formativo mediante el uso inteligente de la información.

1.3 Planteamiento del problema

En la ciudad de Cochabamba, como en muchas otras regiones del país, los colegios privados y públicos gestionan grandes volúmenes de información académica cada gestión. Sin embargo, esta información suele almacenarse en archivos Excel dispersos, con formatos no estandarizados, sin una estructura que permita su análisis ni su integración en sistemas de apoyo a la toma de decisiones.

Esta fragmentación de los datos dificulta el seguimiento académico de los estudiantes, la identificación de patrones de rendimiento, y la generación de estrategias pedagógicas basadas en evidencia. Además, la ausencia de herramientas automatizadas para la limpieza, centralización y visualización de estos datos limita la capacidad de docentes y directivos para anticipar riesgos académicos, orientar vocacionalmente a los estudiantes y evaluar el impacto de las prácticas educativas.

Por tanto, el problema central que aborda este proyecto es: ¿Cómo diseñar un sistema automatizado que permita integrar, limpiar y analizar las calificaciones escolares, utilizando herramientas de ciencia de datos, para apoyar la toma de decisiones académicas y la orientación vocacional en un colegio de Cochabamba?

1.4 Objetivo general

Aplicar un sistema de visualización estratégica y predicción del rendimiento académico estudiantil en un colegio de Cochabamba, con el fin de apoyar la toma de decisiones pedagógicas y fortalecer la orientación vocacional.

1.4.1 Objetivos específicos

- Recopilar e identificar registros académicos de estudiantes de la unidad educativa mediante la identificación y consolidación de fuentes de datos.
- Aplicar técnicas de limpieza y transformación de datos con el propósito de preparar conjuntos consistentes para el desarrollo de modelos predictivos y dashboards.
- Desarrollar modelos de aprendizaje supervisado (Regresión logística) y no supervisado (K-means), validando su eficacia mediante métricas de rendimiento estandarizadas.
- Diseñar un sistema de visualización estratégica que facilite la interpretación de datos para la toma de decisiones pedagógicas.

2. Marco teórico

2.1 Herramientas tecnológicas: Python y modelos supervisados y no supervisados

El uso de herramientas tecnológicas en la educación ha transformado la manera en que las instituciones gestionan y analizan la información académica. En particular, lenguajes de programación como python, modelos de Machine learning y plataformas de visualización como Power Bi se han convertido en pilares fundamentales para la construcción de sistemas predictivos y dashboards interactivos. Según Wiston Corba (Forero-Corba & Negre Bennasar, 2024), el uso combinado de Python y Power BI constituye una estrategia clave para importar, transformar y visualizar datos de manera eficiente en entornos educativos. Asimismo, estudios recientes señalan que el Machine learning aplicado a la educación permite identificar patrones de aprendizaje y apoyar la toma de decisiones pedagógicas basadas en evidencia. Según Corba (2024) estas herramientas permiten no solo procesar grandes volúmenes de datos, sino también generar conocimiento útil para la mejora continua y la innovación en los procesos de enseñanza-aprendizaje.

2.1.1 Python: limpieza, transformación y análisis de datos

Python es uno de los lenguajes de programación más utilizados en el ámbito de la ciencia de datos debido a su simplicidad, versatilidad y amplia comunidad de usuarios. En el contexto educativo, Python facilita la limpieza y transformación de datos escolares, permitiendo convertir registros heterogéneos en estructuras organizadas y listas para el análisis. Según Pedregosa (Pedregosa, Varoquaux, & Gramfort, 2011), la potencia de Python radica en sus librerías especializadas, que ofrecen soluciones eficientes para tareas de manipulación, modelado y visualización de datos.

La limpieza de datos es el primer paso crítico en cualquier proyecto de análisis. Según Daniel Rodríguez (Rodríguez, 2024), los datos del mundo real suelen estar incompletos, duplicados o mal formateados, lo que puede distorsionar los resultados y generar conclusiones erróneas. Python, a través de bibliotecas como pandas, permite detectar y eliminar duplicados, imputar valores faltantes, corregir errores de formato y tratar valores atípicos mediante métodos estadísticos como la puntuación Z modificada.

Entre las librerías más relevantes se encuentra pandas, que permite manejar datos en forma de tablas (DataFrames) y realizar operaciones de filtrado, agrupamiento y transformación. Esta librería es especialmente útil para organizar registros académicos, como notas, asistencia y evaluaciones (Posgrados, 2025). Por su parte, numpy ofrece herramientas para cálculos numéricos y estadísticos, fundamentales en el análisis de tendencias y patrones de rendimiento estudiantil según Posgrados de México (2025).

La transformación incluye operaciones como la normalización, agregación, conversión de formatos y estandarización de variables. Python facilita estas tareas mediante funciones que permiten adaptar los datos a las necesidades del análisis, cómo convertir fechas, agrupar por categorías o aplicar reglas de negocio específicas. Esto es especialmente útil en entornos escolares donde los registros pueden variar entre gestiones, cursos o docentes (Posgrados, 2025).

Una vez que los datos estén limpios y estructurados, Python permite realizar análisis descriptivos, inferenciales y predictivos. Además, mediante bibliotecas como matplotlib, seaborn y plotly, es posible generar visualizaciones interactivas que revelan patrones de rendimiento, evolución académica y áreas de riesgo. Según Shona Alfonso (2024) estas visualizaciones son clave para comunicar hallazgos de forma clara y estratégica a docentes, directivos y estudiantes (Alfonso, 2024).

Asimismo, scikit-learn constituye una librería clave para implementar algoritmos de Machine Learning, como regresión logística, K-means y técnicas de balanceo de datos como SMOTE. Finalmente, librerías como matplotlib y seaborn permiten generar gráficos y visualizaciones que facilitan la interpretación de los resultados, convirtiendo datos complejos en representaciones claras y defendibles para los docentes y directivos (Alfonso, 2024).

2.1.2 Modelos de Machine Learning

En el campo de la educación, los modelos de Machine Learning han adquirido un papel protagónico al permitir analizar volúmenes de datos escolares y generar información valiosa para la toma de decisiones. Estos modelos se dividen principalmente en dos categorías: supervisados y no supervisados, cada uno con características, ventajas y aplicaciones específicas. La combinación de ambos enfoques ofrece una visión integral del rendimiento académico, ya que mientras los modelos supervisados permiten anticipar resultados concretos, los no supervisados facilitan la exploración de patrones ocultos y la segmentación de estudiantes en grupos homogéneos (Equipo Smowl, 2023).

En los modelos supervisados, la regresión logística se utiliza para clasificar a los estudiantes en categorías como “en riesgo” o “no en riesgo”, basándose en variables como notas, asistencia y participación. Esta técnica es defendible porque ofrece resultados interpretables y permite identificar factores asociados al bajo rendimiento, lo que la convierte en una herramienta ampliamente utilizada en el ámbito educativo (Forero-Corba & Negre Bennasar, 2024). Por otro lado, los modelos no supervisados, como K-means, permiten agrupar estudiantes en clústeres según patrones de desempeño, lo que facilita diseñar estrategias pedagógicas diferenciadas y segmentar perfiles académicos de manera más precisa (Soto, 2019). En consecuencia, la combinación de modelos supervisados y no supervisados aporta un enfoque integral para el análisis del rendimiento estudiantil, fortaleciendo la toma de decisiones pedagógicas basadas en evidencia.

Un desafío frecuente en la educación es el desbalance de clases, donde los estudiantes en riesgo representan una minoría. Para enfrentar este problema, se emplea la técnica SMOTE (Synthetic Minority Over-sampling Technique), que genera instancias sintéticas de la clase minoritaria y mejora la capacidad del modelo para detectar casos críticos (Chawla, 2002). La validez de estos modelos se asegura mediante métricas como accuracy, precision, recall, f1-score, Silhouette Score y el índice de Davies-Bouldin, que garantizan que los resultados sean defendibles y confiables.

2.1.2.1 Modelos supervisados

El aprendizaje supervisado se caracteriza por el uso de datos previamente etiquetados, lo que significa que el algoritmo recibe ejemplos en los que se conoce la variable de salida y aprende a predecirla en nuevos

casos. En el ámbito educativo, este enfoque resulta especialmente útil para predecir el rendimiento académico y detectar estudiantes en riesgo de fracaso escolar.

Entre las técnicas más utilizadas se encuentra la regresión logística, la cual permite estimar la probabilidad de que un estudiante pertenezca a la categoría de “riesgo académico” en función de sus calificaciones y otros indicadores. Diversos estudios han demostrado la eficacia de este modelo en la predicción del rendimiento estudiantil, destacando su capacidad para identificar factores asociados al bajo desempeño y anticipar posibles dificultades (Becerra, 2024).

Asimismo, los modelos supervisados no se limitan a la regresión logística, sino que incluyen algoritmos como árboles de decisión, random forest y redes neuronales, los cuales han sido aplicados en investigaciones educativas para mejorar la precisión de las predicciones y ofrecer diagnósticos más completos (Carpio-Mendoza, 2024). En consecuencia, el aprendizaje supervisado constituye una herramienta poderosa para la detección temprana de riesgos, la personalización de estrategias pedagógicas y la optimización de recursos institucionales.

La técnica SMOTE (Synthetic Minority Oversampling Technique), consiste en generar ejemplos sintéticos de la clase minoritaria a partir de los casos existentes. A diferencia de un simple sobremuestreo, SMOTE crea nuevas instancias interpolando características de los estudiantes en riesgo, lo que permite enriquecer la representación de esta categoría sin duplicar datos de manera mecánica (Chawla, 2002).

La aplicación de SMOTE resulta fundamental para equilibrar el conjunto de datos y evitar que el modelo se sobreajustara a la clase mayoritaria. Gracias a esta técnica, la regresión logística puede aprender patrones más representativos de los estudiantes en riesgo, aumentando la sensibilidad del modelo hacia los casos minoritarios.

2.1.2.2 Modelos no supervisados

Por otro lado, el aprendizaje no supervisado se centra en analizar datos sin etiquetas previas, buscando descubrir estructuras latentes y patrones ocultos. En el ámbito educativo, este enfoque es particularmente valioso para segmentar estudiantes en grupos de desempeño y comprender dinámicas académicas que no son evidentes a simple vista.

El algoritmo K-Means es uno de los más representativos dentro de esta categoría. Su aplicación en educación permite agrupar a los estudiantes en clusters de alto, medio y bajo rendimiento, lo cual facilita la implementación de intervenciones pedagógicas diferenciadas y la detección temprana de grupos vulnerables (Domínguez, 2021). Los clusters son un conjunto de elementos agrupados en función de su similitud, en el aprendizaje automático no supervisado, el objetivo del clustering es organizar los datos sin etiquetas previas, de manera que cada grupo refleje patrones comunes entre sus integrantes. Además, investigaciones recientes en Bolivia han demostrado que el uso de técnicas de agrupamiento contribuye a identificar indicadores de riesgo académico y a diseñar estrategias de apoyo más efectivas.

Cabe señalar que los modelos no supervisados no buscan predecir un resultado específico, sino explorar la estructura interna de los datos. Esto los convierte en herramientas exploratorias que complementan los modelos supervisados, ya que permiten descubrir perfiles académicos y patrones de comportamiento que enriquecen la comprensión del rendimiento estudiantil (Maquera, 2025).

2.1.2.3 Complementariedad de ambos enfoques

Tanto los modelos supervisados como los no supervisados cumplen funciones distintas pero complementarias. Mientras los primeros permiten anticipar situaciones de riesgo y generar predicciones concretas, los segundos ofrecen una visión exploratoria que revela la diversidad de perfiles académicos presentes en una institución (Equipo Smowl, 2023). La integración de ambos enfoques potencia la capacidad de los sistemas educativos para tomar decisiones basadas en evidencia, promover la equidad y fortalecer la calidad del aprendizaje (Carpio-Mendoza, 2024).

2.1.3 Power BI: diseño de dashboards interactivos para instituciones educativas

Power Bi permite crear narrativas visuales que ayudan a docentes y directivos a identificar patrones de desempeño, detectar anomalías y comunicar hallazgos de forma clara y accesible. Esta capacidad de síntesis visual es especialmente útil en contextos escolares, donde los datos suelen estar dispersos en planillas, formularios y sistemas administrativos. Según Contreras y Cabrera (2024), Power Bi constituye una herramienta de Business Intelligence que, aplicada en educación, fomenta la alfabetización en datos mediante gráficos interactivos y dinámicos, facilitando la comprensión de conceptos complejos y la toma de decisiones informadas (Contreras Garcia & Cabrera Lozano, 2024).

Power BI permite crear narrativas visuales que ayudan a docentes y directivos a identificar patrones de desempeño, detectar anomalías y comunicar hallazgos de forma clara y accesible. Esta capacidad de síntesis visual es especialmente útil en contextos escolares, donde los datos suelen estar dispersos en planillas, formularios y sistemas administrativos.

Entre las funcionalidades más relevantes para instituciones educativas se destacan:

- Conexión a múltiples fuentes de datos: Excel, SQL Server, formularios web, entre otros.
- Diseño de dashboards personalizados: con filtros, segmentaciones y visualizaciones adaptadas al perfil del usuario.
- Actualización automática de datos: mediante programación de cargas y sincronización en la nube.
- Seguridad y control de acceso: con niveles de permiso según roles institucionales.

La guía de EducaOpen (EducaOpen, 2024)) enfatiza que un buen dashboard educativo debe ser claro, útil y visualmente atractivo, evitando la sobrecarga de información y priorizando gráficos familiares como barras, líneas y mapas de calor. Además, recomienda estructurar los datos previamente en modelos eficientes para garantizar un rendimiento óptimo del panel.

En el marco de este proyecto, Power Bi se utiliza para diseñar dashboards interactivos que visualizan el desempeño estudiantil por curso, área y gestión, permitiendo a los usuarios explorar la información mediante filtros dinámicos, alertas y comparaciones históricas. Esta visualización estratégica no solo mejora la comprensión de los datos, sino que también promueve una cultura institucional basada en evidencia y mejora continua. Tal como señala Sainz (2022), la correcta visualización de datos en el sector educativo se ha convertido en una herramienta clave para favorecer la enseñanza y transmitir información de manera clara y concisa (Sainz, 2022). Asimismo, estudios recientes confirman que Power BI en entornos

académicos permite a las instituciones educativas monitorear indicadores de rendimiento y generar acciones de intervención efectivas para el mejoramiento continuo (Rodríguez, 2024).

2.2 Metodologías de validación y evaluación de modelos predictivos

La validación de modelos predictivos constituye un componente esencial en la investigación aplicada, ya que garantiza que los resultados obtenidos no sean arbitrarios, sino estadísticamente defendibles y confiables. En el ámbito educativo, la evaluación rigurosa de los algoritmos permite asegurar que las predicciones sobre el rendimiento académico de los estudiantes se traduzcan en decisiones pedagógicas efectivas y basadas en evidencia. Según Ventura (2020), la minería de datos educativos requiere no solo aplicar algoritmos de clasificación o segmentación, sino también verificar su desempeño mediante métricas reconocidas internacionalmente. De manera similar, Siemens y Long (Siemens & Long, 2011) sostiene que el Learning Analytics se fundamenta en la capacidad de transformar datos en conocimiento útil, lo cual exige validar los modelos para garantizar que las conclusiones sean fiables y aplicables en contextos reales.

En proyectos educativos, la validación adquiere una relevancia particular porque los errores de clasificación puede tener consecuencias directas en la vida de los estudiantes. Por ejemplo, un modelo que no logra identificar correctamente a los alumnos en riesgo puede dejar sin apoyo a quienes más lo necesitan. Por ello, la literatura enfatiza que las métricas de evaluación deben ser seleccionadas cuidadosamente, considerando tanto la precisión técnica como el impacto pedagógico (Sahlaoui, 2023). En este sentido, la validación no es un proceso meramente estadístico, sino una garantía de que los resultados del modelo contribuyen a mejorar la equidad educativa.

2.2.1 Métricas para modelos supervisados

Los modelos supervisados, como la regresión logística, requieren indicadores que midan su capacidad de clasificación y su utilidad práctica en la identificación de estudiantes en riesgo académico. Estas métricas permiten evaluar el desempeño del modelo en términos de aciertos, errores y balance entre sensibilidad y especificidad. Powers (Powers, 2021), señala que el uso de métricas como accuracy, precision, recall y f1-score es indispensable para interpretar correctamente los resultados de un modelo de clasificación, especialmente en contextos donde las clases están desbalanceadas.

En el ámbito educativo, estas métricas adquieren un valor estratégico. El accuracy ofrece una visión general del porcentaje de predicciones correctas, pero puede ser engañoso si la mayoría de los estudiantes pertenecen a una sola categoría. Por ello, se recomienda complementar esta métrica con el precision y el recall. Según Romero y Ventura (2019) la precision permite evaluar cuántos de los estudiantes identificados como “en riesgo” realmente lo están, reduciendo falsos positivos. El recall, por su parte, mide la capacidad del modelo para detectar a todos los estudiantes en riesgo, lo cual es crítico en educación, ya que bajo recall implica que algunos casos vulnerables no serán atendidos (Soto, 2019).

Finalmente, el f1-score combina precision y recall en una sola métrica, ofreciendo un balance entre ambas. En proyectos educativos, esta métrica es especialmente útil porque permite evaluar de manera integral la calidad de clasificación, asegurando que el modelo no solo sea preciso, sino también sensible a los casos críticos. De esta manera, las métricas supervisadas no solo validan el desempeño técnico del modelo, sino

que también garantizan su relevancia pedagógica, asegurando que las decisiones basadas en datos tengan un impacto positivo de los estudiantes (Powers, 2021),

2.2.1.1 Accuracy

El accuracy es una de las métricas más utilizadas en la validación de modelos supervisados, ya que mide el porcentaje de predicciones correctas respecto al total de casos evaluados. En términos simples, indica cuántas veces el modelo acertó en la clasificación de los estudiantes en comparación con la realidad observada. Según Powers (2011), el accuracy ofrece una visión general del desempeño del modelo, pero puede resultar insuficiente en contextos donde las clases están desbalanceadas, como ocurre frecuentemente en educación, donde la mayoría de los estudiantes no se encuentran en riesgo académico.

En proyectos educativos, confiar únicamente en el accuracy puede generar interpretaciones erróneas. Por ejemplo, si el 90% de los estudiantes no están en riesgo y el modelo clasifica correctamente a todos ellos, se obtendría un accuracy elevado, aunque el modelo haya fallado en identificar a los pocos estudiantes vulnerables. Este escenario demuestra que el accuracy no siempre refleja la verdadera capacidad del modelo para cumplir con el objetivo pedagógico de detectar casos críticos. Por ello, la literatura recomienda complementar esta métrica con otras como el recall y el precision, que permiten evaluar la sensibilidad y especificidad del modelo en la identificación de estudiantes en riesgo (Soto, 2019).

En consecuencia, aunque el accuracy es un punto de partida útil para evaluar modelos supervisados, su aplicación en educación debe ser interpretada con cautela. La combinación de métricas asegura una validación más completa y defendible, garantizando que los resultados no solo sean técnicamente correctos, sino también relevantes para la toma de decisiones pedagógicas.

2.2.1.2 Precision

La precision es una métrica fundamental en la validación de modelos supervisados, ya que mide la proporción de predicciones positivas correctas respecto al total de predicciones positivas realizadas por el modelo. En términos prácticos, indica cuántos de los estudiantes clasificados como “en riesgo” realmente pertenecen a esa categoría. Según David Powers (2011), la precision es especialmente relevante en contextos donde los falsos positivos pueden generar consecuencias indeseadas, como destinar recursos de apoyo a estudiantes que no lo necesitan, reduciendo la eficiencia de las intervenciones pedagógicas.

En el ámbito educativo, la precision adquiere un valor estratégico porque permite evaluar la confiabilidad del modelo en la identificación de estudiantes vulnerables. Un modelo con alta precision asegura que la mayoría de los estudiantes señalados como “en riesgo” efectivamente lo estén, lo que optimiza el uso de recursos institucionales y evita sobrecargar a los docentes con casos que no requieren atención especial. Sin embargo, un exceso de énfasis en la precision puede llevar a descuidar el recall, es decir, la capacidad de detectar a todos los estudiantes en riesgo. Por ello, la literatura recomienda analizar estas métricas en conjunto para lograr un balance adecuado (Soto, 2019).

Además, la precision se relaciona directamente con la toma de decisiones pedagógicas basadas en evidencia. En proyectos educativos, un modelo con baja precision puede generar desconfianza en los resultados y limitar su adopción por parte de las instituciones. En cambio, un modelo con alta precision fortalece la

credibilidad de las herramientas de ciencia de datos y facilita su integración en los procesos de seguimiento académico.

2.2.1.3 Recall

El recall, también denominado sensibilidad o tasa de verdaderos positivos, mide la capacidad del modelo para identificar correctamente a todos los estudiantes que realmente se encuentran en riesgo académico. En términos matemáticos, se calcula como la proporción de casos positivos detectados por el modelo respecto al total de casos positivos existentes en la realidad. Según David Powers (2011), el recall es una métrica crítica en contextos donde la omisión de casos puede tener consecuencias graves, ya que un bajo recall implica que el modelo está dejando fuera a estudiantes que requieren apoyo urgente.

En el ámbito educativo, el recall adquiere una relevancia especial porque la principal preocupación de las instituciones es no pasar por alto a los estudiantes vulnerables. Un modelo con alto recall asegura que la mayoría de los alumnos en riesgo sean detectados, lo que permite implementar estrategias de intervención temprana. Sin embargo, un recall elevado puede estar acompañado de una disminución en la precisión, generando falsos positivos (Soto, 2019).

2.2.1.4 F1-Score

El f1-score es una métrica compuesta que combina la precisión y el recall en un solo indicador, calculado como la media armónica de ambas. Su principal ventaja es que ofrece un balance entre la capacidad del modelo para identificar correctamente a los estudiantes en riesgo (recall) y la confiabilidad de esas predicciones (precision). Según David Powers (2011), el f1-score resulta especialmente útil en escenarios donde existe un desbalance de clases, ya que permite evaluar de manera integral el desempeño del modelo sin favorecer únicamente la exactitud general o la sensibilidad.

En el ámbito educativo, el f1-score se convierte en una métrica crítica porque refleja la calidad global de la clasificación de estudiantes en riesgo académico. Un modelo con alta precisión pero bajo recall puede ser confiable en los casos que detecta, pero dejar fuera a muchos estudiantes vulnerables. Por el contrario, un modelo con alto recall pero baja precisión puede identificar a la mayoría de los estudiantes en riesgo, aunque también genere falsos positivos. El f1-score equilibra estas dos dimensiones, ofreciendo una visión más completa del desempeño del modelo y asegurando que las decisiones pedagógicas se basen en resultados confiables y útiles (Soto, 2019).

2.2.1.5 Log-Loss (Logarithmic Loss o Cross-Entropy Loss)

El Log-Loss, también conocido como pérdida logística o entropía cruzada, mide la calidad de las probabilidades predichas por un modelo de clasificación. A diferencia de métricas como la accuracy, que únicamente consideran si la predicción es correcta o incorrecta, el Log-Loss penaliza con mayor severidad aquellas predicciones erróneas realizadas con alta confianza. En este sentido, un valor cercano a 0 indica un modelo bien calibrado, mientras que valores altos reflejan incertidumbre o mala estimación de las probabilidades (Cox, 1998).

En proyectos educativos, esta métrica adquiere relevancia porque no solo interesa clasificar correctamente a los estudiantes, sino también asignar probabilidades confiables de riesgo académico. Por ejemplo, si un estudiante presenta una probabilidad del 80% de estar en riesgo, el Log-Loss asegura que el modelo no

solo lo clasifique adecuadamente, sino que también refleje con precisión el nivel de confianza en esa predicción (Terven & Cordova-Esparza, 2023). Esto permite a los docentes priorizar intervenciones según el grado de riesgo estimado, fortaleciendo la utilidad práctica del modelo en la gestión pedagógica.

2.2.2 Métricas para modelos no supervisados

En los modelos no supervisados, como el algoritmo K-means, la validación se centra en evaluar la calidad de los clústeres formados. A diferencia de los modelos supervisados, donde existen etiquetas conocidas para comparar, en los no supervisados la evaluación se realiza mediante métricas que analizan la cohesión interna de los grupos y la separación entre ellos. Estas métricas permiten determinar si los clústeres creados representan patrones significativos en los datos académicos y si pueden ser utilizados para diseñar estrategias pedagógicas diferenciadas. Según Rousseeuw (Rousseeuw, 1987), la validez de un modelo de clustering depende de la capacidad de agrupar individuos similares y separar adecuadamente aquellos con características distintas.

En el ámbito educativo, estas métricas son esenciales porque garantizan que la segmentación de estudiantes no sea arbitraria, sino que refleje diferencias reales en el rendimiento académico. Por ejemplo, un clúster bien definido puede representar a estudiantes con alto desempeño constante, mientras que otro puede agrupar a aquellos con dificultades recurrentes. Validar la calidad de estos clústeres asegura que las instituciones puedan diseñar intervenciones específicas para cada grupo, optimizando recursos y mejorando la equidad en el aprendizaje (Davies & Bouldin, 1979).

2.2.2.1 Silhouette Score

El Silhouette Score es una métrica propuesta por Rousseeuw (Rousseeuw, 1987) que evalúa simultáneamente la cohesión interna de los clústeres y la separación entre ellos. Se calcula comparando la distancia promedio de cada punto con los elementos de su propio clúster y con los elementos del clúster más cercano. Los valores oscilan entre -1 y 1: un valor cercano a 1 indica que los clústeres están bien definidos, mientras que valores cercanos a 0 sugieren solapamiento entre grupos y valores negativos indican una clasificación incorrecta.

En proyectos educativos, el Silhouette Score permite verificar si los grupos de estudiantes formados por el algoritmo K-means reflejan diferencias reales en el rendimiento académico. Por ejemplo, un valor alto puede confirmar que los estudiantes agrupados en un clúster comparten características similares de desempeño, lo que facilita diseñar estrategias pedagógicas específicas. Por el contrario, un valor bajo o negativo indicaría que los clústeres no son representativos, lo que obliga a revisar el número de grupos o la metodología utilizada. De esta manera, el Silhouette Score se convierte en una herramienta defendible para validar la segmentación de perfiles estudiantiles.

2.2.2.2 Davies-Bouldin Index

El índice de Davies-Bouldin, propuesto en 1979, mide la similitud promedio entre clústeres, considerando tanto la dispersión interna de cada grupo como la distancia entre ellos. A diferencia del Silhouette Score, esta métrica se centra en evaluar la separación relativa entre clústeres. Un valor bajo indica que los grupos están bien separados y que la segmentación es adecuada, mientras que valores altos sugieren que los clústeres se solapan y no representan diferencias significativas.

En el contexto educativo, el Davies-Bouldin Index es útil para validar la segmentación de estudiantes en perfiles de rendimiento. Por ejemplo, si los clústeres que representan estudiantes de alto, medio y bajo desempeño presentan un índice bajo, se puede concluir que la clasificación es defendible y que los grupos reflejan diferencias reales. Según Davies-Bouldin (1979), un índice elevado señalaría que los clústeres no están claramente diferenciados, lo que podría limitar la utilidad del modelo para diseñar intervenciones pedagógicas. Así, esta métrica asegura que la segmentación de estudiantes sea confiable y aplicable en la práctica educativa (Davies & Bouldin, 1979).

2.2.2.3 Calinski-Harabasz Index

El Calinski-Harabasz Index, también conocido como Variance Ratio Criterion, evalúa la calidad de los clústeres midiendo la relación entre la dispersión interna de los grupos y la separación entre ellos. Valores más altos indican una mejor segmentación, ya que reflejan clústeres compactos y bien diferenciados (Calinski & Harabasz, 1989).

2.2.3 Importancia de la validación en educación

La validación de modelos predictivos en el ámbito educativo no solo tiene un valor técnico, sino también un impacto directo en la calidad de las decisiones pedagógicas. Un modelo que no ha sido correctamente validado puede generar resultados engañosos, lo que a su vez afecta la planificación institucional y la asignación de recursos. Según Romero y Ventura (2020), la minería de datos educativos debe estar acompañada de procesos de evaluación rigurosos que aseguren la fiabilidad de los hallazgos, ya que las instituciones educativas dependen de estos resultados para diseñar estrategias de intervención.

En este sentido, la validación se convierte en un mecanismo de garantía para la equidad educativa. La UNESCO (2021) enfatiza que las herramientas de analítica educativa deben contribuir a reducir brechas de aprendizaje y promover la inclusión, lo cual solo es posible si los modelos predictivos son defendibles y confiables. Un modelo con baja validez puede perpetuar desigualdades al dejar sin apoyo a estudiantes vulnerables, mientras que un modelo validado correctamente asegura que las intervenciones lleguen a quienes más lo necesitan. De esta manera, la validación se vincula directamente con la justicia social y la responsabilidad institucional.

Además, la validación fortalece la credibilidad de las herramientas tecnológicas ante los docentes y directivos. El Banco Mundial (Mundial, 2022) señala que la adopción de modelos de inteligencia artificial en educación requiere confianza en los resultados, lo cual se logra mediante la aplicación de métricas reconocidas internacionalmente. En proyectos educativos, esta confianza es esencial para que las instituciones integren los modelos predictivos en sus procesos de gestión y seguimiento académico. Por ello, la validación no debe ser vista como un paso opcional, sino como un componente indispensable que asegura la utilidad práctica y el impacto positivo de la ciencia de datos en la educación.

2.3 Criterios avanzados y herramientas complementarias en ciencia de datos educativos

2.3.1 Curva ROC y AUC en modelos supervisados

La evaluación de modelos supervisados en educación requiere métricas que permitan analizar no solo la precisión global, sino también la capacidad del algoritmo para distinguir entre estudiantes en riesgo y

aquellos con buen desempeño. En este sentido, la Curva ROC (Receiver Operating Characteristic) y el Área Bajo la Curva (AUC) se han consolidado como herramientas fundamentales para validar modelos de clasificación binaria. La curva ROC representa gráficamente la relación entre la tasa de verdaderos positivos (recall) y la tasa de falsos positivos en diferentes umbrales de decisión, mientras que el AUC resume en un solo valor la calidad del modelo para discriminar entre clases (Developers, 2025).

El principal aporte de la curva ROC es que permite evaluar el rendimiento del modelo en todos los posibles umbrales de clasificación, ofreciendo una visión más completa que métricas como el accuracy, que dependen de un único umbral. Un modelo ideal se caracteriza por una curva ROC cercana al vértice superior izquierdo del gráfico, lo que indica alta sensibilidad y baja tasa de falsos positivos. Por su parte, el AUC proporciona un valor entre 0 y 1: cuanto más cercano a 1, mayor es la capacidad del modelo para distinguir correctamente entre estudiantes en riesgo y no en riesgo. Valores de AUC superiores a 0.80 suelen considerarse indicadores de un modelo robusto y defendible en contextos educativos (EducaOpen, 2024).

En proyectos educativos, el uso de ROC y AUC resulta especialmente relevante porque permite comparar distintos modelos supervisados bajo un mismo criterio. Por ejemplo, si la regresión logística alcanza un AUC de 0.87 frente a otro modelo con un AUC de 0.75, se puede concluir que el primero ofrece una mejor capacidad discriminativa. Además, estas métricas ayudan a seleccionar el umbral de clasificación más adecuado, equilibrando la detección de estudiantes en riesgo con la reducción de falsos positivos. De esta manera, la curva ROC y el AUC no solo validan el desempeño técnico del modelo, sino que también aseguran su utilidad práctica en la toma de decisiones pedagógicas (Equipo Smowl, 2023).

2.3.2 Matriz de confusión y análisis de errores

La matriz de confusión es una herramienta fundamental para evaluar el desempeño de modelos supervisados en clasificación binaria y multiclase. Se trata de una representación tabular que compara las predicciones del modelo con los valores reales, organizando los resultados en cuatro categorías: Verdaderos Positivos (VP), Falsos Positivos (FP), Verdaderos Negativos (VN) y Falsos Negativos (FN). Esta estructura permite identificar no solo el nivel de acierto global, sino también los tipos de errores cometidos por el modelo, lo cual es crítico en contextos educativos donde las consecuencias de clasificar incorrectamente a un estudiante pueden ser significativas (EducaOpen, 2024).

El principal aporte de la matriz de confusión es que ofrece una visión detallada del rendimiento del modelo más allá de métricas agregadas como el accuracy. Por ejemplo, un modelo puede mostrar un alto nivel de exactitud general, pero si presenta un número elevado de falsos negativos, estaría dejando sin identificar a estudiantes en riesgo académico. En cambio, un exceso de falsos positivos podría generar intervenciones innecesarias, sobrecargando a los docentes con casos que no requieren atención especial. Por ello, el análisis de la matriz de confusión permite equilibrar la sensibilidad (recall) y la confiabilidad (precision) del modelo, asegurando que las decisiones pedagógicas se basen en resultados defendibles (Developers, 2025).

En proyectos educativos, la matriz de confusión se convierte en una herramienta estratégica para validar modelos de predicción de riesgo académico. Al analizar los errores, se pueden ajustar los umbrales de clasificación o aplicar técnicas de balanceo como SMOTE, mejorando la detección de estudiantes vulnerables. Además, la matriz facilita la comunicación de resultados a los directivos y docentes, ya que

presenta la información en un formato claro y comprensible. De esta manera, la matriz de confusión no solo valida el desempeño técnico del modelo, sino que también fortalece su utilidad práctica en la gestión escolar (FasterCapital, 2025).

2.3.3 Visualización estratégica y rol de Power BI en la investigación aplicada

La visualización de datos constituye un componente esencial en proyectos educativos, ya que permite transformar resultados complejos en representaciones claras y accesibles para los distintos actores institucionales. En este sentido, Power BI se ha consolidado como una herramienta estratégica para el diseño de dashboards interactivos, facilitando la interpretación de indicadores académicos y la toma de decisiones pedagógicas basadas en evidencia (Developers, 2025).

La principal ventaja de Power BI frente a reportes estáticos es su capacidad de interactividad. Los usuarios pueden explorar los datos mediante filtros, segmentaciones y visualizaciones dinámicas, lo que convierte a los dashboards en instrumentos flexibles y adaptables a las necesidades de cada institución. En el ámbito educativo, esta interactividad permite identificar tendencias de rendimiento, comparar grupos de estudiantes y evaluar el impacto de las intervenciones pedagógicas en tiempo real (Soto, 2019).

2.3.3.1 Lenguaje DAX y creación de medidas calculadas

Un componente clave de Power BI es el lenguaje DAX (Data Analysis Expressions), que posibilita la creación de medidas calculadas y segmentaciones dinámicas. DAX permite realizar operaciones como calcular promedios ponderados de notas, tasas de asistencia y métricas de riesgo académico, adaptándose al contexto específico de cada institución. Su capacidad para manejar filtros y relaciones entre tablas asegura que los dashboards reflejen información precisa y contextualizada (EducaOpen, 2024).

En proyectos educativos, el uso de DAX ha demostrado ser fundamental para convertir datos crudos en indicadores defendibles. Por ejemplo, la creación de medidas que calculan el porcentaje de estudiantes en riesgo por curso o área de conocimiento facilita la identificación de patrones críticos y fortalece la utilidad práctica de los dashboards.

2.3.3.2 Impacto de la visualización en la gestión escolar

La visualización estratégica no solo facilita la comprensión de los datos, sino que también promueve una cultura institucional basada en evidencia. Los dashboards diseñados en Power BI permiten a los directivos y docentes acceder a información clara y confiable, reduciendo la dependencia de reportes manuales y mejorando la eficiencia en la gestión escolar.

Además, la capacidad de segmentar los datos por género, curso o área de conocimiento ofrece una visión más detallada de las dificultades académicas. En el caso analizado, se evidenció que las mayores brechas de rendimiento se concentraban en matemáticas y ciencias naturales, lo que orienta la planificación de intervenciones específicas. De esta manera, Power BI se consolida como un recurso defendible y confiable para la toma de decisiones pedagógicas (UNESCO, 2025).

2.4 Ciencia de datos en la educación

2.4.1 Casos de uso: predicción de rendimiento, segmentación de estudiantes, detección de riesgo académico

La aplicación de la ciencia de datos en contextos educativos ha permitido desarrollar soluciones innovadoras que transforman la forma que se analiza, interpreta y gestiona la información académica. Este sentido, los casos de uso más relevantes se vinculan con la predicción del rendimiento estudiantil, la segmentación de perfiles y la detección temprana de riesgos académicos, los cuales constituyen herramientas estratégicas para la mejora continua de los procesos de enseñanza-aprendizaje.

En primer lugar, la predicción del rendimiento estudiantil se ha convertido en un recurso fundamental para anticipar resultados y diseñar intervenciones pedagógicas oportunas. A través de modelos estadísticos y algoritmos de aprendizaje automático, es posible identificar patrones de desempeño y estimar la probabilidad de éxito o dificultad en determinadas asignaturas. Según Del Carpio-Mendoza (2024), los modelos de Machine learning aplicados a la educación permiten reconocer factores de riesgo y proyectar el rendimiento académico con alta precisión, lo que facilita la implementación de estrategias de apoyo personalizadas y la planificación curricular basada en evidencia (Carpio-Mendoza, 2024).

En segundo lugar, la segmentación de estudiantes constituye otra aplicación relevante de la ciencia de datos en educación, pues facilita la identificación de perfiles diferenciados dentro de la población escolar. Mediante técnicas de minería de datos y análisis de clústeres, se pueden agrupar estudiantes según características académicas, socioemocionales o contextuales, lo que posibilita diseñar estrategias pedagógicas más inclusivas y adaptadas a la diversidad. De acuerdo con Guffante y Logroño (2025), el uso de técnicas de clustering permite identificar perfiles representativos y diseñar estrategias pedagógicas más inclusivas y adaptadas a la diversidad, favoreciendo la personalización del aprendizaje y promoviendo la equidad educativa (Guffante Salazar & Logroño Naranjo, 2025).

Finalmente, la detección temprana de riesgos académicos se presenta como un mecanismo esencial para garantizar la permanencia el éxito escolar. A través del análisis de indicadores como la asistencia, la participación en clase, el rendimiento en evaluaciones y las interacciones en plataformas digitales, es posible identificar señales de alerta que anticipen situaciones de deserción, bajo rendimiento o dificultades socioemocionales. Según Vaca Escobar (2025), las analíticas del aprendizaje permiten construir sistemas de alerta temprana que orientan la toma de decisiones y posibilitan intervenciones personalizadas, evitando que los problemas se agraven y asegurando un seguimiento integral del estudiante (Vaca Escobar, 2025).

2.4.1.1 Predicción de rendimiento académico

La predicción del rendimiento académico constituye uno de los casos de uso más relevantes de la ciencia de datos aplicada en la educación, ya que permite anticipar el desempeño futuro de los estudiantes, y en consecuencia, diseñar estrategias pedagógicas más eficaces. Mediante algoritmos de aprendizaje automático como los árboles de decisión, las redes neuronales y las máquinas de soporte vectorial, es posible analizar grandes volúmenes de información y detectar patrones que resultan invisibles a la observación tradicional. De este modo, la predicción se convierte en un recurso estratégico que no solo describe la situación actual, sino que también proyecta escenarios futuros con un alto grado de precisión.

En efecto, estos modelos predictivos se nutren de múltiples variables, entre las que se incluyen las calificaciones previas, los hábitos de estudio, la participación en clase, la asistencia y hasta las interacciones en plataformas digitales. La integración de estos datos en sistemas de análisis avanzados permite construir perfiles de desempeño que facilitan la identificación de estudiantes con altas probabilidades de éxito, así

como de aquellos que presentan riesgo de fracaso académico. Tal como señala Ventura Soto (Soto, 2019), la capacidad de los algoritmos para reconocer patrones de éxito o dificultad constituye una herramienta invaluable para la intervención pedagógica temprana, pues posibilita actuar antes de que los resultados negativos se materialicen.

Asimismo, la predicción del rendimiento académico no debe entenderse únicamente como un ejercicio técnico, sino como un proceso pedagógico que fortalece la equidad y la personalización del aprendizaje. Cuando los docentes cuentan con información anticipada sobre el desempeño de sus estudiantes, pueden ajustar sus estrategias didácticas, ofrecer apoyos diferenciados y diseñar actividades que respondan a las necesidades específicas de cada grupo. Según Ventura Soto (2019), los directivos pueden utilizar estos modelos para planificar recursos, establecer políticas de acompañamiento y garantizar que las acciones institucionales se orienten hacia la mejora continua.

Por otra parte, la utilidad de la predicción se incrementa cuando se combina con sistemas de visualización estratégica que permiten representar los resultados de manera clara y accesible. Los dashboards educativos, al integrar modelos predictivos, ofrecen una visión dinámica del rendimiento estudiantil y facilitan la toma de decisiones en tiempo real. Tal como señala Ventura Soto (2019), la ciencia de datos se convierte en un aliado indispensable para transformar la información en conocimiento accionable, promoviendo una cultura institucional basada en evidencia y en la anticipación de escenarios.

2.4.1.2 Segmentación de estudiantes

La segmentación de estudiantes constituye una de las aplicaciones más relevantes de la ciencia de datos en el ámbito educativo, ya que permite agrupar a los alumnos en función de características comunes y, en consecuencia, diseñar estrategias pedagógicas más ajustadas a sus necesidades. En este sentido, la segmentación no se limita a una clasificación estática, sino que se concibe como un proceso dinámico que integra variables académicas, socioemocionales y de interacción digital, generando perfiles que reflejan la diversidad de la población escolar. De esta manera, se favorece la personalización de los contenidos, la adaptación de las metodologías de enseñanza y la conformación de grupos colaborativos más efectivos, lo cual repercute directamente en la calidad del aprendizaje.

En efecto, los criterios de segmentación pueden incluir estilos de aprendizaje, niveles de desempeño, motivación, hábitos de estudio, participación en clase y trazas digitales derivadas del uso de plataformas educativas. El análisis de estas variables mediante técnicas de minería de datos y algoritmos de agrupación, como k-means, DBSCAN o k-prototypes, permite identificar patrones de comportamiento y construir perfiles dinámicos que enriquecen la experiencia formativa. Según Ventura (Soto, 2019), el análisis de datos de interacción constituye un recurso fundamental para comprender cómo los estudiantes se relacionan con los contenidos y con sus pares, lo que posibilita diseñar entornos de aprendizaje más inclusivo y participativos.

Por otra parte, la segmentación no solo tiene implicaciones pedagógicas, sino también institucionales. Al contar con perfiles claros de los estudiantes, las instituciones educativas pueden optimizar la asignación de recursos, focalizar programas de apoyo y orientar políticas de retención escolar. Según Ventura (2019), la segmentación se convierte en una herramienta estratégica que contribuye a la sostenibilidad de los procesos

educativos, ya que permite anticipar necesidades y responder de manera proactiva a los desafíos que plantea la diversidad estudiantil.

2.4.1.3 Detección de riesgo académico

La detección de riesgo académico se ha consolidado como una de las contribuciones más significativas de la ciencia de datos en el ámbito educativo, ya que permite identificar de manera temprana a los estudiantes que podrían enfrentar dificultades en su trayectoria escolar. Este enfoque se fundamenta en el análisis de múltiples variables, entre las que destacan el ausentismo reiterado, el bajo rendimiento sostenido, la escasa participación en actividades académicas y la retroalimentación negativa recibida de análisis predictivo, se generan alertas tempranas que facilitan la intervención preventiva por parte de docentes, tutores y equipos de orientación, evitando que los problemas se profundicen y afecten la continuidad del proceso formativo.

La utilidad de estas herramientas radica en que transforman la gestión educativa de un modelo reactivo a uno proactivo. En lugar de esperar a que los estudiantes acumulen fracasos o lleguen al límite de la deserción, los sistemas de alerta temprana permiten actuar con antelación, ofreciendo acompañamiento académico, apoyo socioemocional y estrategias de motivación personalizadas. Tal como señala Ventura Soto (2019), la detección de riesgo académico no solo contribuye a mejorar los índices de permanencia escolar, sino que también fortalece la equidad, al brindar oportunidades de intervención a quienes más lo necesitan.

La aplicación de la ciencia de datos en este ámbito debe realizarse con responsabilidad ética. Tal como advierte Ventura (Soto, 2019), la detección de riesgo no debe convertirse en un mecanismo de etiquetado que estigmatice a los estudiantes, sino en una herramienta de acompañamiento que promueve su mejora continua. En este sentido, la información obtenida debe ser utilizada para orientar procesos de apoyo y no para limitar las expectativas sobre el desempeño futuro de los alumnos. La transparencia en el manejo de los datos, la protección de la privacidad y la comunicación responsable de los resultados constituyen condiciones indispensables para garantizar la legitimidad de estos sistemas.

Además, la detección temprana de riesgo académico representa un avance significativo en la gestión educativa contemporánea. Al identificar de manera anticipada las señales de alerta y al promover intervenciones oportunas, se contribuye a garantizar la permanencia escolar, mejorar los resultados de aprendizaje y consolidar una cultura institucional basada en la prevención y el apoyo integral. De este modo, la ciencia de datos se convierte en un aliado estratégico para transformar la información en acciones pedagógicas que favorezcan la inclusión, la equidad y el éxito académico de todos los estudiantes.

3. Marco metodológico

3.1 Área de estudio

El área de estudio se centra en el ámbito de la educación primaria y secundaria del departamento de Cochabamba, específicamente en el municipio de Quillacollo.



Figura 3-1: Ubicación en tiempo real de la Unidad Educativa

Fuente: Captura de pantalla dentro de la aplicación Google Maps, 2026.

La institución se encuentra en el municipio de Quillacollo, ubicado en la Av. Blanco Galindo, km 11 a más o menos 12 cuadras al norte (Ver Figura 3-1).

El colegio fue fundado el año 2001, por el Dr. Kee Jea Lee, con el propósito de brindar una formación integral a niños y jóvenes del municipio de Quillacollo. El área de funcionamiento del colegio es de lunes a viernes, de 8:00 am a 4:00 pm, también pasan un deporte que los estudiantes escogen los días sábados, permitiendo una jornada completa que combina formación académica, actividades extracurriculares y espacios de orientación.

3.2 Flujograma metodológico

Para el desarrollo de la presente investigación se adoptó la metodología CRISP-DM (Cross Industry Standard for Data Mining), ampliamente utilizada en proyectos de ciencia de datos, análisis predictivo y modelado estadístico, debido a su carácter estructurado y flexible. Esta metodología permite organizar de manera sistemática el proceso de implementación del modelo predictivo para el rendimiento académico de la unidad educativa ubicada en Cochabamba.




Figura 3-2: Flujograma metodológico CRISP-DM

Fuente: Elaboración propia, 2026.

La metodología CRISP-DM se utilizó como marco de referencia, pero fue adaptada a las necesidades específicas del proyecto, tal como se refleja en el flujograma metodológico (Figura 3-2). El proceso inició con la recopilación e identificación de los registros académicos de los estudiantes de la unidad educativa, mediante la identificación y consolidación de fuentes de datos. Posteriormente, se aplicaron técnicas de limpieza y transformación de datos con el propósito de preparar conjuntos consistentes para el desarrollo de modelos predictivos y dashboards. En la siguiente etapa se procedió a la implementación y validación de modelos supervisados y no supervisados, específicamente regresión logística y K-Means, verificando su desempeño mediante métricas de evaluación como Accuracy, ROC–AUC, Log-Loss, Silhouette Score, Davies-Bouldin Index y Calinski–Harabasz Index. En caso de que los resultados no cumplieran con los criterios establecidos, el proceso contempló un retorno a la fase de modelado para realizar ajustes. Finalmente, cuando los modelos alcanzaron los niveles de validez requeridos, se diseñó un modelo de visualización estratégica que facilita la interpretación de datos académicos de manera clara y accesible, a través de dashboards interactivos orientados a apoyar la toma de decisiones pedagógicas.

3.3 Fuentes de información

La fuente de información utilizada en este proyecto es de carácter secundario, ya que se basa en registros previamente recolectados en formato Excel por la unidad educativa. Estos datos incluyen calificaciones

por materia, niveles académicos, años escolares y segmentación por cursos tal como se detalla en el **Anexo 1**.

3.4 Recopilación e identificación de registros académicos de estudiantes de la unidad educativa mediante la identificación y consolidación de fuentes de datos

3.4.1 Recopilación de los datos

Para el desarrollo del proyecto se trabajó con cuatro archivos Excel institucionales, correspondientes a los años escolares 2021, 2022, 2023 y 2024. Cada archivo contenía la información académica de los estudiantes, incluyendo nombres, cursos, materias y calificaciones por trimestre. Con el fin de facilitar el procesamiento y análisis, estos archivos fueron transformados a formato CSV como se muestra en el **Anexo 1**, lo que permitió consolidar un dataset único y consistente para las siguientes etapas del modelado y la construcción de dashboards.




Figura 3-3: Recopilación de datos
Fuente: Datos recopilados pro la Unidad Educativa, 2026.

3.4.2 Identificación del set de datos

En el proceso de identificación se analizaron los archivos académicos en formato Excel con el fin de determinar qué variables eran relevantes para el modelado y cuáles deberían descartarse. Se identificaron como variables principales las siguientes que están mostrados en el **Anexo 2**:

- Datos de estudiantes: nombres y cursos, necesarios para segmentar la información por nivel y grupo.
- Calificaciones por materia y trimestre: constituyen la base del análisis de rendimiento académico y permiten detectar estudiantes en riesgo.
- Año escolar (2021-2024): permite evaluar la evolución del rendimiento en el tiempo y detectar variaciones entre cohortes.

La identificación de estas variables se realizó con el propósito de construir un sistema analítico capaz de:

- Detectar estudiantes en riesgo académico.
- Identificar materias con bajo rendimiento colectivo.
- Comparar el desempeño entre cursos y años.

- Generar alertas pedagógicas para la toma de decisiones.

3.5 Aplicación de técnicas de limpieza y transformación de datos con el propósito de preparar conjuntos consistentes para el desarrollo de modelos predictivos y dashboards

Durante el proceso de limpieza y tratamiento de datos se trabajó en el entorno de desarrollo Visual Studio Code (VSCode), utilizando scripts en Python para transformar, consolidar y preparar la información académica proveniente de la unidad educativa. El primer paso consistió en convertir los archivos Excel que se encontraban en formato .xls (una versión antigua de Excel) a archivos .csv, con el objetivo de estandarizar el formato y facilitar su manipulación.

Una vez convertidos, se procedió a organizar los archivos por año escolar, agrupando todos los cursos correspondientes a cada año en un solo archivo anual. Esto permitió reducir la cantidad de archivos individuales y tener una estructura más clara y manejable. Al finalizar esta etapa, se contaba con cuatro archivos .csv, cada uno representando los datos académicos de los años 2021, 2022, 2023 y 2024.

Con los archivos anuales listos, se desarrolló un script en VSCode para realizar la unión de los cuatro archivos en uno solo. Este script se encargó de leer cada archivo .csv, identificar su ruta y concatenarlos en un único archivo denominado notas_unidas.csv. Esta consolidación fue clave para poder trabajar con una base de datos completa que abarcara todos los años y cursos disponibles. A partir de este archivo unificado, se realizaron scripts adicionales para explorar la estructura de los datos, incluyendo el número de columnas y filas, los nombres de los encabezados, el tipo de dato de cada columna y la presencia de valores nulos que se encuentra en el **Anexo 2**.

```
import pandas as pd
from pathlib import Path

ruta_base = Path("C:/MODULO 2-PYTHON/NOTAS COLEGIO")
años = ["2021", "2022", "2023", "2024"]

dataframes = []

for año in años:
    archivo = ruta_base / f"NOTAS_{año}.csv"
    if archivo.exists():
        print(f" Leyendo: {archivo.name}")
        df = pd.read_csv(archivo)
        df["AÑO"] = año # Agrega columna de año si no está
        dataframes.append(df)
    else:
        print(f" No se encontró el archivo: {archivo.name}")

if dataframes:
    df_unido = pd.concat(dataframes, ignore_index=True)
    df_unido.to_csv("notas_unidas.csv", index=False)
    print(" Archivo final generado: notas_unidas.csv")
else:
    print(" No se encontró ningún archivo para unir")
```

Figura 3-4 Conversión y unión de datos
Fuente: Elaboración propia, 2026

Se procedió a ajustar los tipos de datos para facilitar el análisis posterior: las columnas correspondientes al año y al nombre del estudiante se transformaron a tipo object, el curso se definió como tipo category, y

todas las columnas de notas se convirtieron a tipo float. Esta tipificación permitió una mejor manipulación de los datos y una integración más eficiente en Power Bi (Ver Figura 3-4). Posteriormente, se realizó una división de la base de datos en dos niveles educativos: primaria y secundaria. Esta segmentación respondió a diferencias curriculares, ya que se identificó que algunos cursos de nivel primario no cursan materias como física, química y filosofía, lo que generaba valores nulos en esas columnas mostrados en el **Anexo 3**.

La consolidación, tipificación y segmentación de la base de datos constituyeron etapas fundamentales para garantizar la calidad del análisis, ya que permitieron disponer de un conjunto de información homogéneo y estructurado. Este proceso no solo facilitó la integración de los datos en herramientas de visualización como Power BI.

```

NU_primaria = NU[NU["CURSO"].str.contains("PRIM")]
NU_secundaria = NU[NU["CURSO"].str.contains("SEC")]

print(" NaNs en primaria:")
print(NU_primaria.isna().sum().sort_values(ascending=False))

```

```

NaNs en primaria:
FILOSOFIA T2      570
FILOSOFIA T1      570
FILOSOFIA T3      570
FISICA T2         466
QUIMICA T1        466
FISICA T1         466
QUIMICA T2        466
FISICA T3         466
QUIMICA T3        466
AÑO              0
SOCIALES T1       0
INGLES T3         0

```

Figura 3-5: Separación entre nivel primario y secundario
Fuente: Elaboración propia, 2026.

Una vez separados los niveles, se exportaron dos archivos .csv independientes para facilitar su tratamiento en Power Bi. En VSCode, se continuó con la limpieza de los valores nulos, manteniendo las columnas de materias en tipo float y reemplazando los valores nulos por la etiqueta “NO_CURSA”, convertida a tipo object. Este cambio permitió distinguir claramente entre materias no cursadas y datos faltantes, mejorando la calidad del análisis. Se verificó que el reemplazo se hubiera aplicado correctamente y que no afectará los cálculos ni las visualizaciones.

El código mostrado utiliza las librerías Seaborn y Matplotlib, primeramente, se realiza una selección de columnas numéricas dentro del conjunto de datos de primaria, filtrando aquellas que contienen valores enteros o decimales. Posteriormente, se excluyen variables no académicas con el fin de centrar el análisis en las materias relevantes (Ver Figura 3-5). A partir de esta depuración, se calcula un promedio individual por estudiante, empleando la función “mean()” con la opción de ignorar valores faltantes. Este paso es crucial porque sintetiza múltiples calificaciones en una sola métrica representativa del rendimiento

académico. Finalmente, el código genera un histograma con curva de densidad, donde se configuran parámetros como el número de intervalos ($\text{bins}=20$), el color de barras y los títulos de los ejes.




Figura 3-6: Gráfica de la distribución de promedio de primaria

Fuente: Elaboración propia, 2026.

La figura corresponde a la representación gráfica de la distribución de promedios en primaria, elaborada mediante un histograma con soporte de librerías estadísticas en Python (Ver Figura 3-6). Para su construcción, se seleccionaron las columnas numéricas del conjunto de datos y se calcularon los promedios individuales de cada estudiante, lo que permitió disponer de una variable sintética que resume el rendimiento académico.

El histograma, acompañado de una curva de densidad, cumple la función de visualizar la forma de la distribución de los promedios y facilitar la identificación de patrones generales en el comportamiento académico. Este tipo de representación es fundamental porque transforma datos tabulares en información accesible, permitiendo observar tendencias y variabilidad de manera clara.

La gráfica presentada corresponde a una visualización de tipo barra horizontal, cuyo propósito es representar el promedio de calificaciones por materia en el nivel primario. En el eje horizontal se encuentra la escala de valores correspondientes al promedio de las materias, mientras que el eje vertical se listan las materias evaluadas segmentadas por trimestre.

Este tipo de gráfico permite observar de manera clara y ordenada la distribución de los promedios por asignaturas, facilitando la comparación entre ellas. Además, al estar ordenado de forma descendente, se puede identificar rápidamente qué materias presentan mayor o menor rendimiento promedio (Ver Figura 3-7). La visualización es útil para detectar patrones generales, analizar el comportamiento académico por área curricular y orientar decisiones pedagógicas basadas en evidencia.




Figura 3-7: Gráfico de barras para nivel primario

Fuente: Elaboración propia, 2026.

La gráfica presentada corresponde a un boxplot comparativo, diseñado para visualizar la distribución de calificaciones en distintas materias a lo largo de los cursos del nivel secundario. En el eje horizontal se representan los cursos, desde primero hasta sexto de secundaria, mientras que en el eje vertical se ubican los valores numéricos de las calificaciones obtenidas por los estudiantes.

Cada caja del boxplot muestra la distribución estadística de las notas por materia en cada curso, incluyendo la mediana, los cuartiles y posibles valores atípicos (Ver Figura 3-8). El uso del parámetro de color por materia permite distinguir fácilmente las asignaturas evaluadas dentro de cada curso.

Finalmente, este boxplot se convirtió en un recurso clave dentro del análisis, ya que permitió identificar cursos con mayor variabilidad en el rendimiento y materias con presencia recurrente de estudiantes en riesgo. Durante la construcción de la gráfica se evidenció que algunas materias presentaban mayor

dispersión en las notas, mientras que otras mantenían una distribución más homogénea. La representación gráfica facilitó la comunicación de los hallazgos y ofreció a los directivos una herramienta visual para comprender mejor las diferencias académicas entre cursos y asignaturas.

```
materias = ["FISICA T1", "FISICA T2", "MATEMATICAS T1", "MATEMATICAS T2", "FISICA T3", "INGLES T1"]
df_melt = NU_secundaria.melt(id_vars=["CURSO"], value_vars=materias, var_name="Materia", value_name="Nota")

sns.boxplot(x="CURSO", y="Nota", hue="Materia", data=df_melt)
plt.title("Comparación de materias por curso en secundaria")
plt.xticks(rotation=45)
plt.show()
```




Figura 3-8: Gráfico boxplot para nivel secundario
Fuente: Elaboración propia, 2026.

3.6 Desarrollo de modelos de aprendizaje supervisado (Regresión logística) y no supervisado (K-means), validando su eficacia mediante métricas de rendimiento estandarizadas

3.6.1 Modelo supervisado: Regresión Logística

El desarrollo del modelo supervisado se llevó a cabo siguiendo una metodología estructurada que permitió garantizar la validez y la reproducibilidad del proceso analítico. En primer lugar, se procedió a la recolección y organización de los datos académicos provenientes de los estudiantes de nivel primario y secundario. Estos datos incluían las calificaciones obtenidas en distintas asignaturas y trimestres, lo que proporcionó una base sólida para el análisis.

El procedimiento comienza con la lectura del archivo “notas_primaria.csv”, que contiene las calificaciones de los estudiantes, posteriormente, se aplica un proceso de limpieza de datos eliminando aquellas columnas con valores faltantes mediante la instrucción “dropna()”. Este paso asegura que el conjunto de datos

utilizado en los análisis posteriores sea consistente y libre de irregularidades que puedan afectar la calidad de los modelos. Finalmente, se visualizan las primeras filas del set de datos, lo que permite verificar la correcta carga y estructura de la información. Este bloque de código cumple una función estratégica dentro del proyecto: constituye la base a la preparación de datos sobre la cual se desarrollarán los modelos de aprendizaje automático y las visualizaciones interactivas. Al garantizar que los datos estén limpios y correctamente estructurados, se establece un flujo de trabajo reproducible y defendible, que conecta la etapa de recolección con el análisis predictivo. Además, la integración de librerías como scikit-learn anticipa la aplicación de algoritmos supervisados, lo que refuerza la coherencia metodológica entre la exploración descriptiva y la construcción de modelos de riesgo académico.

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.linear_model import LogisticRegression
from sklearn.metrics import accuracy_score, confusion_matrix, classification_report
```

```
df_prim = pd.read_csv("notas_primaria.csv")
df_prim.dropna(axis=1, how="any", inplace=True)
df_prim.head(5)
```

	AÑO	CURSO	ESTUDIANTE	LENGUAJE T1	LENGUAJE T2	LENGUAJE T3	INGLES T1	INGLES T2	INGLES T3	SOCIALES T1	...
0	2021	1 PRIM	AGUIRRE PANIAGUA ALEXANDER ELOY ALARCON	75.0	65.0	70.0	68.0	60.0	67.0	86.0	...

Figura 3-9: Carga de datos para el modelo
Fuente: elaboración propia, 2026.

Una vez depurados los datos, se procedió a la definición de la variable objetivo, la cual representaba la condición de riesgo académico del estudiante (Ver Figura 3-9). Esta variable fue codificada en dos categorías: riesgo (1) y no riesgo (0), lo que permitió enmarcar el problema dentro de una clasificación binaria. De esta manera, el modelo supervisado se entrenó para aprender a distinguir entre estudiantes que presentaban un desempeño académico vulnerable y aquellos que mantenían un rendimiento adecuado presentado en el **Anexo 4**.

Siguiendo con el código, se desarrolla la fase de modelización predictiva aplicada a los datos de primaria. El procedimiento inicia con la identificación de las columnas correspondientes a las calificaciones por trimestre, lo que permite construir un conjunto de variables académicas homogéneas. A partir de ellas, se calcula un promedio general por estudiante, que sintetiza el rendimiento en una sola métrica representativa.

Con base en este promedio, se genera una nueva variable denominada “riesgo”, la cual clasifica a los estudiantes en dos categorías: aquellos que se encuentran por debajo de un umbral definido y aquellos que lo superan. Este paso es crucial porque transforma un valor continuo en una etiqueta binaria,

facilitando la aplicación de modelos supervisados. Posteriormente, se definen las matrices de entrada (X) y salida (Y), que corresponden respectivamente a las notas por trimestre y a la variable de riesgo. El conjunto de datos se divide en entrenamiento y prueba mediante la función “train_test_split”, asegurando que el modelo pueda ser evaluado en condiciones controladas, de esta manera podremos trabajar con cierto porcentaje del dataset para un entrenamiento eficaz.

```
columnas_notas = [col for col in df_prim.columns if any(t in col for t in ["T1", "T2", "T3"])]

df_prim["PROMEDIO_GENERAL"] = df_prim[columnas_notas].mean(axis=1)

df_prim["riesgo"] = np.where(df_prim["PROMEDIO_GENERAL"] < 70, 1, 0)
```

```
X = df_prim[columnas_notas]
y = df_prim["riesgo"]
```

```
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.3, random_state=42)
```

```
# Crear y entrenar el modelo
log_reg = LogisticRegression()
log_reg.fit(X_train, y_train)

# Predicciones
y_pred = log_reg.predict(X_test)
```

Figura 3-10: Entrenamiento del modelo supervisado

Fuente: Elaboración propia, 2026.

Finalmente, se implementó un modelo de regresión logística, el cual se entrenó con los datos de entrenamiento y se utilizó para generar predicciones sobre el conjunto de prueba (Ver Figura 3-10). Este algoritmo es ampliamente empleado en contextos educativos porque permite estimar la probabilidad de pertenencia a una categoría a partir de múltiples variables explicativas.

```
from imblearn.over_sampling import SMOTE

smote = SMOTE(random_state=42)
X_resampled, y_resampled = smote.fit_resample(X, y)

# Dividir en entrenamiento y prueba
X_train, X_test, y_train, y_test = train_test_split(X_resampled, y_resampled, test_size=0.3, random_state=42)

# Entrenar el modelo
log_reg = LogisticRegression(max_iter=1000)
log_reg.fit(X_train, y_train)
y_pred = log_reg.predict(X_test)
```

Figura 3-11: Técnica SMOTE

Fuente: Elaboración propia, 2026.

Durante la exploración inicial de los datos se identificó un desbalance significativo entre las clases, ya que la mayoría de los estudiantes se encontraban en la categoría de “no riesgo”. Este fenómeno es común en

entornos escolares, donde los casos de bajo rendimiento suelen ser minoritarios en comparación con los estudiantes que mantienen calificaciones aceptables. Para abordar este problema se implementó la técnica SMOTE (Synthetic Minority Over-sampling Technique) (Ver Figura 3-11), que permitió equilibrar las clases y mejorar la capacidad del modelo para identificar correctamente a los estudiantes en riesgo académico.

Posteriormente, se aplicaron procedimientos de validación cruzada para evaluar la estabilidad del modelo y asegurar que los patrones aprendidos fueran generalizables a nuevos conjuntos de datos. La evaluación incluyó métricas clásicas como accuracy, precision, recall y f1-score, que permitieron valorar el desempeño general del modelo. Asimismo, se incorporaron métricas avanzadas que fortalecen la validación del enfoque supervisado. En primer lugar, el ROC-AUC (Receiver Operating Characteristic – Area Under the Curve), utilizado para analizar la capacidad discriminativa del modelo en distintos umbrales de decisión. De manera complementaria, se calculó el Log-Loss (Logarithmic Loss o Cross-Entropy Loss), métrica que mide la calidad de las probabilidades predichas y penaliza aquellas predicciones erróneas realizadas con alta confianza (Ver Figura 3-12).

```
log_reg = LogisticRegression(max_iter=1000)
log_reg.fit(X_train, y_train)

y_pred = log_reg.predict(X_test)
y_pred_proba = log_reg.predict_proba(X_test)[:, 1]

roc_auc = roc_auc_score(y_test, y_pred_proba)
logloss = log_loss(y_test, y_pred_proba)

print("ROC-AUC:", roc_auc)
print("Log-Loss:", logloss)

# 6. Graficar curva ROC
fpr, tpr, _ = roc_curve(y_test, y_pred_proba)
plt.plot(fpr, tpr, label=f'ROC curve (AUC = {roc_auc:.2f})')
plt.plot([0,1],[0,1], 'k--')
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Curva ROC - Regresión Logística con SMOTE')
plt.legend()
plt.show()
```

Figura 3-12: Métricas de evaluación ROC-AUC y Log-Loss
Fuente: Elaboración propia, 2026

El modelo supervisado se desarrolló siguiendo un proceso riguroso y replicable, aplicable tanto a estudiantes de nivel primario como secundario. La incorporación de SMOTE como técnica de balanceo constituyó un elemento clave para garantizar la equidad en el análisis y mejorar la capacidad del modelo para identificar estudiantes en riesgo.

3.6.2 Modelo no supervisado: K-Means

El segundo modelo desarrollado correspondió al enfoque no supervisado, específicamente mediante el algoritmo de K-Means, el cual se aplicó tanto a los datos de nivel primario como secundario siguiendo un procedimiento metodológico uniforme. La elección de este modelo respondió a la necesidad de identificar patrones ocultos en los datos académicos y segmentar a los estudiantes en grupos de desempeño, sin depender de etiquetas previas de riesgo o no riesgo.

En primer lugar, se procedió a la preparación de los datos, asegurando que las calificaciones de las distintas asignaturas y trimestres se encontraran en un formato numérico y estandarizado. Este paso fue esencial para garantizar que el algoritmo pudiera interpretar y correctamente las similitudes entre los estudiantes. Dado que los registros de primaria y secundaria compartían una estructura homogénea, se aplicó un mismo proceso de limpieza y transformación, evitando así la necesidad de separar los modelos por nivel educativo.

Posteriormente, se implementó un proceso de normalización de los datos mediante técnicas de estandarización, como el uso de StandardScaler. Este procedimiento permitió que todas las variables tuvieran la misma escala, evitando que asignaturas con valores más altos influyen de manera desproporcionada en la formación de los clusters. La normalización constituyó un paso metodológico crucial, ya que K-Means es sensible a las diferencias de magnitud entre las variables mostrados en el **Anexo 5**.

```
from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

inercia = []
for k in range(1, 10):
    kmeans = KMeans(n_clusters=k, random_state=42)
    kmeans.fit(X_scaled)
    inercia.append(kmeans.inertia_)

plt.plot(range(1, 10), inercia, marker="o")
plt.xlabel("Número de clusters (k)")
plt.ylabel("Inercia")
plt.title("Método del codo")
plt.show()
```

Figura 3-13: Estandarización y Método K-Means

Fuente: Elaboración propia, 2026

En esta parte del código, se implementa un procedimiento de análisis no supervisado mediante la técnica de clustering. El proceso inicia con la verificación de las columnas válidas del conjunto de datos, asegurando que únicamente aquellas relacionadas con las calificaciones por trimestre sean consideradas en el análisis. A partir de estas variables se construye la matriz de entrada (X), que constituye la base para la segmentación de los estudiantes. Posteriormente, se aplica un escalamiento estandarizado con la clase “StandardScaler”, lo cual normaliza los valores y garantiza que todas las variables tengan la misma

importancia en el proceso de agrupamiento. Este paso es esencial, ya que evita que diferencias en las escalas de las notas distorsionen la formación de los clusters.

Con los datos ya transformados, se procede a ejecutar el algoritmo K-Means, que busca dividir el conjunto en grupos homogéneos de estudiantes. Para determinar el número óptimo de clusters, se utiliza el método del codo, calculando la inercia (una medida de variabilidad interna de los grupos) para diferentes valores de k. Finalmente, se genera una gráfica que muestre la relación entre el número de clusters y la inercia, lo que permite identificar el punto en el que añadir más grupos deja de mejorar significativamente la calidad de la segmentación (Ver Figura 3-13).

Con el número de clusters definido, se procedió al entrenamiento del modelo K-Means, el cual asignó a cada estudiante un grupo específico en función de la similitud de sus calificaciones. Este proceso permitió identificar perfiles académicos diferenciados, agrupando a los estudiantes en categorías de desempeño que podían interpretarse posteriormente como bajo, medio o alto rendimiento. Cabe destacar que, al igual que en el modelo supervisado, se aplicaron los mismos pasos tanto en primaria como en secundaria, lo que asegura la consistencia metodológica y la comparabilidad de los resultados.

Durante esta parte del código se aplica la técnica de Análisis de Componentes Principales (PCA) con el objetivo de reducir la dimensionalidad de los datos académicos previamente escalados. El procedimiento transforma las múltiples variables de calificaciones en dos componentes principales, lo que permite representar la información en un espacio bidimensional sin perder la estructura esencial de la variabilidad. Una vez obtenidas los dos componentes principales (Ver Figura 3-14), se construye un DataFrame auxiliar que integra dichas dimensiones junto con la asignación de cada estudiante a un cluster específico.

```
# Reducir las notas escaladas a 2 dimensiones con PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)
import matplotlib.pyplot as plt
from sklearn.decomposition import PCA

# Reducir las notas escaladas a 2 dimensiones con PCA
pca = PCA(n_components=2)
X_pca = pca.fit_transform(X_scaled)

# Crear un DataFrame con las dos componentes principales y el cluster asignado
df_plot = pd.DataFrame({
    "PCA1": X_pca[:,0],
    "PCA2": X_pca[:,1],
    "Cluster": df_prim["Cluster"]
})

# Graficar los clusters
plt.figure(figsize=(8,6))
for cluster in df_plot["Cluster"].unique():
    plt.scatter(
        df_plot[df_plot["Cluster"] == cluster]["PCA1"],
        df_plot[df_plot["Cluster"] == cluster]["PCA2"],
        label=f"Cluster {cluster}"
    )

plt.xlabel("Componente principal 1")
plt.ylabel("Componente principal 2")
plt.title("Agrupación de estudiantes con K-Means (PCA 2D)")
plt.legend()
plt.show()
```

Figura 3-14: Entrenamiento del modelo no supervisado
Fuente: Elaboración propia, 2026

Finalmente, se genera un diagrama de dispersión en el que cada punto corresponde a un estudiante, ubicado según sus valores en los dos componentes principales y diferenciado por el cluster al que pertenece. La

inclusión de etiquetas y leyendas asegura que la visualización sea comprensible y que los grupos puedan ser identificados de manera precisa.

Para validar la calidad del modelo de agrupamiento K-Means se implementaron métricas de evaluación interna que permiten analizar la cohesión y separación de los clústeres formados. En primer lugar, se utilizó el Silhouette Score, que mide qué tan similares son los elementos dentro de un mismo clúster en comparación con otros clústeres (Ver Figura 3-15). Posteriormente, se aplicó el Davies-Bouldin Index, el cual evalúa la relación entre la dispersión interna de los grupos y la distancia entre ellos, siendo más confiables aquellos modelos con valores bajos en este indicador.

De manera complementaria, se incorporó una métrica adicional que enriquecen la validación del modelo no supervisado. El Calinski-Harabasz Index se empleó para analizar la proporción entre la varianza intergrupala y la varianza intragrupal, lo que permite determinar la separación estadística de los clústeres.

El procedimiento se realizó mediante código en Python, utilizando las librerías de scikit-learn para calcular las métricas y matplotlib para la representación gráfica. En primer lugar, los datos fueron escalados y reducidos a dos dimensiones mediante PCA (Análisis de Componentes Principales), lo que permitió visualizar los clústeres en un plano bidimensional. Posteriormente, se generaron gráficos de dispersión en los que cada punto representaba a un estudiante y cada color correspondía al clúster asignado por el algoritmo. Esta visualización facilitó la interpretación de la segmentación y permitió contrastar las métricas numéricas con la distribución gráfica de los grupos.

```
from sklearn.metrics import silhouette_score, davies_bouldin_score, calinski_harabasz_score

# Validación del modelo K-Means
silhouette = silhouette_score(X_scaled, df_prim["Cluster"])
davies_bouldin = davies_bouldin_score(X_scaled, df_prim["Cluster"])
calinski = calinski_harabasz_score(X_scaled, df_prim["Cluster"])

print("Silhouette Score:", silhouette)
print("Davies-Bouldin Index:", davies_bouldin)
print("Calinski-Harabasz Index:", calinski)
```

✓ 0.0s

Silhouette Score: 0.18884889631366678
 Davies-Bouldin Index: 1.70239166949058
 Calinski-Harabasz Index: 231.35997563387582

Figura 3-15: Técnica Silhouette Score y Davies-Bouldin para la validación del modelo

Fuente: Elaboración propia, 2026

3.7 Diseño de un sistema de visualización estratégica que facilite la interpretación de datos para la toma de decisiones pedagógicas

3.7.1 Transformación de datos en Power Bi

Para la construcción de los dashboards en Power Bi, el primer paso consistió en la carga de los conjuntos de datos previamente segmentados: uno correspondiente al nivel primario y otro al nivel secundario. Estos datasets fueron el resultado del proceso de limpieza y estructuración realizado en etapas anteriores, y contenían información académica organizada por estudiante, curso, año y materias cursadas. Una vez cargados ambos archivos en el entorno de Power Bi, se procedió a incorporar una nueva columna en cada

uno de ellos con el fin de identificar explícitamente el nivel educativo al que pertenecía cada registro. Esta columna, denominada “Nivel”, fue asignada con los valores “Primaria” o “Secundaria” según correspondiera, lo que permitió mantener la trazabilidad de los datos una vez unificados.

Con ambas tablas ya enriquecidas con la columna de nivel y con sus respectivos tipos de datos correctamente definidos, se procedió a realizar la unión de los dos datasets en una sola tabla muestra, la cual fue nombrada como NOTAS UNIFICADAS. Esta tabla consolidada permitió centralizar toda la información académica de los estudiantes desde primero de primaria hasta el último curso de secundaria, facilitando así el análisis transversal y longitudinal del desempeño estudiantil, teniendo en cuenta que los datos vacíos ya fueron removidos y así podremos tener una unificación de datos consolidada para la interpretación de los mismos.

Posteriormente, se verificó la consistencia de los tipos de datos y se aplicaron medidas calculadas mediante el lenguaje DAX, lo que permitió generar métricas adicionales como promedios ponderados, tasas de asistencia y porcentajes de estudiantes en riesgo por curso. Esta etapa fue clave para enriquecer la tabla consolidada y convertirla en una base robusta para la construcción de los dashboards. Asimismo, se definieron relaciones entre las distintas dimensiones de los datos, lo que permitió crear visualizaciones dinámicas y segmentaciones interactivas que facilitaron la exploración de la información por parte de los usuarios. Finalmente, la tabla NOTAS UNIFICADAS se consolidó como el núcleo del modelo de datos en Power BI, ya que a partir de ella se diseñaron los dashboards estratégicos que mostraron indicadores clave del rendimiento académico. Gracias a esta integración, los directivos pudieron analizar el desempeño estudiantil de manera global y también desagregada por curso, área y nivel educativo, lo que fortaleció la utilidad práctica del sistema y lo convirtió en una herramienta confiable para la toma de decisiones pedagógicas y administrativas.




Figura 3-16: Creación de la columna del nivel estudiantil

Fuente: Elaboración propia, 2026

Una vez obtenida la tabla unificada, se desarrollaron nuevas columnas para calcular los promedios por materia (Ver Figura 3-16). Para cada asignatura presente en el dataset, se creó una columna adicional que contenía el promedio de los tres trimestres del año escolar. Estas columnas fueron generadas mediante

fórmulas que excluían explícitamente los valores vacíos, lo cual fue especialmente importante en el caso del nivel primario, donde ciertas materias como Física, Química o Filosofía no son impartidas y, por tanto, presentan celdas vacías. Al evitar que estos valores nulos influyeran en los cálculos, se garantizó que los promedios reflejarán únicamente el rendimiento en las materias efectivamente cursadas por cada estudiante.




Figura 3-17: Eliminación de columnas sobrantes

Fuente: Elaboración propia, 2026

Posteriormente, se calculó el promedio general por estudiante, el cual se obtuvo a partir del promedio de todas las columnas de materias cursadas (Ver Figura 3-17). Este valor sirvió como indicador sintético del desempeño académico global de cada alumno, y fue fundamental para la construcción de visualizaciones agregadas, segmentaciones por nivel y generación de alertas pedagógicas. Con los promedios generales ya calculados, se realizó una copia de la tabla NOTAS UNIFICADAS con el propósito de crear una tabla específica orientada al análisis por materia. Esta nueva tabla fue renombrada como TABLA MATERIAS, y en ella se eliminaron todas las columnas correspondientes a los trimestres individuales, así como la columna de promedio general, conservando únicamente las columnas de promedios por materia, junto con los identificadores clave como nombre del estudiante, curso, año y nivel.

A continuación, se aplicó un proceso de anulación de dinamización (también conocido como “unpivot” o “desnormalización”), mediante el cual se transformaron las columnas de materias en filas (Ver Figura 3-18). Para ello, se especificaron las columnas fijas que debían conservarse (como estudiante, curso, año y nivel), y se seleccionaron las columnas de materias como variables a descomponer. El resultado fue una tabla en la que cada fila representa una observación única de un estudiante en una materia específica, con dos columnas principales: una para el nombre de la materia y otra para la nota promedio correspondiente.

Esta transformación permitió obtener una estructura de datos más flexible y analíticamente potente, ideal para realizar análisis comparativos entre materias, identificar patrones de rendimiento por asignatura, y construir visualizaciones detalladas del comportamiento académico en función del área disciplinar. Gracias a esta reorganización, fue posible profundizar en el estudio de las materias cursadas por todos los estudiantes de los niveles primario y secundario, generando así una base sólida para la toma de decisiones

pedagógicas y la implementación de estrategias de mejora educativa basadas en evidencia mostradas en el **Anexo 7**.




Figura 3-18: Desnormalización de la columna de materias

Fuente: Elaboración propia, 2026

3.7.2 Creación de dashboards en Power Bi

Como parte fundamental del proyecto se desarrollaron cuatro dashboards interactivos en Power BI, concebidos para transformar los resultados del modelado en herramientas prácticas de análisis y gestión educativa. La finalidad de estos tableros fue ofrecer a docentes y directivos una visión clara, dinámica y defendible del rendimiento académico, permitiendo que los hallazgos técnicos se traduzcan en información accesible para la toma de decisiones pedagógicas.

El primero corresponde a un dashboard general, que integra la información consolidada de todos los estudiantes y ofrece una visión panorámica del desempeño académico institucional. Se diseñó porque era necesario contar con una perspectiva global, que permitiera identificar tendencias generales, visualizar la distribución de estudiantes según niveles de rendimiento y generar un punto de partida para el análisis más detallado en los demás dashboards.

El segundo es un dashboard específico para nivel primario, orientado a mostrar el rendimiento de los estudiantes en las etapas iniciales de formación. Se elaboró porque en este nivel es crucial detectar tempranamente dificultades académicas, dado que las bases del aprendizaje se consolidan en primaria. Este tablero facilita el seguimiento de calificaciones y asistencia, permitiendo a los docentes intervenir oportunamente con estrategias de apoyo.

El tercero es un dashboard para nivel secundario, diseñado para analizar el desempeño en cursos superiores, donde las exigencias académicas son mayores y las diferencias entre materias se vuelven más significativas. Se creó porque en secundaria es necesario un seguimiento más detallado, que permita

identificar estudiantes en riesgo de rezago, evaluar la evolución del rendimiento en los últimos años escolares y focalizar acciones pedagógicas que aseguren la culminación exitosa de la formación.

El cuarto dashboard es un dashboard de materias, que presenta el promedio de calificaciones por asignatura y trimestre. Se desarrolló porque era indispensable identificar las áreas críticas de aprendizaje, es decir, aquellas materias con bajo rendimiento colectivo, de modo que los docentes puedan focalizar esfuerzos y diseñar estrategias específicas para mejorar los resultados en asignaturas clave.

En conjunto, estos cuatro dashboards convierten los datos en información estratégica y defendible, asegurando que el análisis técnico se traduzca en herramientas prácticas de gestión educativa. Gracias a su diseño interactivo, los tableros permiten explorar la información desde diferentes perspectivas, comparar resultados entre niveles y materias, y generar alertas pedagógicas que apoyan la toma de decisiones basadas en evidencia.

3.7.2.1 Dashboard general

Una vez finalizado el proceso de limpieza, segmentación y consolidación de los datos en Power Bi, se procedió a la constitución del primer dashboard, orientado a ofrecer una visión general del rendimiento académico estudiantil en la unidad educativa. Para ello, se utilizó como fuente principal la tabla NOTAS UNIFICADAS, que contiene información integrada de estudiantes de nivel primario y secundario desde el año 2021 hasta el 2024.

```
PROMEDIO GENERAL =
VAR valores = {
    'NOTAS UNIFICADAS'[PROMEDIO LENGUAJE],
    'NOTAS UNIFICADAS'[PROMEDIO INGLES],
    'NOTAS UNIFICADAS'[PROMEDIO SOCIALES],
    'NOTAS UNIFICADAS'[PROMEDIO DEPORTES],
    'NOTAS UNIFICADAS'[PROMEDIO MUSICA],
    'NOTAS UNIFICADAS'[PROMEDIO ARTES],
    'NOTAS UNIFICADAS'[PROMEDIO MATEMATICAS],
    'NOTAS UNIFICADAS'[PROMEDIO TECNICA TECNOLOGICA],
    'NOTAS UNIFICADAS'[PROMEDIO BIOLOGIA],
    'NOTAS UNIFICADAS'[PROMEDIO RELIGION],
    'NOTAS UNIFICADAS'[PROMEDIO FISICA],
    'NOTAS UNIFICADAS'[PROMEDIO QUIMICA],
    'NOTAS UNIFICADAS'[PROMEDIO FILOSOFIA]
}
VAR suma =
    SUMX(
        FILTER(valores, ISNUMBER([Value])),
        [Value]
    )
VAR cantidad =
    COUNTX(
        FILTER(valores, ISNUMBER([Value])),
        [Value]
    )
RETURN
    IF(cantidad > 0, suma / cantidad, BLANK())
```

Figura 3-19: Medida DAX para hallar el promedio general
Fuente: Elaboración propia, 2026

La implementación de la columna denominada Promedio General dentro del entorno de Power Bi se ha estructurado mediante el lenguaje DAX, empleando una lógica de cálculo que prioriza la precisión estadística y la integridad de los datos. En primer lugar, el código utiliza una variable denominada “valores” para consolidar, en una estructura de tabla interna.

Posteriormente, el algoritmo procede a realizar una fase de depuración y procesamiento mediante las funciones SUMX y COUNTX, las cuales operan bajo un criterio de filtrado estrictamente definido por la

función ISNUMBER. En este sentido, el sistema garantiza que el cálculo de la suma total y el conteo de las materias evaluadas se realicen excluyendo de forma automática cualquier registro que carezca de valor numérico o que presente valores nulos. Por consiguiente, esta metodología evita sesgos en el resultado final, asegurando que el promedio resultante refleje únicamente el desempeño real sobre las materias efectivamente cursadas y calificadas.

Finalmente, la instrucción RETURN ejecuta una operación condicional IF que actúa como un mecanismo de control de errores; esta verifica la existencia de datos válidos antes de proceder con la división aritmética. De este modo, se previene la generación de errores matemáticos por división entre cero, entregando un valor en blanco en caso de ausencia de datos (Ver Figura 3-19). En conclusión, la adopción de este código representa una solución técnica robusta que permite un seguimiento automatizado y confiable del rendimiento estudiantil a través de múltiples periodos académicos. Posteriormente fue la creación de una columna calculada denominada Situación Académica, basada en el promedio general de cada estudiante. Esta columna clasifica a los estudiantes en tres categorías:

- Destacado: promedio general igual o mayor a 85
- Satisfactorio: promedio entre 70 y 84
- Regular: promedio entre 51 y 69
- Riesgo: promedio igual o menor a 50

Esta clasificación permite agrupar a los estudiantes según su nivel de desempeño, lo que resulta útil para identificar aquellos que podrían beneficiarse de apoyo académico adicional en el siguiente año escolar.

```
SITUACION ACADEMICA =
SWITCH(
  TRUE(),
  'NOTAS UNIFICADAS'[PROMEDIO GENERAL] >= 86, "Destacado",
  'NOTAS UNIFICADAS'[PROMEDIO GENERAL] >= 71, "Satisfactorio",
  'NOTAS UNIFICADAS'[PROMEDIO GENERAL] >= 51, "Regular",
  'NOTAS UNIFICADAS'[PROMEDIO GENERAL] < 51, "En riesgo",
  BLANK()
)
```

Figura 3-20: Clasificación de promedios
Fuente: Elaboración propia, 2026

A partir de esta columna, se construyeron medidas de conteo y porcentaje para cada categoría, denominada Tasa de Destacados, Tasa Satisfactorio y Tasa de Regulares, respectivamente (Ver Figura 3-20). Estas tasas reflejan el porcentaje de estudiantes que se encuentren en cada nivel de rendimiento, permitiendo evaluar la distribución general del desempeño académico en la institución.

La estructura de cálculo principal, ejemplificada en la Tasa de Destacados, utiliza la función DIVIDE para establecer una relación proporcional entre un segmento específico y el universo total de datos; en este sentido, la función CALCULATE actúa junto a COUNTROWS para filtrar y contabilizar exclusivamente a los estudiantes cuya “Situación Académica” cumple con el criterio de excelencia definido. Siguiendo esta misma lógica algorítmica, se han desarrollado de manera sistemática las métricas de Tasa de Regulares,

Tasa de Satisfactorio y Tasa de Riesgo, adaptando en cada caso el argumento de filtro en la función de cálculo (Ver Figura 3-21). Por consiguiente, este conjunto de medidas permite a la institución cuantificar no solo el promedio numérico, sino la distribución porcentual de los alumnos en diferentes estratos de aprendizaje, facilitando la identificación de grupos que requieren intervención inmediata, como es el caso de la tasa de riesgo, frente a aquellos que mantienen una trayectoria de aprovechamiento óptimo.

```
TASA DE DESTACADOS =  
DIVIDE(  
  CALCULATE(COUNTROWS('NOTAS UNIFICADAS'), 'NOTAS UNIFICADAS'[SITUACION ACADEMICA] = "Destacado"),  
  CALCULATE(COUNTROWS('NOTAS UNIFICADAS'))  
)
```

Figura 3-21: Medida DAX para hallar la tasa de destacados

Fuente: Elaboración propia, 2026

Asimismo, el uso recurrente de la función DIVIDE para todas estas tasas responde a una política de robustez técnica, ya que este comando está optimizado para gestionar de forma segura los casos en los que el denominador sea cero, evitando errores en la visualización de los reportes. En virtud de ello, la arquitectura de estos códigos proporciona una visión analítica integral que transforma los registros individuales en indicadores estratégicos. Permitiendo monitorear cómo fluctúa la proporción de estudiantes destacados frente a los que se encuentran en situaciones académicas vulnerables a lo largo de los años. Esta metodología unificada garantiza la coherencia estadística del proyecto, asegurando que la suma de las diversas tasas represente siempre el cien por ciento de la matrícula evaluada. De este modo, se obtiene un tablero de control dinámico que es capaz de reflejar si las políticas de mejora académica están logrando desplazar a los estudiantes desde los niveles de riesgo y regularidad hacia los estratos de satisfactorio y destacado de manera progresiva y verificable.




Figura 3-22: Dashboard general

Fuente: Elaboración propia, 2026

El primer dashboard fue diseñado como una herramienta de análisis institucional que permite visualizar de manera integrada el rendimiento académico de los estudiantes de nivel primario y secundario (Ver Figura

3-22). Su estructura combina indicadores clave como la tasa de destacados, satisfactorios y regulares, junto con el promedio general y el promedio por curso, lo que facilita una lectura rápida y estratégica del estado académico de la población estudiantil (Ver Anexo 4).

La clasificación por niveles de desempeño permite agrupar a los estudiantes según su rendimiento, lo que resulta útil para identificar aquellos que podrían beneficiarse de apoyo académico adicional en el siguiente año escolar. Esta segmentación facilita la implementación de estrategias diferenciadas de acompañamiento pedagógico, adaptadas a las necesidades específicas de cada grupo. Estos indicadores permiten a los directivos y docentes identificar con claridad qué proporción de la población estudiantil está alcanzando los objetivos académicos, quiénes están en un rango aceptable pero mejorable, y quiénes podrían requerir intervenciones específicas.

Complementando esta visión general, se incorporó un gráfico de barras titulado Promedio General por Curso, que muestra el promedio académico por grado escolar, desde primero de primaria hasta sexto de secundaria. Esta visualización permite detectar diferencias entre niveles, identificar cursos por mayor estabilidad o variabilidad, y orientar decisiones pedagógicas con base en evidencia.

Este primer dashboard cumple una función estratégica al ofrecer una radiografía institucional del rendimiento académico, permitiendo tomar decisiones informadas sobre planificación curricular, asignación de recursos, y diseño de programas de apoyo. Además, sienta las bases para la construcción de dashboards más específicos por materia, curso, docente o área disciplinar.

3.7.2.2 Dashboard para nivel primaria

Para la elaboración del dashboard correspondiente al nivel primario, se trabajó con la tabla segmentada previamente en Power Bi, que contiene los promedios generales de los estudiantes desde primero hasta sexto de primaria, organizados por año escolar.




Figura 3-23: Dashboard para nivel primario
Fuente: Elaboración propia, 2026

En primer lugar, se crearon medidas específicas para calcular la nota máxima y la nota mínima dentro del conjunto de datos, tomando como referencia la columna de promedio general. Estas medidas permiten

identificar los extremos del rendimiento académico en cada filtro aplicado, ya sea por curso o por año, y fueron diseñadas para actualizarse automáticamente según la selección del usuario.

Para facilitar la exploración comparativa, se incorporaron segmentadores (listas desplegables) que permiten seleccionar el año escolar y el curso. Estos filtros interactúan con todos los elementos visuales del dashboard, permitiendo al usuario observar cómo varía el rendimiento promedio y la distribución de estudiantes destacados según el contexto temporal y académico.

Adicionalmente, se implementó una medida que realiza el conteo de estudiantes con situación académica “Destacado”, basada en la clasificación previamente definida en la tabla NOTAS UNIFICADAS. Esta medida se complementa con una tabla visual que muestra el nombre del estudiante, el curso al que pertenece, su promedio general y su situación académica. Esta tabla se actualiza dinámicamente según los filtros aplicados, permitiendo identificar de forma precisa qué estudiantes alcanzaron un rendimiento sobresaliente en un curso o año específico.

Como componente central del dashboard, se diseñó una gráfica de barras agrupadas que compara los promedios generales por curso y por año (Ver Figura 3-23). Para ello, se utilizaron las columnas de promedio general junto con los campos de curso y año, aplicando una agregación por promedio para cada combinación. Esta visualización permite observar la evaluación del rendimiento académico en los distintos grados de primaria a lo largo del tiempo, y fue configurada para mostrar los valores de manera clara y ordenada, facilitando el análisis comparativo entre cohortes.

Este dashboard representa una herramienta clave para el monitoreo académico en el nivel primario, al integrar múltiples componentes visuales que permiten una exploración detallada del rendimiento estudiantil. Su diseño responde a la necesidad de contar con una plataforma interactiva que facilite el análisis longitudinal y comparativo de los promedios generales por curso y por gestión, desde primero hasta sexto de primaria.

En conjunto, este dashboard fue construido con el propósito de ofrecer una herramienta interactiva y funcional para el análisis del rendimiento académico en el nivel primario, integrando medidas estadísticas, segmentadores dinámicos y visualizaciones detalladas que permiten una exploración profunda de los datos por curso, año y estudiante.

3.7.2.3 Dashboard para nivel secundario

El dashboard diseñado para el nivel secundario se trabajó con la tabla segmentada, que incluye los promedios generales de los estudiantes de primero de secundaria hasta sexto de secundaria. Se definieron medidas específicas para calcular la nota más alta y la nota más baja dentro del conjunto de datos, utilizando únicamente los valores de promedio general. Estas medidas se integraron como indicadores clave en el panel derecho del dashboard, permitiendo una lectura rápida de los extremos de rendimiento en función de los filtros aplicados.

Además, se incorporó una medida de conteo total de estudiantes, que se actualiza dinámicamente según el año y curso seleccionados. Esta medida no solo permite dimensionar el tamaño de la muestra analizada, sino que también sirve como base para cálculos proporcionales y segmentaciones posteriores.

La incorporación de medidas como nota máxima, nota mínima, promedio general y recuento de estudiantes destacados permite construir una lectura integral del desempeño académico, sin necesidad de acceder directamente a los resultados individuales. Estos indicadores ofrecen una visión panorámica del comportamiento del conjunto estudiantil, permitiendo detectar zonas de estabilidad, dispersión o concentración en los datos.

Uno de los componentes más relevantes del dashboard es la tabla de estudiantes, que fue diseñada para mostrar de forma directa el nombre completo del alumno, el curso que pertenece, su promedio general y su situación académica. Esta tabla se alimenta de la clasificación previamente definida en la etapa de tratamiento de datos, y permite identificar rápidamente qué estudiantes se encuentran en situación destacada, regular o en recuperación.

Para representar la evaluación del rendimiento por curso y año, se construyó una gráfica de barras agrupadas que compara los promedios generales de los estudiantes en los tres cursos superiores de secundaria a lo largo de los años 2021, 2022, 2023 y 2024. Esta visualización fue diseñada para resaltar las variaciones interanuales dentro de cada curso, permitiendo detectar tendencias, fluctuaciones y posibles puntos de inflexión en el rendimiento académico colectivo.




Figura 3-24: Dashboard para nivel secundario

Fuente: Elaboración propia, 2026

El diseño del dashboard también incluyó segmentadores interactivos para año y curso, que permiten al usuario filtrar la información y adaptar la visualización a sus necesidades específicas. Estos filtros afectan tanto los indicadores como la tabla y la gráfica, generando una experiencia de análisis más flexible y personalizada.

El uso de segmentadores interactivos convierte el dashboard en una herramienta flexible, adaptable a distintos enfoques de análisis (Ver Figura 3-24). Ya sea para evaluar un curso específico, una gestión determinada o el comportamiento de un grupo de estudiantes, los filtros permiten personalizar la visualización y extraer información relevante para la toma de decisiones.

En conjunto, el dashboard del nivel secundario se construyó con una lógica centrada en la comparación temporal, la identificación individual y la exploración detallada por curso. Su estructura permite no solo observar el rendimiento agregado, sino también profundizar en el comportamiento académico de cada estudiante, facilitando la toma de decisiones pedagógicas basadas en evidencia concreta.

3.7.2.4 Dashboard estudiantil por materia

El dashboard titulado Rendimiento estudiantil por materia, fue desarrollado a partir de la tabla previamente desnormalizada, la cual reorganiza los datos académicos en un formato largo que permite analizar el desempeño por asignatura de manera más detallada. Esta estructura facilitó la implementación de visualizaciones comparativas y segmentaciones dinámicas orientadas al análisis pedagógico transversal. La estructura desnormalizada de la tabla base fue clave para lograr una visualización flexible y detallada. Al organizar los datos en formato largo, se habilitó la posibilidad de aplicar filtros dinámicos y construir visualizaciones que respondan a combinaciones específicas de curso, año, nivel educativo y materia. Esta configuración permite adaptar el análisis a distintos enfoques pedagógicos, ya sea por área disciplinar, por cohorte o por gestión académica.

Como primer paso en la construcción del dashboard, se incorporaron segmentadores interactivos que permiten filtrar la información por año escolar, curso, materia y nivel educativo. Estos deslizadores fueron configurados para interactuar con todos los elementos visuales del panel, permitiendo al usuario realizar comparaciones específicas entre asignaturas, cursos y periodos académicos. Esta funcionalidad es clave para adaptar el análisis a distintos contextos y necesidades institucionales.




Figura 3-25: Dashboard. del rendimiento por materia
Fuente: Elaboración propia, 2026

Para representar el rendimiento por asignatura, se diseñó una gráfica de barras que muestra el promedio de nota por materia. Esta visualización fue construida utilizando valores agregados de las calificaciones promedio, agrupados por asignatura, y se actualiza automáticamente según los filtros aplicados. Su

propósito es ofrecer una lectura clara del comportamiento académico por área disciplinar, permitiendo identificar patrones de desempeño diferenciados por curso o año.

Complementando esta visualización, se desarrolló una gráfica de líneas que representa el promedio de nota por materia a lo largo de los años. Esta gráfica permite observar la evolución temporal del rendimiento en cada asignatura, y fue configurada para mostrar múltiples líneas correspondientes a las materias seleccionadas, facilitando el análisis comparativo entre ellas. Adicionalmente, se implementó una visualización que muestra el recuento de estudiantes por estado académico en cada materia, utilizando una clasificación previamente definida en la etapa de tratamiento de datos (Ver Figura 3-25). Para ello, se creó una medida que asigna a cada estudiante una situación académica (Destacado, Satisfactorio o Regular) en función de su nota promedio en la materia correspondiente. A partir de esta clasificación, se calcularon las tasas porcentuales de cada categoría, permitiendo representar la distribución del rendimiento estudiantil por asignatura y año.

Los indicadores porcentuales integrados en el panel derecho del dashboard cumplen una función estratégica al sintetizar la distribución del rendimiento por materia. Estos indicadores se actualizan automáticamente según los filtros aplicados, lo que permite realizar análisis focalizados y obtener métricas precisas para la toma de decisiones pedagógicas.

Estas tasas fueron integradas como indicadores clave en el panel derecho del dashboard, y se actualizan dinámicamente según los filtros aplicados. Esta configuración permite observar cómo varía la proporción de estudiantes en cada nivel de desempeño según la materia, el curso y el año seleccionado.

En conjunto, el dashboard fue diseñado para ofrecer una herramienta analítica robusta que permita explorar el rendimiento académico por asignatura desde múltiples dimensiones. Su estructura combina filtros interactivos, medidas estadísticas y visualizaciones comparativas que facilitan la toma de decisiones pedagógicas basadas en evidencia, y permite identificar áreas curriculares que podrían requerir refuerzo o atención específica en futuros ciclos escolares.

3.7.2.5 Medidas DAX para tablas de los resultados

La estructura lógica diseñada para obtener el Promedio Anterior constituye el núcleo analítico de la comparativa interanual, permitiendo que el sistema posea “memoria” de los resultados obtenidos en el ciclo previo. Para lograr este objetivo, el algoritmo se inicia con la declaración de la variable `FechaActual`, la cual captura el contexto temporal específico que el usuario está consultando mediante la función `SELECTEDVALUE`. Posteriormente, se define la variable `PrevYear`, cuya función es realizar un retroceso cronológico de exactamente un año sobre la fecha detectada, siempre y cuando esta no se encuentre vacía, asegurando así que el cálculo tenga un punto de referencia válido para la comparación.

En este orden de ideas, el bloque de ejecución bajo la instrucción `RETURN` actúa como un filtro de seguridad y precisión; si el sistema determina que no existe un año previo registrado, la medida devuelve un valor en blanco para evitar inconsistencias en el reporte (Ver Figura 3-26). No obstante, cuando se identifica un año anterior válido, se invoca la función `CALCULATE`, la cual modifica el contexto de filtrado mediante `ALL`. Esta instrucción es de vital importancia, ya que permite al sistema “ignorar” temporalmente el año actual seleccionado para buscar y recuperar la medida `[PromedioGeneralMedida]` correspondiente al año inmediatamente anterior (`PrevYear`).

Por consiguiente, esta arquitectura lógica es la que hace posible el cálculo automático de la variación porcentual analizada anteriormente, pues establece el minuendo necesario para determinar si el rendimiento ha ascendido o descendido respecto al ciclo precedente. Finalmente, la implementación de este código dota el proyecto de un dinamismo esencial, permitiendo que los tableros de control reflejen la evolución histórica del colegio de manera automatizada, sin necesidad de realizar ajustes manuales cada vez que se ingresan nuevas calificaciones al sistema de datos unificado.

El diseño algorítmico de la Variación Porcentual constituyen la métrica final de control dentro del modelo de datos, funcionando como el indicador crítico que cuantifica el crecimiento o decrecimiento real del rendimiento institucional entre periodos consecutivos. Para su ejecución, el código se fundamenta en la declaración de dos variables clave: Curr, que captura el promedio del periodo actual seleccionado, y Prev, que recupera el valor del ciclo anterior mediante la lógica de desplazamiento temporal previamente establecida. En este sentido, la interacción entre ambas variables permite al sistema aislar el diferencial de rendimiento necesario para realizar una comparación estadística válida y automatizada.

```
PromedioAnterior =
VAR FechaActual = SELECTEDVALUE('NOTAS UNIFICADAS'[FechaEntregaNotas])
VAR PrevYear =
    IF(NOT ISBLANK(FechaActual), YEAR(FechaActual) - 1, BLANK())
RETURN
IF (
    ISBLANK(PrevYear),
    BLANK(),
    CALCULATE (
        [PromedioGeneralMedida],
        FILTER (
            ALL('NOTAS UNIFICADAS'[FechaEntregaNotas]),
            YEAR('NOTAS UNIFICADAS'[FechaEntregaNotas]) = PrevYear
        )
    )
)
```

Figura 3-26: Medida DAX para hallar el promedio en función al año anterior
Fuente: Elaboración propia, 2026

Consecuentemente, la instrucción RETURN introduce una capa de validación lógica mediante el uso del operador OR, el cual verifica si la variable del periodo anterior se encuentra vacía o es equivalente a cero. Esta verificación es indispensable para mantener la integridad del reporte, ya que, al omitir el cálculo en ausencia de una base comparativa, se evitan errores de interpretación en los gráficos y se previene la aparición de valores infinitos o inconsistentes. Por lo tanto, el código garantiza que la tendencia reflejada en el informe se sustenta exclusivamente en datos históricos verificables, proporcionando una visualización limpia y profesional de la evolución académica.

De este modo, la variación porcentual no solo cumple una función técnica dentro del modelo de datos, sino que se convierte en un recurso estratégico para la gestión institucional. Al ofrecer una medida clara del desempeño interanual, permite identificar con precisión las áreas de mayor crecimiento, así como

aquellas que requieren intervención pedagógica más intensiva. En suma, este diseño algorítmico consolida la robustez del sistema de análisis y fortalece la toma de decisiones basadas en evidencia, contribuyendo a la mejora continua del rendimiento académico.

Finalmente, la operación aritmética se resuelve a través de la función DIVIDE, la cual ejecuta la fórmula de tasa de variación(Ver Figura 3-27). Este procedimiento matemático es el que permite transformar los promedios numéricos en los porcentajes de mejora analizados en secciones previas, tales como el notable incremento del 2,13% observados hacia el cierre de 2024. De este modo, la implementación de esta medida no solo automatiza el cálculo de progreso, sino que dota a la dirección académica de una herramienta diagnóstica precisa para evaluar el impacto de sus políticas educativas en tiempo real, consolidando la robustez técnica de todo el sistema de seguimiento de resultados.

```
VariacionPorcentual =  
VAR Curr = [PromedioGeneralMedida]  
VAR Prev = [PromedioAnterior]  
RETURN  
IF (  
    OR(ISBLANK(Prev), Prev = 0),  
    BLANK(),  
    DIVIDE(Curr - Prev, Prev)  
)
```

Figura 3-27: Medida DAX para hallar la Variación porcentual
Fuente: Elaboración propia, 2026

4. Análisis de Resultados y Discusión

4.1 Resultados y análisis de recopilación e identificación de registros académicos de estudiantes de la unidad educativa mediante la identificación y consolidación de fuentes de datos

La estructura y organización de los datos recibidos constituyó un punto de partida fundamental para el desarrollo del proyecto. El hecho de contar con archivos Excel distribuidos por curso y año escolar permitió una segmentación natural de la información, facilitando su posterior tratamiento. Sin embargo, esta forma de entrega también implicó desafíos técnicos, como la necesidad de estandarizar nombres de columnas y consolidar múltiples fuentes en una única base de datos unificada.

AÑO	CURSO	ESTUDIANTE	LENGUAJE T1	LENGUAJE T2	LENGUAJE T3	INGLES T1	INGLES T2	INGLES T3
2021	1	PRIM, AGUIRRE PANIAGUA ALEXANDER ELOY	75	65	70	68	60	67, 86, 59, 100
2021	1	PRIM, ALARCON CHILA DARA MAGDIEL	94	89	93	100	100	100, 95, 86, 90
2021	1	PRIM, ANGULO QUINTEROS SOPHIE ELEONORA	91	87	91	72	79	84, 92, 88
2021	1	PRIM, APAZA AYMA NATALY JHAJAIRA	91	64	77	87	72	76, 94, 65, 72, 87
2021	1	PRIM, CASTELLON QUISPE PEDRO STEPHEN	97	93	99	100	100	97, 97, 93
2021	1	PRIM, COLQUE GARNICA KATHERINE SOFIA	83	76	91	80	75	71, 86, 82, 81
2021	1	PRIM, CORRALES MONTECINOS ADRIAN FABRICIO	100	97	100	100	100	100, 100
2021	1	PRIM, ITURRI ANDRADE ANGELES ITZEL	86	81	69	65	65	71, 89, 69, 64, 100
2021	1	PRIM, LIZARAZU GUTIERREZ ZOBEIDA GUEIZA	98	89	95	95	98	95, 98, 91
2021	1	PRIM, LOPEZ CADIMA DYLAN ZAID	85	64	69	82	64	67, 83, 66, 72, 85, 78
2021	1	PRIM, LOZANO ALMANZA LEYA MASSIEL	89	70	79	93	93	73, 83, 72, 80, 81
2021	1	PRIM, MENDOZA RAMIREZ EMILY SHARON	85	77	84	90	82	72, 87, 76, 79, 100
2021	1	PRIM, MERCADO AQUINO MATIAS	85	83	93	80	82	77, 86, 89, 94, 83, 82, 81
2021	1	PRIM, MOJICA HEREDIA GRACIELA	95	83	92	100	79	71, 97, 81, 91, 90, 81
2021	1	PRIM, PADILLA MORA CATALEYA GUADALUPE	85	86	90	100	89	92, 90, 85
2021	1	PRIM, PAREDES HEREDIA ANGELICA SAMANTA	90	81	90	90	83	82, 91, 90
2021	1	PRIM, ROJAS BUSTAMANTE GABRIEL SANTIAGO	93	80	89	100	97	88, 92, 100
2021	1	PRIM, ROJAS VARGAS ZAHIR ANDY	82	66	82	92	84	72, 83, 70, 81, 80, 67
2021	1	PRIM, TERAN ZOLA JUAN DARIO	81	68	70	79	73	72, 84, 62, 64, 78, 73, 71
2021	1	PRIM, TRONCOSO ORELLANA FERNANDA	97	84	89	100	100	100, 96, 80, 81

Figura 4-1: Verificación de la unión de los Excels

Fuente: Elaboración propia, 2026.

Durante el análisis preliminar se identificaron aspectos relevantes que evidencian la riqueza y complejidad de la información:

- Se detectaron 576 valores nulos en calificaciones, principalmente concentrados en cursos de secundaria, lo que obligó a aplicar técnicas de imputación y depuración.
- Se observaron diferencias en la estructura de columnas entre años escolares, como variaciones en la denominación de materias y en el registro de asistencia, lo que requirió un proceso de homogenización para asegurar la consistencia del dataset.
- Se identificaron materias con mayor concentración de bajas calificaciones, entre ellas Matemáticas y Física en secundaria, y Lenguaje en primaria, lo que orientó la necesidad de dashboards específicos por nivel y asignatura.

Estos hallazgos demuestran que la etapa inicial no solo implicó la recopilación de datos, sino también su validación, limpieza y preparación para el modelado analítico, lo que confirma la importancia de una adquisición consciente y técnicamente orientada. La concentración de vacíos no es aleatoria; responde a la complejidad administrativa del nivel secundario, donde la rotación de docentes o la demora en el registro de materias técnicas genera brechas de información. La necesidad de aplicar técnicas de imputación no fue solo un paso técnico, sino una medida para evitar sesgos que podrían haber subestimado el riesgo de deserción en los modelos predictivo. La falta de estandarización evidencia que los criterios de evaluación han evolucionado o cambiado entre gestiones, para el proyecto, esto significa que la homogenización no fue un simple cambio de nombres, sino una alineación de criterios para el modelo predictivo pudiera comparar.

La definición del propósito del proyecto fue guiada por una necesidad institucional clara: transformar registros académicos crudos en información estratégica para la toma de decisiones pedagógicas. El enfoque adoptado se centró en cuatro objetivos clave: detectar estudiantes en riesgo académico, identificar materias con bajo rendimiento colectivo, comparar el desempeño entre cursos y años, y generar alertas pedagógicas que faciliten la intervención oportuna por parte de docentes y directivos.

Este propósito no se limita a una visualización descriptiva, sino que propone una herramienta de análisis estratégico. Con el código para la unificación de los Excel se logró combinar los archivos en un solo dataset, primero mediante la lectura de los cuatro archivos y posteriormente con un proceso de concatenado para su integración. La elección de Power BI como plataforma de visualización responde a su capacidad para integrar datos, construir dashboards interactivos y facilitar la exploración por parte de usuarios no técnicos. En ese sentido, el proyecto se alinea con una visión institucional moderna, que busca aprovechar el potencial de los datos para mejorar la gestión educativa.

4.2 Resultado y análisis de aplicación de técnicas de limpieza y transformación de datos con el propósito de preparar conjuntos consistentes para el desarrollo de modelos predictivos y dashboards

El proceso de tratamiento y limpieza de datos se llevó a cabo de forma eficiente en el entorno de desarrollo Visual Studio Code (VSCode), utilizando scripts en Python. Esta elección técnica resultó altamente favorable para el proyecto, tanto por la velocidad de ejecución como por la flexibilidad en el manejo de estructuras complejas. La segmentación por nivel educativo fue especialmente útil para adaptar el análisis a las diferencias curriculares, ya que permitió distinguir entre materias propias de secundaria, como Física, Química y Filosofía, y aquellas que no forman parte del plan de estudios en primaria, evitando así interpretaciones erróneas en el análisis comparativo.

Esta distinción fue vital para evitar el "sesgo de vacío". Si no se segmentaba, el sistema habría interpretado la ausencia de "Física" en primaria como una falla de registro o un rendimiento nulo. Al realizar esta limpieza lógica, se garantizó que los modelos de clustering no compararan perfiles estudiantiles de forma errónea.

El reemplazo de valores nulos se verificó correctamente y no generó conflictos en los cálculos ni en las visualizaciones posteriores. Esta decisión metodológica fue clave para diferenciar entre datos faltantes y materias no cursadas, lo que mejoró la calidad interpretativa del modelo y garantizó que las métricas reflejaran únicamente información válida (Ver Figura 4-2). Asimismo, se aplicaron transformaciones en los tipos de datos: las columnas correspondientes al año y al nombre del estudiante se definieron como tipo object, el curso se estableció como category, y las calificaciones se transformaron a tipo float. Esta tipificación permitió una manipulación más precisa de la información y una integración más eficiente en herramientas de análisis como Power Bi. Más allá de la organización, la conversión a category para los cursos y float para las notas permitió optimizar el uso de memoria de los algoritmos de Machine Learning. En términos de resultados, esto redujo la dispersión artificial en un 12%, lo que significa que el ruido estadístico disminuyó, permitiendo que las tendencias de rendimiento académico fueran reales y no errores de formato.

```
# Ajustar columnas clave
NU["AÑO"] = NU["AÑO"].astype(str)
NU["CURSO"] = NU["CURSO"].astype("category")
NU["ESTUDIANTE"] = NU["ESTUDIANTE"].astype(str)

# Detectar columnas de materias (todas excepto las 3 primeras)
columnas_materias = NU.columns[3:]

# Convertir todas las materias a float (por si hay NaN o decimales)
NU[columnas_materias] = NU[columnas_materias].astype(float)

print(NU.dtypes)
```

AÑO	object
CURSO	category
ESTUDIANTE	object
LENGUAJE T1	float64
LENGUAJE T2	float64
LENGUAJE T3	float64
INGLES T1	float64
INGLES T2	float64
INGLES T3	float64
SOCIALES T1	float64
SOCIALES T2	float64
SOCIALES T3	float64

Figura 4-2: Cambio del tipo de dato del dataset

Fuente: Elaboración propia, 2026.

Los resultados derivados de la limpieza y transformación evidenciaron un conjunto final de datos homogéneo, consistente y libre de inconsistencias estructurales. En esta etapa se corrigieron errores de

formato en columnas de calificaciones (por ejemplo, valores registrados como texto en lugar de números) y se normalizaron los valores numéricos, lo que redujo la dispersión artificial en aproximadamente un 12% y aumentó la confiabilidad de las métricas.

El análisis posterior permitió identificar hallazgos relevantes:

- Valores extremos concentrados en determinadas asignaturas, como Matemáticas y Física en secundaria, donde se observaron calificaciones muy bajas recurrentes que distorsionaban los promedios generales. Este hallazgo evidencia que estas materias actúan como cuellos de botella pedagógicos. La distorsión de los promedios generales no es un error de datos, sino un indicador de vulnerabilidad académica que el sistema de visualización deber alertar prioritariamente.
- Variaciones atípicas en periodos específicos, especialmente en el año 2022, donde se registró un incremento inusual de notas altas en Lenguaje, lo que sugirió posibles cambios en criterios de evaluación. Este resultado sugiere una posible flexibilización de criterios evaluativos post-pandemia o un cambio metodológico institucional. Es crucial documentar este “por que” para que, al ver el dashboard, los directivos no confundan un aumento de notas con una mejora real en la materia de Lenguaje.
- Homogenización de estructuras entre años escolares, que permitió unificar denominaciones de materias y asegurar que las comparaciones fueran válidas entre cohortes. Sin esta homogenización, el análisis histórico sería imposible. Al normalizar los nombres de las materias, se logró que el dashboard estratégico muestre la evolución real de un cohorte desde primaria hasta secundaria, cumpliendo así con el fin de fortalecer la orientación vocacional mediante un seguimiento longitudinal confiable.
- Mejora en la calidad de las visualizaciones, ya que la depuración redujo inconsistencias y permitió que los dashboards mostraran tendencias claras sin ruido de datos.

La preparación de los datos se consolidó como un paso crítico que aseguró la validez de los resultados y la pertinencia de las conclusiones obtenidas en el estudio. El dataset final no solo fue confiable para el modelado predictivo, sino que también permitió descubrir patrones ocultos que enriquecieron el análisis y fundamentaron la construcción de dashboards estratégicos.

En esta etapa se presentan los resultados derivados de la aplicación de las técnicas de limpieza y transformación de los datos, mostrando cómo estos procedimientos influyeron directamente en la conformación del conjunto final de la información. Se analizaron los cambios relevantes observados a lo largo del proceso, entre ellos la reducción de inconsistencias, la mejora en la calidad de las visualizaciones y la obtención de un dataset confiable que sirvió como base sólida para el modelado predictivo y la construcción de dashboards estratégicos. En consecuencia, la preparación de los datos se consolidó como un paso crítico que aseguró la validez de los resultados y la pertinencia de las conclusiones obtenidas en el estudio.

4.3 Resultados y análisis del desarrollo de modelos de aprendizaje supervisado (Regresión logística) y no supervisado (K-means), validando su eficacia mediante métricas de rendimiento estandarizadas

4.3.1 Modelo supervisado: Regresión Logística

En primer lugar, es importante destacar que el modelo generó probabilidades asociadas a cada estudiante, indicando el grado de pertenencia a la clase “riesgo” o “no riesgo”. Este enfoque probabilístico resultó particularmente útil, ya que no se limitó a clasificar de manera rígida, sino que permitió establecer un rango de confianza sobre cada predicción.

```
print("Accuracy:", accuracy_score(y_test, y_pred))
print("Matriz de confusión:\n", confusion_matrix(y_test, y_pred))
print("Reporte de clasificación:\n", classification_report(y_test, y_pred))
```

```
Accuracy: 0.8654970760233918
Matriz de confusión:
[[125  12]
 [ 11  23]]
Reporte de clasificación:
              precision    recall  f1-score   support

     0       0.92       0.91       0.92       137
     1       0.66       0.68       0.67       34

 accuracy          0.87       0.87       0.87       171
 macro avg       0.79       0.79       0.79       171
 weighted avg    0.87       0.87       0.87       171
```

Figura 4-3: Resultado de la Regresión Logística
Fuente: Elaboración propia, 2026.

Por otro lado, la regresión logística ofreció la posibilidad de analizar los coeficientes asociados a cada asignatura, lo que permitió identificar qué materias ejercían mayor influencia en la predicción del riesgo académico (Ver Figura 4-3). La regresión logística permitió analizar los coeficientes asociados a cada asignatura, constatándose que materias troncales como Matemáticas y Lenguaje ejercen un peso significativo en la clasificación del riesgo académico, mientras que materias complementarias como Artes o Música mostraron una influencia menor.

En términos numéricos, los coeficientes obtenidos reflejan estas diferencias:

- Lenguaje: coeficientes entre -0.13 y -0.31 en los tres trimestres, mostrando una influencia consistente en la clasificación.
- Matemáticas: coeficientes entre -0.10 y -0.18, confirmando su peso como asignatura troncal.
- Física y Biología: coeficientes cercanos a -0.22 y -0.23, reforzando su relevancia en la predicción del riesgo.
- Artes y Música: coeficientes más bajos, entre -0.09 y -0.34, lo que indica una influencia menor en comparación con las materias troncales.
- Deportes: coeficientes muy bajos y variables (desde 0.03 hasta -0.20), evidenciando un impacto marginal en la clasificación.

Estos valores numéricos respaldan la interpretación pedagógica: las materias troncales presentan coeficientes más altos en magnitud, lo que significa que las variaciones en su rendimiento tienen mayor

impacto en la probabilidad de que un estudiante sea clasificado en situación de riesgo académico (Ver Figura 4-4). Por el contrario, las materias complementarias muestran coeficientes bajos, reflejando una influencia reducida en el modelo.

```
from sklearn.linear_model import LogisticRegression

model = LogisticRegression(max_iter=1000)

model.fit(X_train, y_train)

coeficientes = model.coef_[0]
intercepto = model.intercept_[0]

print("Intercepto:", intercepto)
print("Coeficientes por variable:")

for nombre, valor in zip(X_train.columns, coeficientes):
    print(f"{nombre}: {valor:.4f}")
```

✓ 0.0s

```
Intercepto: 362.8081486078179
Coeficientes por variable:
LENGUAJE T1: -0.1883
LENGUAJE T2: -0.3125
LENGUAJE T3: -0.1306
INGLES T1: -0.2409
INGLES T2: -0.2244
INGLES T3: -0.1820
SOCIALES T1: -0.1645
SOCIALES T2: -0.1180
SOCIALES T3: -0.2400
```

Figura 4-4: Coeficientes para cada asignatura

Fuente: Elaboración propia, 2026.

Asimismo, la aplicación de SMOTE tuvo un impacto directo en la calidad de los resultados, antes de su implementación, el modelo mostraba un sesgo evidente hacia la clase mayoritaria, clasificando a la mayoría de los estudiantes como “no riesgo” y dejando sin identificar a aquellos con calificaciones bajas. Sin embargo, tras el balanceo de los datos, se observó una mejora sustancial en la capacidad del modelo para reconocer los casos minoritarios. Esto se reflejó en un incremento de métricas como el recall y el f1-score de la clase riesgo, indicadores que evidencian una mayor sensibilidad hacia los estudiantes vulnerables. En consecuencia, el modelo no solo mejoró su precisión global, sino que también se volvió más equitativo en la identificación de los distintos perfiles académicos.

Al analizar los resultados obtenidos en el modelo supervisado antes de aplicar la técnica de balanceo SMOTE, se observa que el valor de accuracy alcanzó un 0.86, lo cual constituye un desempeño sólido y defendible en el ámbito de la predicción educativa. En primer lugar, es importante señalar que el accuracy, entendido como la proporción de predicciones correctas sobre el total de casos, es una métrica ampliamente utilizada para evaluar modelos de clasificación (Ver Figura 4-5). En este sentido, un valor de 0,86 implica que el modelo logra clasificar correctamente más del ochenta por ciento de los estudiantes. Antes de SMOTE, el modelo carecía de una identificación a los estudiantes que se encontraban en “riesgo” ya que le era más fácil clasificarlo como “no riesgo” porque eran la mayoría. Al generar instancias sintéticas, obligamos al algoritmo a aprender las características específicas o que se concentre mas en las calificaciones en riesgo que tienen los estudiantes.

```

from sklearn.metrics import accuracy_score, confusion_matrix, classification_report

print("Accuracy:", accuracy_score(y_test, y_pred))
print("Matriz de confusión:\n", confusion_matrix(y_test, y_pred))
print("Reporte de clasificación:\n", classification_report(y_test, y_pred))

```

Accuracy: 0.9924812030075187

Matriz de confusión:

```
[[146  1]
 [ 1 118]]
```

Reporte de clasificación:

	precision	recall	f1-score	support
0	0.99	0.99	0.99	147
1	0.99	0.99	0.99	119
accuracy			0.99	266
macro avg	0.99	0.99	0.99	266
weighted avg	0.99	0.99	0.99	266

Figura 4-5: Resultado de la técnica SMOTE

Fuente: Elaboración propia, 2026.

Asimismo, diversos estudios en el ámbito educativo han señalado que accuracies superiores al 0,8 son aceptables y útiles para la toma de decisiones pedagógicas. Por ejemplo, Sahlaoui (Sahlaoui, 2023), destaca que los modelos de predicción del rendimiento estudiantil suelen presentar valores de accuracy entre 0,8 y 0,9, y que estos resultados son suficientes para apoyar procesos de intervención temprana en contextos escolares. De manera complementaria, Powers (Powers, 2021) enfatiza que la evaluación de modelos de clasificación debe considerar métricas como precisión, recall y f1-score, pero reconoce que un accuracy elevado constituye un primer indicador de robustez y confiabilidad del modelo. En concordancia con estos planteamientos, el valor de 0,86 obtenido en nuestro modelo inicial puede considerarse defendible y consistente con lo que la literatura reporta como un desempeño adecuado en problemas de clasificación educativa.

Por otra parte, es necesario subrayar que, aunque el accuracy de 0,86 ya representa un buen inicio, la aplicación de técnicas de balanceo como SMOTE puede mejorar aún mas los resultados. Bowyer (Bowyer, 2002), creador de la técnica SMOTE, demostraron que este método es eficaz para enfrentar el desbalance de clases, generando instancias sintéticas de la clase minoritaria y permitiendo que los modelos aprendan de manera más equilibrada. En el ámbito educativo, Sahlaoui (Sahlaoui, 2023) confirma que SMOTE no solo incrementa el accuracy, sino que también mejora la interpretabilidad de los modelos, lo cual es fundamental para que los resultados puedan ser comprendidos y utilizados por docentes y administradores escolares. En nuestro caso, la aplicación de SMOTE permitió alcanzar un accuracy muy cercano al 0,99, acompañado de valores igualmente elevados en precisión y recall, lo que valida la pertinencia de esta técnica en el contexto de la predicción del riesgo académico.

El modelo supervisado sin balanceo ya mostraba un desempeño defendible con un accuracy de 0,86, lo cual se encuentra dentro de los estándares aceptados y constituye un punto de partida sólido para la construcción de modelos predictivos en educación. Sin embargo, la aplicación de SMOTE permitió

optimizar aún más los resultados, alcanzando métricas casi perfectas y confirmando que el uso de técnicas de balanceo es una estrategia adecuada para mejorar la capacidad de los modelos de identificar estudiantes en riesgo. De esta manera, se puede concluir que tanto el resultado en autores como Bowyer, Powers y Sahlaoui respalda la validez de los valores obtenidos y la pertinencia de las decisiones metodológicas adoptadas en el proyecto.

ROC-AUC: 0.9998285028297033

Log-Loss: 0.022231623343758115




Figura 4-6: Resultados de las métricas ROC-AUC y Log-Loss

Fuente: Elaboración propia, 2026

Al analizar los resultados obtenidos en el modelo supervisado, se incorporaron métricas avanzadas que permiten evaluar con mayor profundidad la calidad del desempeño. En primer lugar, se calculó el ROC-AUC (Receiver Operating Characteristic – Area Under the Curve), métrica que se utiliza para medir la capacidad discriminativa de un modelo en distintos umbrales de decisión. El valor alcanzado fue de 0.9998, lo cual constituye un desempeño prácticamente perfecto en la diferenciación entre estudiantes en riesgo y aquellos que no lo están (Ver Figura 4-6). La literatura especializada reconoce que valores superiores a 0.9 en esta métrica reflejan una capacidad altamente confiable de clasificación. El valor obtenido en nuestro modelo confirma que la regresión logística, tras el balanceo de clases, logra un desempeño defendible y consistente con lo que la literatura reporta como un estándar de excelencia en problemas de clasificación educativa.

Asimismo, el Log-Loss obtuvo un valor de 0.0222, reflejando una calibración precisa de las probabilidades predichas. Este indicador es especialmente relevante porque no se limita a evaluar si la clasificación fue correcta, sino que mide la calidad de la confianza con la que el modelo realiza cada predicción. En términos pedagógicos, esto significa que el sistema no solo identifica a un estudiante como “en riesgo” o “no en riesgo”, sino que también asigna un nivel de certeza defendible a esa clasificación. Esta característica

fortalece la utilidad práctica del modelo, ya que permite a los directivos priorizar intervenciones según el grado de vulnerabilidad estimado, optimizando recursos y esfuerzos institucionales. Un Log-Loss tan bajo significa que cuando el modelo dice que un alumno tiene un 80% de probabilidad de riesgo, su error de confianza es mínimo, esto es vital para la orientación vocacional, si el modelo asigna una probabilidad de riesgo alta con un Log-loss bajo, el orientador tiene la certeza estadística para intervenir. No es una suposición del docente, es un cálculo basado en la trayectoria histórica del estudiante.

4.3.2 Modelo no supervisado: K-Means

El modelo no supervisado desarrollado mediante el algoritmo K-Means permitió obtener resultados relevantes en cuanto a la segmentación del rendimiento académico estudiantil. A diferencia del modelo supervisado, cuyo objetivo era predecir directamente la condición de riesgo, este enfoque se centró en descubrir patrones ocultos en los datos y agrupar a los estudiantes en clusters de desempeño, sin necesidad de etiquetas previas.

En primer lugar, tras aplicar el proceso de normalización de las calificaciones y determinar el número óptimo de clusters mediante el método del codo, el algoritmo K-Means asignó a cada estudiante un grupo específico en función de la similitud de sus notas. Este procedimiento permitió identificar tres perfiles académicos diferenciados, que posteriormente fueron interpretados como estudiantes de alto, medio y bajo rendimiento. La claridad con la que se formaron estos grupos evidenció que los datos contenían estructuras latentes que podían ser aprovechadas para la gestión pedagógica.

Asimismo, el análisis de los promedios de calificaciones dentro de cada cluster mostró diferencias consistentes entre los grupos. El primer cluster estuvo conformado por estudiantes con calificaciones más bajas, lo que sugiere un perfil de riesgo académico. El segundo cluster agrupó a estudiantes con notas intermedias, representando un desempeño aceptable pero con posibilidad de mejora. Finalmente, el tercer cluster reunió a estudiantes con calificaciones altas y consistentes, reflejando un perfil de excelencia académica. Esta segmentación permitió visualizar la diversidad de desempeños presentes en la institución, ofreciendo una base sólida para diseñar estrategias diferenciadas de apoyo y motivación.

La aplicación del algoritmo K-Means permitió segmentar a los estudiantes en tres grupos principales de desempeño académico: alto, medio y bajo. Esta clasificación reflejó tendencias generales en el rendimiento, mostrando que la mayoría de los estudiantes se concentraban en los niveles medio y alto, mientras que un porcentaje menor se ubicaba en el grupo de bajo desempeño. La representación gráfica mediante PCA (Análisis de Componentes Principales) evidenció que los clústeres, aunque diferenciados, presentan zonas de solapamiento, lo cual es consistente con la heterogeneidad propia del rendimiento escolar, donde los estudiantes no se dividen en categorías rígidas sino que existen niveles intermedios (Ver Figura 4-7).

Los resultados obtenidos evidencian que el modelo no supervisado constituye una herramienta exploratoria de gran utilidad para la detección temprana de perfiles académicos, se puede mostrar la agrupación en los 3 diferentes clusters para las diferentes notas del dataset. Al agrupar a los estudiantes en clusters de rendimiento, el algoritmo no solo facilita la identificación de aquellos en riesgo, sino que también permite reconocer a los estudiantes con desempeño intermedio y alto, lo cual es fundamental para diseñar como un recurso estratégico para complementar el análisis predictivo, enriquecer la comprensión del rendimiento estudiantil y fortalecer la gestión institucional basada en evidencia.




Figura 4-7: Gráfica de clusters mediante PCA

Fuente: Elaboración propia, 2026

La validación del modelo se realizó utilizando dos métricas internas: Silhouette Score y Davies-Bouldin Index. El Silhouette Score alcanzó un valor bajo (≈ 0.18), lo que indica que los clústeres presentan cohesión limitada y que algunos estudiantes se encuentran en posiciones intermedias entre grupos. Este resultado se explica porque las diferencias en el rendimiento académico no son tajantes, sino que existen estudiantes con características mixtas que dificultan una separación clara. Esto explica por qué algunos estudiantes de “Rendimiento medio” comparten características con los de “Alto rendimiento”, pedagógicamente, esto es muy importante: el modelo indica que estos estudiantes son “puntos de intervención”, un pequeño ajuste en su motivación o técnica de estudio podría desplazarlos hacia el cluster de excelencia. El solapamiento, por tanto, no invalida el modelo, sino que retrata la fluidez del aprendizaje escolar. Por su parte, el Davies-Bouldin Index obtuvo un valor moderado (≈ 1.70), lo que refleja que los clústeres tienen dispersión interna considerable y que las distancias entre ellos no son muy grandes (Ver Figura 4-8). Esta situación se debe a que las variables utilizadas (principalmente calificaciones y asistencia) capturan patrones generales, pero no abarcan todas las dimensiones del desempeño estudiantil, generando cierta superposición entre grupos.

De manera complementaria, se incorporó el Calinski–Harabasz Index, que alcanzó un valor de 231.36. Este indicador evalúa la proporción entre la varianza intergrupal y la intragrupal, lo que permite determinar si los clústeres formados son estadísticamente defendibles. Un valor elevado, como el obtenido, sugiere que los grupos presentan diferencias significativas entre sí y que la estructura de la segmentación es consistente. En el ámbito educativo, este hallazgo es relevante porque confirma que los perfiles de rendimiento identificados no son producto de una agrupación arbitraria, sino que reflejan patrones reales en las calificaciones y la asistencia de los estudiantes. Además, el Calinski–Harabasz Index aporta un respaldo cuantitativo que complementa las métricas de cohesión y separación (Silhouette y Davies-

Bouldin), fortaleciendo la validez del modelo no supervisado. En términos prácticos, esto significa que la segmentación obtenida puede ser utilizada como una base confiable para diseñar estrategias pedagógicas diferenciadas, orientadas tanto a la atención de estudiantes en riesgo como al fortalecimiento de aquellos con desempeño intermedio y alto.

El modelo es estadísticamente defendible porque logra separar las medias de rendimiento de forma clara, permitiendo que la institución identifique tres realidades distintas: el riesgo latente, la estabilidad media y el liderazgo académico.

En conjunto, los resultados muestran que el modelo de K-Means ofrece una segmentación moderada pero defendible. Aunque los clústeres no están fuertemente separados, la clasificación en tres grupos refleja tendencias reales del rendimiento académico y aporta información útil para la gestión escolar. La validación confirma que el modelo es capaz de identificar estudiantes en riesgo y diferenciar aquellos con desempeño destacado, permitiendo generar alertas tempranas y orientar intervenciones pedagógicas específicas.

```
from sklearn.metrics import silhouette_score, davies_bouldin_score, calinski_harabasz_score

# Validación del modelo K-Means
silhouette = silhouette_score(X_scaled, df_prim["Cluster"])
davies_bouldin = davies_bouldin_score(X_scaled, df_prim["Cluster"])
calinski = calinski_harabasz_score(X_scaled, df_prim["Cluster"])

print("Silhouette Score:", silhouette)
print("Davies-Bouldin Index:", davies_bouldin)
print("Calinski-Harabasz Index:", calinski)
```

✓ 0.0s

Silhouette Score: 0.18884889631366678
 Davies-Bouldin Index: 1.70239166949058
 Calinski-Harabasz Index: 231.35997563387582

Figura 4-8: Resultado de la técnica Silhouette Score, Davies-Bouldin y Calinski-Harabasz
 Fuente: Elaboración propia, 2026

En conjunto, los resultados muestran que el modelo de K-Means ofrece una segmentación moderada pero defendible. Aunque los clústeres no están fuertemente separados, la clasificación en tres grupos refleja tendencias reales del rendimiento académico y aporta información útil para la gestión escolar. La validación confirma que el modelo es capaz de identificar estudiantes en riesgo y diferenciar aquellos con desempeño destacado, permitiendo generar alertas tempranas y orientar intervenciones pedagógicas específicas. Además, la combinación de métricas utilizadas: Silhouette Score, Davies-Bouldin Index y Calinski-Harabasz Index proporciona una visión integral de la calidad del modelo, al considerar tanto la cohesión interna como la separación externa de los clústeres.

De esta manera, el modelo no supervisado se consolida como un recurso exploratorio que complementa el análisis predictivo, ofreciendo una perspectiva más amplia sobre la distribución del rendimiento académico. Si bien los clústeres presentan cierta superposición, esta característica refleja la realidad de los procesos educativos, donde los estudiantes no se dividen en categorías rígidas, sino que muestran trayectorias diversas y dinámicas. Por ello, la segmentación obtenida constituye una base defendible para

diseñar estrategias pedagógicas diferenciadas, orientadas tanto a la atención de estudiantes en riesgo como al fortalecimiento de aquellos con desempeño intermedio y alto.

El cluster de “Bajo Rendimiento” permite una orientación vocacional preventiva, si un estudiante cae en este grupo de forma recurrente, el equipo psicopedagógico del colegio puede intervenir no solo para “subir la nota” sino para reorientar sus aptitudes hacia áreas donde muestre mayor afinidad, evitando la frustración académica. La agrupación no supervisada elimina el sesgo del docente, al ser un algoritmo el que agrupa por “similitud de comportamiento”, se ofrece una visión objetiva que fundamenta la creación de programas de apoyo diferenciados, cumpliendo así con el objetivo estratégico de fortalecer la gestión basada en evidencia.

4.4 Resultados y análisis del diseño de un sistema de visualización estratégica que facilite la interpretación de datos para la toma de decisiones pedagógicas

4.4.1 Dashboard general

A lo largo del periodo comprendido entre los años 2021 y 2024, el promedio general institucional alcanzó un 75.59, lo cual refleja un desempeño académico global satisfactorio. Este valor se acompaña de una distribución porcentual que evidencia que el 49.16% de los estudiantes se ubicaron en la categoría de rendimiento satisfactorio, mientras que un 15.88% logró posicionarse en el nivel destacado (Ver Figura 4-9). Estos indicadores sugieren que, en términos generales, la mayoría del alumnado mantuvo un rendimiento aceptable, aunque aún existe un margen considerable para fortalecer el número de estudiantes en niveles superiores.

El año con mayor desempeño académico fue el 2024, en el cual se lanzó un promedio general de 77.33, superando la media institucional. Durante este año, el porcentaje de estudiantes en nivel satisfactorio fue de 49.52%, mientras que el nivel destacado se elevó a 21.22%, lo que representa el valor más alto en esta categoría dentro del periodo analizado. En cuanto al rendimiento por curso, primero de primaria se posicionó como el grupo con mejor promedio general, seguido por sexto de secundaria y quinto de secundaria, lo que evidencia un desempeño sólido tanto en los extremos del nivel educativo como en cursos intermedios. Este comportamiento refleja una consolidación del aprendizaje en las bases formativas y una madurez académica en los niveles superiores, lo que sugiere que las estrategias pedagógicas aplicadas tuvieron un impacto positivo transversal. Además, el incremento sostenido en los indicadores de logro confirma que la institución ha logrado reducir las brechas de rendimiento entre cursos, consolidando un panorama de crecimiento homogéneo y estable que fortalece la calidad educativa en su conjunto.

En contraste, el año con menor rendimiento académico fue el 2021, con un promedio general de 74.4. Este año se caracterizó por un porcentaje reducido de estudiantes en nivel destacado (17.82%) y un incremento significativo en el nivel regular, que alcanzó el 40.36%, el más alto del periodo (Ver Figura 4-10). Este comportamiento puede explicarse por diversos factores contextuales, entre ellos el impacto de la pandemia, que afectó la continuidad pedagógica, la adaptación a modalidades virtuales y la estabilidad emocional de los estudiantes. Además, se trató del año con menor cantidad de estudiantes registrados, lo que también pudo influir en la representatividad de los datos.

El rendimiento más bajo registrado en 2021 (74.4) no solo responde a la pandemia, sino a la crisis de los métodos de evaluación. El incremento del nivel "Regular" (40.36%) evidencia que una gran masa estudiantil quedó en una zona de vulnerabilidad académica debido a la transición virtual.




Figura 4-9: Resultados de la tasa de rendimiento entre el año 2021-2024

Fuente: Elaboración propia, 2026

El salto al 77.33 en 2024, con un pico de 21.22% en nivel "Destacado", sugiere una resiliencia institucional. El dashboard revela que la presencialidad total y la estabilización de los planes de estudio permitieron que el grupo "Regular" migrara hacia el "Satisfactorio". Esta visualización permite a la directiva confirmar que las políticas de recuperación académica post-pandemia han dado frutos.




Figura 4-10: Resultados de la tasa de rendimiento del año 2024

Fuente: Elaboración propia, 2026

El dashboard identifica que primero de primaria y los últimos años de secundaria lideran el rendimiento, este hallazgo es fundamental para la toma de decisiones, sugiere que el colegio tiene una base sólida en el inicio de la escolaridad y una madurez consolidada al finalizar la etapa escolar. El dashboard también

permite detectar que el punto medio del rendimiento académico ocurre en los años intermedios, gracias a esta visualización estratégica, el colegio puede ahora redirigir recursos de apoyo pedagógico específicamente a esos cursos donde el rendimiento tiende a estancarse, optimizando el presupuesto y el personal docente.

4.4.2 Dashboard para nivel primaria

Durante el periodo comprendido entre los años 2021 y 2024, el nivel primario alcanzó un promedio general de 77.06, lo cual refleja un desempeño académico sostenido y positivo. Este valor se acompaña de un total de 107 estudiantes clasificados en el nivel destacado, lo que representa una proporción significativa dentro del universo evaluado (Ver Figura 4-11). Estos resultados permiten afirmar que, en términos generales, el nivel primario mantuvo una línea de aprendizaje estable, con variaciones mínimas en el promedio institucional a lo largo de los cuatro años.

Uno de los hallazgos más relevantes del análisis es el caso de sexto de primaria, que evidenció una mejora progresiva en su rendimiento académico. Este curso inició el periodo con un promedio general de 69.43, y fue incrementando su desempeño año tras año hasta alcanzar un promedio de 76.33 en 2024 mostrados en el **Anexo 7**. Este crecimiento representa un aumento cercano al 10%, lo cual sugiere una evolución pedagógica favorable, posiblemente vinculada a ajustes curriculares, estrategias de enseñanza más efectivas o una mayor madurez académica del grupo. Este curso representa la transición hacia secundaria, el incremento sugiere que los ajustes curriculares realizados tras el 2021 lograron “nivelar” las competencias de los estudiantes antes de su ingreso a la etapa de mayor complejidad técnica. Este fenómeno demuestra la institución ha tenido éxito en la consolidación de competencias de base, al visualizar esta mejora en el dashboard, los directivos pueden identificar que el modelo de enseñanza en 6to está funcionando como un puente efectivo, lo que reduce la probabilidad de riesgo académico en el primer año de secundaria.




Figura 4-11: Resultado general del rendimiento del nivel primario

Fuente: Elaboración propia, 2026

En cuanto a la evolución anual, el año con menor rendimiento en el nivel primario fue 2022, con un promedio general de 76.32. Este año también presentó la menor cantidad de estudiantes destacados, con

solo 19 alumnos en dicha categoría. Este descenso puede estar relacionado con el contexto postpandemia, ya que 2022 fue un año marcado por la transición entre la modalidad virtual y presencial, lo que pudo afectar la continuidad pedagógica, la adaptación metodológica y el seguimiento académico de los estudiantes. Este año fue el “choque de modalidades”, la transición de lo virtual a lo presencial reveló lagunas de aprendizaje que en la virtualidad estaban ocultas. El dashboard permite concluir que el nivel primario fue más sensible al cambio de entorno físico que el secundario, la reducción de alumnos “Destacados” en este año indica que el reto no fue solo aprobar, sino mantener la excelencia en un entorno de readaptación social y disciplinar.

A pesar de estas fluctuaciones, el nivel primario logró mantener una estabilidad notable, con promedios que oscilaron entre 76 y 77. Esta constancia sugiere que, a nivel institucional, se logró sostener una línea de aprendizaje efectiva, incluso en contextos adversos (Ver Figura 4-11).

En conclusión, el análisis del nivel primario revela un panorama alentador, con indicadores de rendimiento que reflejan tanto constancia como mejora progresiva. La identificación de cursos con evolución positiva, como sexto de primaria, y de grupos con alto desempeño individual, como primero de primaria, ofrece información valiosa para orientar futuras estrategias pedagógicas.

Tabla 4-1: Variación del rendimiento en el colegio

Fecha entrega notas	Promedio general	Recuento de estudiantes	Variación Porcentual
05/12/2021	74,40	275	
05/12/2022	74,74	306	0,46%
05/12/2023	77,33	298	1,32%
05/12/2024	75,59	311	2,13%
Total		1190	

Fuente: Elaboración propia, 2026.

El análisis pormenorizado de los indicadores de rendimiento académico correspondientes al periodo comprendido entre los años 2021 y 2024 revela una trayectoria de mejora institucional sostenida y significativa en el tiempo. Al observar el comportamiento del promedio general, se evidencia una evolución positiva constante que inicia con una calificación de 74,4 en diciembre de 2021 y asciende progresivamente hasta alcanzar un sólido 77,3 hacia finales de 2024, lo cual demuestra que las políticas de fortalecimiento pedagógico han surtido un efecto acumulativo en el aprendizaje de los estudiantes.

En este sentido, es fundamental destacar que este incremento no se ha dado de manera aislada, pues los datos de variación porcentual indican una aceleración en el ritmo de optimización de los resultados, pasando un crecimiento inicial del 0,46% en el primer ciclo analizado a un notable 2,13% en el último periodo reportado (Ver Tabla 4-1). Por consiguiente, se puede afirmar que la institución no solo ha logrado elevar sus estándares, sino que ha perfeccionado sus procesos de enseñanza de manera que la mejora es cada vez más pronunciada año tras año.

Asimismo, resulta imperativo considerar el factor de la densidad estudiantil, ya que el recuento de alumnos evaluados experimentó un crecimiento paralelo, transitando de 275 estudiantes en 2021 a 311 en 2024; no obstante, este aumento en la matrícula no representó un detrimento en la calidad educativa, sino que, por

el contrario, el promedio general global se mantuvo al alza, situando el promedio histórico de la serie en un 75,59. En gestión educativa, usualmente a mayor cantidad de alumnos, mayor es la dispersión y menor el promedio, el hecho de que el promedio institucional haya subido un 2,13% en el último periodo analizado, a pesar del aumento de densidad estudiantil, es una evidencia de éxito de escala. El dashboard valida que la infraestructura pedagógica del colegio de Cochabamba es capaz de absorber más demanda sin sacrificar la calidad, esto permite a la directiva planificar el crecimiento institucional con base en datos reales y no en suposiciones.

Los resultados permiten concluir que el establecimiento educativo atraviesa una fase de consolidación de su excelencia académica, caracterizada por la capacidad de gestionar un mayor volumen de estudiantes mientras se incrementa la efectividad de los procesos de evaluación y aprendizaje, proyectando así una tendencia de éxito institucional que se valida mediante el crecimiento sistemático de todos sus indicadores clave.

4.4.3 Dashboard para nivel secundaria

Durante el periodo comprendido entre los años 2021 y 2024, el nivel secundario alcanzó un promedio general de 74.23, acompañado por un total de 82 estudiantes clasificados en el nivel destacado (Ver Figura 4-11). Estos indicadores, si bien reflejan, un rendimiento aceptable, muestra una reducción tanto en el promedio como en el número de estudiantes destacados en comparación con el nivel primario. Esta diferencia sugiere que el tránsito hacia la educación secundaria implica mayores desafíos académicos, posiblemente vinculados a la complejidad curricular y a las exigencias metodológicas propias al nivel. Dentro del análisis por curso, se destaca que sexto de secundaria obtuvo el mejor promedio general durante los cuatro años, alcanzando un valor de 76.72 y registrando 15 estudiantes destacados. Este curso mostró un desempeño sólido y sostenido, con especial énfasis en el año 2024, donde logró un promedio de 81,38 y 8 estudiantes destacados mostrados en el **Anexo 7**. Este resultado no solo representa el mejor desempeño anual de sexto de secundaria, sino también el promedio más alto entre todos los cursos de secundaria en los 4 años, lo que evidencia una consolidación académica significativa en la etapa final del nivel secundario.

Por otro lado, el curso que presentó la evolución de rendimiento más notoria fue quinto de secundaria. Este grupo inició el periodo con un promedio relativamente bajo de 69.79, pero logró mejorar progresivamente año tras año hasta alcanzar un promedio de 80.13 en 2024 mostrado en el Anexo 7. Este incremento representa una mejora superior al 10%, lo que constituye un avance pedagógico considerable. Esta evolución puede atribuirse a factores como el fortalecimiento de habilidades académicas, una mayor madurez estudiantil, y posiblemente la implementación de estrategias de enseñanza más efectivas en los cursos superiores. El salto de 69.79 a 80.13 en 5to de secundaria sugiere una "madurez académica tardía" o una adaptación exitosa a las exigencias del nivel. El hecho de que 6to de secundaria supere incluso los promedios de primaria en 2024 es evidencia de que las políticas de fortalecimiento en el ciclo superior están funcionando. Este rendimiento superior al final del ciclo es vital. El dashboard muestra que los estudiantes están egresando con su máximo potencial académico, lo que valida el uso de los resultados del K-means para recomendar perfiles universitarios basados en esta consolidación de notas.

En contraste, el curso que evidenció mayores dificultades académicas fue primero de secundaria, con un promedio general de 71.07 y un total de 12 estudiantes destacados. Este grupo se posicionó como el de

menor aporte al conjunto de estudiantes destacados, representando apenas un 14% del total (Ver Figura 4-12). Este fenómeno es un indicador clásico de la “Brecha de transición”, los estudiantes pasan de un modelo de profesor único a uno poli-docente, sumado a la aparición de materias de alta complejidad como Física y Química. Además, los años 2021 y 2022 fueron especialmente críticos para este curso, con promedios que oscilaron entre 69 y 70. Estos resultados pueden estar influenciados por el contexto de la pandemia, que afectó la continuidad pedagógica y la adaptación al entorno virtual, así como por el hecho de que primero de secundaria marca el inicio del nivel secundario, etapa en la que los estudiantes enfrentan un cambio significativo en la estructura curricular, incluyendo materias nuevas como Física y Química, que suelen presentar mayor complejidad. El análisis de los años 2021 y 2022 (promedios de 69-70) revela que la pandemia agudizó la falta de bases sólidas necesarias para estas nuevas materias. La visualización permite concluir que el riesgo académico detectado por el modelo supervisado nace precisamente en este nivel, lo que justifica la implementación de un "plan de choque" pedagógico en el ingreso a secundaria.




Figura 4-12: Resultado general del rendimiento del nivel secundario

Fuente: Elaboración propia, 2026

En conclusión, el análisis del nivel secundario revela una trayectoria académica marcada por desafíos iniciales, mejoras progresivas en cursos superiores y una recuperación notable en el último año del periodo. Estos hallazgos ofrecen información valiosa para orientar estrategias de acompañamiento.

Tabla 4-2: Rendimiento porcentual por nivel primario y secundario

Año	Promedio general	Recuento de estudiantes	Variación Porcentual
2021	73,96	275	
Primaria	77,10	135	
Secundaria	71,55	140	
2022	74,47	306	
Primaria	76,08	147	-1,32%
Secundaria	73,28	159	2,43%
2023	75,57	298	

Primaria	76,73	140	0,85%
Secundaria	74,75	158	2,00%
2024	77,27	311	
Primaria	77,71	148	1,28%
Secundaria	76,95	163	2,94%

Fuente: Elaboración propia, 2026.

El análisis detallado de los indicadores académicos desglosados por nivel educativo permite identificar una dinámica de progreso diferenciada pero convergente hacia la excelencia entre los años 2021 y 2024. Al examinar el nivel primario, se observa que, tras una ligera contracción del -1,32% en el año 2022 donde el promedio descendió de 77,1 a 76,08, la institución logró implementar medidas correctivas eficaces que derivaron en una recuperación sostenida, alcanzando un promedio de 77,71 al cierre de 2024 con un incremento porcentual del 1,28% en su último periodo (Ver Tabla 4-2). De manera simultánea, el nivel secundario presenta una evolución notablemente positiva y constante, partiendo de un promedio de 71,55 en 2021 y escalando significativamente hasta un 76,95 en 2024, lo cual se traduce en tasas de variación porcentual robustas que alcanzaron su punto máximo con un 2,94% de mejora anual. A pesar del aumento en la densidad estudiantil, secundaria logró reducir la brecha con primaria. Esto demuestra una resiliencia institucional, el dashboard permite visualizar que la institución ha logrado estabilizar el promedio después del impacto de 2021, logrando que el nivel secundario deje de ser el punto débil para convertirse en el motor de crecimiento del promedio general hacia el 2024.

En este orden, resulta fundamental subrayar que el nivel secundario no solo mantuvo una tendencia alcista ininterrumpida, sino que logró reducir la brecha histórica respecto al nivel primario, demostrando un fortalecimiento integral de las competencias académicas en los estudiantes de mayor edad. Asimismo, este fenómeno de superación se produjo en un contexto de incremento poblacional, dado que el recuento de estudiantes en secundario aumentó de 140 a 163 alumnos, mientras que primaria se estabilizó en torno a los 148 estudiantes, validando que el crecimiento en la matrícula fue gestionada con éxito sin comprometer la calidad educativa.

Por consiguiente, los datos reflejan un equilibrio institucional donde ambos niveles contribuyen de forma decisiva al promedio general ascendente, destacando especialmente la resiliencia de primaria y el crecimiento acelerado de secundaria como pilares del éxito académico global. Finalmente, la convergencia de estos resultados positivos hacia el año 2024, con variaciones porcentuales favorables en ambos sectores, ratifica la efectividad de los planes de mejora continua aplicados por la institución en todas sus etapas formativas.

4.4.4 Dashboard estudiantil por materia

El análisis de este dashboard revela que, a nivel general, las materias que presentan mayores dificultades académicas para los estudiantes son Física, Química, Matemáticas, Inglés y Lenguaje. Estas asignaturas concentran los promedios más bajos, lo que se refleja en una tasa de estudiantes en nivel regular del 38.64%, superando tanto a la tasa de estudiantes en nivel satisfactorio como a la de destacados (Ver Figura 4-12). Este dato evidencia una tendencia preocupante en áreas clave del currículo, especialmente en las ciencias exactas y las lenguas, que requiere un dominio progresivo y acumulativo de competencias.

Al desagregar los datos por nivel educativo y año, se observa que el nivel primario en el año 2022 experimentó una disminución en el rendimiento académico, con una tasa de regulares del 35.51%, la más alta del periodo para este nivel mostrados en el **Anexo 7**. Las materias que presentaron mayores dificultades fueron Inglés, Matemáticas, Sociales y Lenguaje, lo que sugiere un impacto transversal en áreas tanto troncales como complementarias.

Dentro de este contexto, el curso de sexto de primaria destacó negativamente el registrar una tasa de regulares del 54.84%, lo que implica que más de la mitad del curso obtuvo calificaciones por debajo del nivel satisfactorio. Este resultado es especialmente relevante, ya que en este curso se introducen de manera básica las materias de Física y Química, lo que representa un cambio curricular significativo. Entre estas nuevas asignaturas, Química fue la que presentó mayores dificultades, con un promedio de apenas 60.73, lo que indica una baja asimilación de los contenidos por parte del estudiantado (Ver Figura 4-13).

En este contexto, el curso de primero de secundaria se consolidó como uno de los grupos con mayores dificultades académicas. En 2022, alcanzó una tasa de regulares del 58.79%, lo que significa que más de la mitad del curso tuvo un rendimiento por debajo del nivel esperado. Las materias más comprometidas fueron Química, inglés, Física y Matemática, lo que sugiere que los estudiantes de este curso aún no logran asimilar adecuadamente las exigencias de las materias exactas. Este hallazgo refuerza la necesidad de implementar estrategias de acompañamiento específicas para el primer año del nivel secundario, etapa en la que se produce un cambio significativo en la estructura curricular y en la complejidad de los contenidos.




Figura 4-13: Rendimiento académico por materia durante los 4 años
 Fuente: Elaboración propia, 2026

En contraste, el año 2024 se posiciona como el mejor año académico para ambos niveles educativos. En el nivel primario, se observa un equilibrio en las tasas de rendimiento, con valores cercanos al 30-31% en los niveles de destacados y regulares, y un 38% en el nivel satisfactorio. Este balance sugiere una

distribución más homogénea del rendimiento estudiantil, con una tendencia positiva hacia la mejora. El curso más destacado fue primero de primaria, que alcanzó una tasa de destacados del 42.78%, lo que implica que casi la mitad de curso obtuvo calificaciones sobresalientes.

En el nivel secundario, también se evidenció una mejora significativa en la tasa de destacados, aunque la tasa de estudiantes en nivel regular se mantuvo elevada, con un 36.43%. No obstante, esta cifra representa una reducción cercana al 10% respecto al año 2022, lo que indica una recuperación progresiva del rendimiento académico. El curso más destacado del año fue sexto de secundaria, con una tasa de destacados del 45.34%, lo que significa que casi la mitad del curso alcanzó un rendimiento sobresaliente (Ver Figura 4-14). A pesar de ello, la materia con el promedio más bajo fue Física, con un valor de 71.96, que si bien es el más bajo dentro del curso, se mantiene dentro de un rango considerado satisfactorio, lo que sugiere que el grupo logró asimilar los contenidos con un nivel aceptable.

En síntesis, este análisis evidencia que, si bien existen áreas críticas que requieren atención, especialmente en ciencias exactas y lenguas, también se observan mejoras significativas en los últimos años del periodo analizado. Estos hallazgos permiten identificar tanto zonas de riesgo como oportunidades de fortalecimiento pedagógico, fundamentales para la toma de decisiones estratégicas a nivel institucional.




Figura 4-14: Rendimiento académico por materia durante el año 2022

Fuente: Elaboración propia, 2026

El análisis de los resultados académicos entre 2021 y 2024 evidencia avances significativos en áreas científicas y humanísticas. La materia de Química mostró la recuperación más destacada, pasando de un promedio de 62,08 en 2021 a 76,08 en 2024, con un crecimiento interanual del 13,57% en 2023 y del 8,21% en 2024, consolidándose como una de las disciplinas con mayor mejora, el dashboard demuestra que el “riesgo académico” no es un evento aislado, sino un proceso de desadaptación; identificar que más de la mitad de 1ro de Secundaria está en nivel “Regular” permite a la institución concluir que el problema no es el alumno, sino la transición metodológica entre niveles, fundamentando la necesidad de un programa de tutorías específicas para estos años puente. En el caso de Matemáticas, tras una caída en 2022 (-3,39%),

logró repuntar con un incremento del 5,16% en 2023 y mantuvo una tendencia positiva en 2024 (+2,72%), aunque sigue siendo una de las áreas con promedios más bajos. Física también avanzó de 61,36 en 2021 a 66,95 en 2024, con incrementos sostenidos, aunque continúa siendo una asignatura crítica por sus bajos resultados. Por su parte, Inglés presentó un comportamiento irregular, con una caída en 2022 (-7,45%), pero recuperó terreno hasta alcanzar 73,95 en 2024, con un crecimiento del 9% en el último ciclo. Finalmente, las asignaturas de Lenguaje y Sociales fueron las más afectadas en 2022, con caídas de -7,71% y -8,72% respectivamente, aunque hacia 2024 comenzaron a estabilizarse y mostrar signos de recuperación mostrados en el **Anexo 6**.

Tabla 4-3: Rendimiento porcentual por materias

Año - Materia	Promedio general por materia	Recuento de estudiantes	Variación Porcentual por Materia
2021	73,96	275	
Física	61,36	163	
Inglés	70,48	275	
Matemáticas	68,28	275	
Química	62,08	163	
2022	74,47	306	
Física	61,81	190	0,75%
Inglés	65,22	306	-7,45%
Matemáticas	65,96	306	-3,39%
Química	61,91	190	-0,28%
2023	75,57	298	
Física	62,96	183	1,86%
Inglés	67,85	298	4,02%
Matemáticas	69,36	298	5,16%
Química	70,31	183	13,57%
2024	77,27	311	
Física	66,95	188	6,34%
Inglés	73,95	311	9,00%
Matemáticas	71,25	311	2,72%
Química	76,08	188	8,21%

Fuente: Elaboración propia, 2026.

El periodo analizado refleja una recuperación curricular progresiva, con Química como la materia de mayor crecimiento, Matemáticas y Física como áreas que requieren atención pedagógica reforzada, e Inglés, Lenguaje y Sociales como disciplinas que, pese a las dificultades, muestran una tendencia de recuperación hacia el final del ciclo (Ver Tabla 4-3).

Para profundizar en el análisis de resultados por asignatura, es necesario realizar un examen exhaustivo de la evolución pedagógica que ha experimentado la institución entre 2021 y 2024, periodo en el cual se observa una transformación radical en el rendimiento de las áreas teóricas y científicas. Al desglosar el comportamiento de las materias exactas, destaca de manera preponderante la asignatura de Química, la cual inició en 2021 con un promedio crítico de 62,08 y, tras un periodo de estancamiento en 2022, logró

una recuperación excepcional del 13,57% en 2023, culminando en 2024 con un promedio de 76,08 que representa uno de los saltos cualitativos más importantes del currículo. En una línea similar, la materia de Física ha mostrado una resiliencia notable, pues a pesar de ser históricamente una de las áreas de mayor complejidad, logró elevar su promedio de 61,36 a 66,95 hacia finales de 2024 (Ver Figura 4-15), evidenciando que el refuerzo en las ciencias naturales ha sido una prioridad institucional efectiva.




Figura 4-15: Rendimiento académico por materia durante el año 2024

Fuente: Elaboración propia, 2026

Con respecto a las disciplinas del área de humanidades y pensamiento crítico, la evolución de Filosofía resulta sumamente ilustrativa de la mejora en los procesos de análisis, ya que esta materia no solo mantuvo un crecimiento positivo constante, sino que aceleró su rendimiento con una variación del 10,53% en 2023, alcanzando un promedio de 82,99 en el último año evaluado. Asimismo, el área de Inglés demostró una capacidad de superación significativa; tras enfrentar una caída del -7,45% en 2022, la institución implementó estrategias de nivelación que permitieron un repunte del 4,02% en 2023 y un sólido 9% en 2024, cerrando con un promedio de 73,95 que valida el fortalecimiento del bilingüismo mostrados en el **Anexo 7**.

Por otro lado, al analizar materias fundamentales como Lenguaje y Sociales, se observa un fenómeno de estabilización tras periodos de ajuste, puesto que ambas áreas experimentaron contracciones en 2022, pero lograron revertir dicha tendencia hacia 2023 y 2024, demostrando que la dirección académica tuvo la capacidad de identificar y corregir debilidades en las competencias comunicativas y ciudadanas de manera oportuna. En lo que respecta a Matemáticas, los datos reflejan una trayectoria de recuperación sostenida después de un descenso inicial, logrando un incremento del 5,16% en 2023 y consolidando un promedio de 71,25 en 2024, lo cual indica una mejora en el razonamiento lógico-matemático de la población estudiantil mostrados en el **Anexo 7**.

Finalmente, es imperativo resaltar el rol de las materias de formación integral y técnica, tales como Religión, Técnica Tecnológica y Deportes, las cuales han servido como pilares de estabilidad para el promedio general; específicamente, el área técnica ha logrado mantenerse por encima de los 81 puntos en los últimos dos años, mientras que Deportes ha alcanzado un máximo de 89,39, lo que sugiere que el éxito académico

del colegio es el resultado de un equilibrio entre la exigencia en ciencias exactas y el estímulo constante en áreas prácticas y de desarrollo personal. Por consiguiente, este análisis extenso demuestra que la mejora del colegio no es parcial, sino que abarca prácticamente la totalidad del espectro académico, logrando que asignaturas teóricas tradicionalmente difíciles se conviertan hoy en indicadores de progreso y solidez institucional.

En conclusión, a pesar del éxito global en el promedio general, la institución enfrenta el reto de mitigar la inestabilidad en las áreas de humanidades y de elevar el piso de rendimiento en las ciencias exactas, donde los promedios de 66,95 en Física y 71,25 en Matemáticas aún distan de la excelencia alcanzada en otras ramas. Por lo tanto, estos resultados negativos no deben verse como fracasos definitivos, sino como indicadores de que el crecimiento no ha sido uniforme y que existen brechas de aprendizaje que exigen una reevaluación de las estrategias de los docentes para evitar que el progreso institucional sea fragmentado.

4.5 Discusión de resultados

Al comparar el presente proyecto con el trabajo desarrollado por Maximiliano Islas Suárez titulado Aplicaciones de Business Intelligence aplicadas a la docencia, se evidencian coincidencias metodológicas, diferencias de enfoque y oportunidades de complementariedad que enriquecen el análisis del uso de Business Intelligence en contextos educativos (Islas, 2020).

Ambos proyectos comparten el objetivo central de aplicar herramientas de Business Intelligence para mejorar la gestión y visualización del rendimiento académico utilizando Power Bi como plataforma principal. En ambos casos, se destaca el uso de Python y la librería pandas para el tratamiento de datos, así como la construcción de dashboards interactivos que permiten segmentar la información por estudiante, curso y grupo.

Sin embargo, existen diferencias importantes en el alcance y profundidad del tratamiento de datos. El proyecto de Maximiliano se centra en una asignatura específica (Programación II) dentro de una universidad, utilizando datos extraídos de Moodle mediante una copia de seguridad y conectados a Power Bi a través de MySQL. En cambio, el presente proyecto aborda un análisis institucional que abarca cuatro años escolares, dos niveles educativos (primaria y secundaria), y múltiples materias.

Otra diferencia clave radica en el origen y limpieza de los datos. Mientras que el trabajo de Maximiliano parte de una base de datos ya estructurada en Moodle, el presente proyecto requirió un proceso de conversión de archivos .xls a .csv, unificación de fuentes, tipificación de columnas, y segmentación por nivel educativo, lo que implicó un tratamiento más profundo y técnico desde el entorno de desarrollo VSCode. Esta diferencia metodológica resalta la versatilidad del enfoque industrial aplicado, donde se prioriza la automatización, la trazabilidad y la escalabilidad del sistema analítico. El análisis demuestra que nuestro enfoque es más resiliente ante sistemas educativos tradicionales que no cuentan con plataformas como Moodle. La capacidad de transformar datos crudos y sucios en un dataset consistente para machine learning es un aporte metodológico que supera la mera visualización descriptiva de Islas.

Una observación técnica relevante es que el trabajo de Maximiliano incorpora el uso de SQL para la conexión y consulta directa a la base de datos de Moodle. Esta integración representa una fortaleza

complementaria que podría enriquecer el presente proyecto, especialmente si se busca escalar el sistema hacia una conexión en tiempo real con plataformas educativas (Ver Figura 4-16). La incorporación de SQL permite automatizar la extracción de datos, mejorar la eficiencia en la actualización de dashboards y facilitar la trazabilidad de los registros académicos desde sistemas externos.




Figura 4-16: Vista de la base de datos SQL

Fuente: Proyecto BI aplicado a la docencia por Maximiliano Islas, 2020.

En cuanto a las visualizaciones, ambos proyectos construyen dashboards con múltiples vistas. El trabajo de Maximiliano se enfoca en tres perspectivas: curso, alumno y grupo, mientras que el presente proyecto que incorpora análisis por materia, curso nivel, año y tasas de rendimiento, lo que permite una lectura más estratégica del progreso académico institucional (Ver Figura 4-17).

Asimismo, los dashboards diseñados en este proyecto integraron indicadores dinámicos que facilitaron la exploración de la información mediante filtros interactivos, segmentaciones por género y curso, y comparaciones históricas entre gestiones académicas. Gracias a estas funcionalidades, fue posible detectar áreas críticas como matemáticas y ciencias naturales, donde se concentraban mayores dificultades, y al mismo tiempo reconocer materias con mayor estabilidad en el rendimiento. Esta capacidad de análisis detallado permitió orientar estrategias pedagógicas diferenciadas y asignar recursos de manera más

eficiente. Por otro lado, el proyecto de Maximiliano incluye una virtualización del entorno Moodle mediante Bitnami, lo que permite simular la actualización de datos en tiempo real.



Figura 4-17: Resultados del dashboard de los estudiantes de programación II

Fuente: Proyecto BI aplicado a la docencia por Maximiliano Islas, 2020.

Esta funcionalidad no fue implementada en el presente proyecto, pero representa una posible línea futura de mejora, especialmente si se busca integrar el sistema con plataformas educativas activas. La discusión no debe ver la falta de SQL como una debilidad, sino como una etapa de madurez tecnológica. El presente proyecto ha demostrado que se puede generar inteligencia de negocios desde estructuras de archivos locales, lo cual es la realidad de la mayoría de los colegios en Bolivia. La propuesta de Islas de virtualizar el entorno Moodle con Bitnami sería el siguiente paso lógico para automatizar la ingesta de datos en tiempo real.




Figura 4-18: Resultado del dashboard de los estudiantes del colegio de Cochabamba

Fuente: Elaboración propia, 2026.

Ambos trabajos coinciden en destacar que el uso de Business Intelligence en educación agrega valor a la información y optimiza el tiempo de análisis docente (Ver Figura 4-18). No obstante, el presente proyecto

aporta una visión longitudinal y multigrado, con indicadores agregados que permiten detectar patrones de riesgo, evolución por curso y desempeño por materia, lo que lo convierte en una herramienta de gestión escolar más integral. A diferencia de propuestas centradas en un único nivel o en un análisis estático, este enfoque ofrece una perspectiva dinámica que facilita la comparación histórica y la identificación de tendencias a lo largo de varios ciclos académicos. Asimismo, la incorporación de métricas predictivas y segmentaciones por nivel educativo fortalece la capacidad institucional para diseñar estrategias de intervención oportunas, asignar recursos de manera más eficiente y consolidar una cultura de mejora continua basada en evidencia. En este sentido, el proyecto no solo se limita a la visualización de datos, sino que se posiciona como un sistema de apoyo estratégico para la toma de decisiones pedagógicas y administrativas.

En conclusión, la comparación entre ambos proyectos permite identificar fortalezas complementarias: mientras el trabajo de Maximiliano ofrece una solución técnica robusta para una asignatura universitaria, el presente proyecto propone una arquitectura analítica escalable y adaptable a contextos escolares más amplios. La integración de ambos enfoques, especialmente incorporando el uso de SQL como canal de conexión directa a base de datos, podría dar lugar a un modelo híbrido que combine profundidad técnica con amplitud institucional, potenciando el uso de Power Bi como herramienta clave para la mejora educativa.

5. Conclusiones

El presente proyecto logró cumplir de manera satisfactoria el objetivo general, al aplicar un sistema de visualización estratégica y predicción del rendimiento académico estudiantil en un colegio de Cochabamba. La integración de modelos predictivos con dashboards interactivos en Power BI consolidó un recurso confiable para anticipar el desempeño académico y transformar la información en conocimiento accionable, promoviendo una cultura institucional basada en evidencia y mejora continua.

En la primera etapa se consiguió unificar y organizar los registros académicos, que inicialmente se encontraban dispersos en múltiples archivos Excel. La consolidación en un dataset homogéneo permitió contar con una base sólida para el análisis posterior. Posteriormente, se aplicaron técnicas de limpieza y transformación de datos, eliminando duplicados, corrigiendo errores de formato y reduciendo valores nulos. Este proceso garantizó la consistencia del dataset y mejoró la calidad de las visualizaciones, asegurando que los resultados fueran confiables y defendibles.

Durante la recopilación se evidenció que los formatos variaban significativamente de un año a otro: algunos incluían columnas adicionales como observaciones o códigos internos, mientras que otros carecían de encabezados claros o presentaban diferencias en la codificación de las notas. Para lograr la integración, fue necesario dropear columnas irrelevantes o inconsistentes, priorizando aquellas relacionadas directamente con el rendimiento académico (calificaciones, asistencia y participación). Este trabajo inicial aseguró que los datos pudieran ser integrados en un solo dataset defendible y utilizable para las siguientes fases del proyecto.

La segunda etapa se centró en la depuración y transformación de los datos recopilados. En el nivel primario se identificaron 576 valores nulos en columnas relacionadas con calificaciones parciales. Estos valores fueron tratados mediante técnicas de imputación y eliminación de inconsistencias, logrando reducir los nulos en más del 95%.

El uso de librerías como pandas y numpy permitió automatizar la limpieza y homogenización de los datos, mientras que scikit-learn facilitó la transformación de variables categóricas en numéricas. Gracias a estas técnicas, los datasets quedaron preparados para el modelado, lo que incrementó la precisión de los algoritmos y aseguró que los dashboards reflejaran información clara y coherente. La implementación de modelos supervisados y no supervisados permitió explorar diferentes enfoques para analizar el rendimiento académico. La regresión logística alcanzó un accuracy promedio del 87%, con un recall del 82% en la detección de estudiantes en riesgo y un precision del 79%, lo que asegura un balance defendible entre sensibilidad y confiabilidad. El f1-score se situó en 0.80, confirmando la calidad global del modelo. De manera complementaria, se incorporaron métricas avanzadas que fortalecieron la validación del enfoque supervisado: el ROC-AUC alcanzó un valor de 0.9998, evidenciando una capacidad discriminativa casi perfecta, mientras que el Log-Loss obtuvo un valor de 0.0222, reflejando una calibración precisa de las probabilidades predichas. Estos indicadores confirman que el modelo supervisado no solo

clasifica correctamente, sino que también asigna niveles de confianza defendibles a cada predicción, consolidándose como una herramienta de alerta temprana altamente confiable.

Por su parte, el algoritmo K-means permitió segmentar a los estudiantes en tres clústeres principales: alto desempeño (42%), desempeño medio (38%) y bajo desempeño (20%). La validación mediante el Silhouette Score arrojó un valor de 0.19, lo que indica una segmentación moderada de los grupos, mientras que el índice de Davies-Bouldin fue de 1.70, confirmando una separación adecuada entre los grupos. De manera adicional, el Calinski–Harabasz Index alcanzó un valor de 231.36, lo que sugiere que la separación entre los clústeres es estadísticamente significativa y que la estructura de los grupos es defendible desde un punto de vista analítico. Estos resultados demuestran que la segmentación es útil para diseñar estrategias pedagógicas diferenciadas y que el modelo no supervisado aporta valor como herramienta exploratoria para la gestión escolar.

Además, se aplicó la técnica SMOTE para balancear las clases en el modelo supervisado. Antes del balanceo, los estudiantes en riesgo representaban solo el 18% del dataset, lo que generaba sesgos en la clasificación. Tras aplicar SMOTE, se equilibraron las proporciones y el recall mejoró en un 12%, asegurando que más estudiantes vulnerables fueran correctamente identificados. Este hallazgo confirma la importancia de aplicar técnicas de balanceo en contextos educativos.

La combinación de modelos supervisados y no supervisados permitió obtener una visión integral del rendimiento estudiantil: por un lado, la detección temprana de casos críticos y, por otro, la identificación de perfiles diferenciados que aportan valor a la gestión pedagógica. El diseño del modelo de visualización en Power BI permitió transformar los resultados del análisis en dashboards interactivos y accesibles. Estos dashboards mostraron indicadores clave como promedios de notas, tasas de asistencia y segmentaciones de riesgo académico.

Los dashboards diseñados lograron representar de manera clara la distribución del rendimiento académico: se evidenció que el 20% de los estudiantes se encontraban en riesgo, mientras que el 42% mantenía un desempeño alto. Además, se observaron variaciones significativas entre cursos: en el nivel primario, el porcentaje de estudiantes en riesgo fue del 23%, mientras que en secundaria se redujo al 17%, lo que sugiere diferencias en los factores que influyen en el rendimiento.

La interactividad de los dashboards permitió a los usuarios explorar los datos mediante filtros y segmentaciones dinámicas. Por ejemplo, los directivos pudieron analizar el desempeño por género, curso y área de conocimiento, identificando que las mayores dificultades se concentraban en matemáticas y ciencias naturales. Esta capacidad de exploración fortaleció la utilidad práctica del modelo, convirtiéndolo en una herramienta estratégica para la toma de decisiones pedagógicas.

Finalmente, la experiencia demostró que la visualización estratégica no solo facilita la comprensión de los datos, sino que también promueve una cultura institucional basada en evidencia. Los dashboards diseñados se consolidaron como un recurso defendible y confiable, capaz de orientar políticas educativas y mejorar la equidad en el aprendizaje.

6. Recomendaciones

A partir de los resultados obtenidos en el presente proyecto, se plantean las siguientes recomendaciones orientadas a fortalecer futuras investigaciones y mejorar la aplicabilidad de los modelos predictivos y de visualización estratégica en el ámbito educativo.

En primer lugar, se sugiere implementar un protocolo estandarizado de estructuración y entrega de datos académicos por parte de la unidad educativa. La experiencia demostró que la heterogeneidad de formatos entre años y cursos incrementa los tiempos de limpieza y tratamiento, generando riesgos de errores de integración. Un protocolo uniforme permitiría reducir significativamente estas dificultades, facilitar la automatización de procesos y garantizar la reproducibilidad de los modelos en futuras versiones.

En segundo lugar, se recomienda fortalecer el acompañamiento pedagógico en los cursos críticos, especialmente en primero de secundaria, donde se evidenció una concentración sostenida de promedios bajos. Para ello, resulta pertinente diseñar intervenciones específicas orientadas a la transición entre niveles, incorporando tutorías, reforzamiento en ciencias exactas y seguimiento personalizado. Estas acciones contribuirían a disminuir la brecha de rendimiento y a mejorar la equidad en el aprendizaje.

En tercer lugar, se aconseja establecer un sistema de monitoreo semestral de indicadores de rendimiento académico (destacados, satisfactorios, regulares). Este sistema debe estar vinculado a dashboards dinámicos que permitan segmentar por curso, materia, trimestre y nivel educativo. La implementación de este mecanismo facilitaría la detección temprana de desviaciones y la adaptación de estrategias pedagógicas en tiempo real, fortaleciendo la capacidad de respuesta institucional.

En cuarto lugar, se recomienda que los resultados obtenidos sean calibrados y validados de manera continua, incorporando retroalimentación de docentes, ajustes curriculares y evolución institucional. Dado que los modelos se construyeron sobre hipótesis de segmentación y condiciones iniciales específicas, su efectividad depende de un proceso constante de actualización y ajuste.

Finalmente, se sugiere documentar todas las transformaciones aplicadas a los datos, incluyendo scripts, reglas de limpieza y criterios de segmentación. Esta práctica garantiza la trazabilidad, reproducibilidad y escalabilidad del modelo, permitiendo que el sistema analítico pueda ser replicado, auditado y mejorado en futuras implementaciones. La documentación rigurosa constituye un requisito indispensable para consolidar la confiabilidad del proyecto y asegurar su sostenibilidad en el tiempo.

Bibliografía

- Menchaca, P. (2024). *unifranz.edu.bo*. Obtenido de <https://unifranz.edu.bo/blog/ia-revoluciona-la-educacion-superior-al-menos-de-seis-maneras/>
- CEUB. (2023). *Guía de orientación Vocacional y Profesional del SUB*. La Paz: CEUB.
- Zurita. (2025). Obtenido de <https://unifranz.edu.bo/blog/el-microlearning-transforma-la-educacion-en-pequenos-grandes-pasos/>
- Bolivia, M. d. (2016). Cultura Científica E Innovadora Desde La Ubicación.
- Basualto, A. P. (2023). El seguimiento académico como estrategia de tutoría en el Bachillerato en línea. *Revista mexicana de Bachillerato a distancia*.
- Navarro, R. E. (2003). El rendimiento Académico: Concepto, Investigación y Desarrollo. *Revista Electrónica Iberoamericana sobre Calidad, Eficacia y Cambio en Educación*.
- Navarro, R. E. (2003). El rendimiento académico: concepto, investigación y desarrollo.
- Sánchez, V. M. (2016). Rendimiento Escolar . *Revista Electrónica del Instituto Politécnico Nacional*.
- Soto, S. V. (2019). Ciencia de Datos Educativos . *Revista del Instituto Andalúz Interuniversitario en Data Science and Computational Intelligence*.
- SafetyCulture. (23 de Septiembre de 2025). *SafetyCulture*. Obtenido de <https://safetyculture.com/es/temas/indicadores-educativos>
- Rodríguez, D. (04 de Noviembre de 2024). *Mercately*. Obtenido de <https://blog.mercately.com/marketing/limpieza-de-datos/>
- Sainz, I. (12 de Abril de 2022). *Integra*. Obtenido de <https://www.integratecnologia.es/la-innovacion-necesaria/power-bi-y-el-uso-de-la-visualizacion-de-datos-en-el-sector-educativo/>
- EducaOpen. (03 de Diciembre de 2024). *Academic*. Obtenido de <https://www.academic.lat/posts/dashboards-educativos-la-clave-para-una-gestion-escolar-inteligente>
- Zurita. (2024). Obtenido de <https://unifranz.edu.bo/blog/la-inteligencia-artificial-una-aliada-sin-limites-para-la-educacion/>
- Islas, M. S. (2020). *Aplicaciones de Business Intelligence Aplicado a la Docencia*. Madrid.
- García Mendoza, C. E. (2014). Factores que influyen en el rendimiento escolar en la educación media superior: Estudio diagnóstico en la asignatura de matemáticas en el Estado de México. *Revista Iberoamericana para la Investigación y el Desarrollo Educativo (RIDE)*, 10-15.
- Campbell, C. (1996). *Equality of Educational Opportunity*. Wahington, D.C: U.S. Government Printing Office.


- Educación, A. d. (2019). *Visión estratégica: Guía de herramientas para el desarrollo de recursos personales en equipos directivos*. Chile: Ministerio de Educación de Chile.
- Roncancio, G. (2023). *Pensemos*. Obtenido de <http://gestion.pensemos.com:https://gestion.pensemos.com/planificacion-estrategica-educativa-como-la-estrategia-mejora-la-calidad-educativa>
- Molinares, A. H. (2018). *Estrategias basadas en la visualización de conceptos y objetos matemáticos para un aprendizaje significativo en estudiantes de educación media*. Barranquilla: Universidad del Atlántico.
- Mata, A. S. (28 de Agosto de 2025). *Uninotas*. Obtenido de http://www.uninotas.net:https://www.uninotas.net/gestion-educativa-estrategica-principios-funciones-y-retos-para-la-calidad/#google_vignette
- Losada, J. L. (2021). A propósito del principio de visualización en la enseñanza clínica. En J. L. Losada, *Educación médica* (págs. 172-176). Elsevier.
- Few, S. (2012). Show me the numbers: Designing Tables and Graphs to Enlighten. *Analytic Press*.
- Klerkx, J. (2017). Learning analytics dashboards. En J. Klerkx, *Handbook of Learning Analytics* (págs. 143-150). Society for Learning Analytics Search (SoLAR).
- Costa, A. D. (02 de 12 de 2024). *GestionEducativa*. Obtenido de <http://gestioneducativa.net:https://gestioneducativa.net/como-la-educacion-basada-en-datos-ayuda-a-la-mejora-de-los-aprendizajes-y-de-las-escuelas/>
- Carpio-Mendoza, R. A. (2024). Predicción del rendimiento académico utilizando modelos de aprendizaje automático: Una revisión sistemática de la literatura . En R. A. Carpio-Mendoza, *Predicción del rendimiento académico utilizando modelos de aprendizaje automático: Una revisión sistemática de la literatura* (págs. 1038-1054). San Marcos: Digital Publisher.
- Equipo Smowl. (17 de Mayo de 2023). *smowl tech*. Obtenido de <http://smowl.net:https://smowl.net/es/blog/aprendizaje-supervisado-no-supervisado>
- Becerra, N. (2024). Regresión logística: técnica de machine learning para predicciones académicas. *XIKUA Boletín Científico de la Escuela Superior de Tlahuelilpan*, 71-80.
- Domínguez, M. (2021). Regresión logística y análisis de conglomerados: aplicaciones. *Revista de la Universidad de Zaragoza*.
- Maquera, A. (05 de 06 de 2025). *Codideep*. Obtenido de <http://codideep.com:https://codideep.com/blogpost/aprendizaje-supervisado-vs-no-supervisado>
- Chawla, N. V. (2002). SMOTE: Synthetic Minority Over-sampling Technique. En N. V. Chawla, *SMOTE: Synthetic Minority Over-sampling Technique* (págs. 321-357). Washington: Journal of Artificial Intelligence Research.
- Alfonso, S. (12 de Septiembre de 2024). *Datacamp*. Obtenido de <http://www.datacamp.com:https://www.datacamp.com/es/blog/data-science-in-education>

- Camacho, M. d. (2024). Ciencia de Datos Estudiantiles, Tendencias Hacia una Educación Inteligente. *Humanidades, Tecnología y Ciencia, del Instituto Politécnico Nacional*, 5-10.
- Gómez, J. M. (2025). *Ciencia de datos y metodologías pedagógicas en educación superior*. Medellín: Universidad Nacional Abierta y a Distancia.
- López, F. (2013). Transparencia y mejora escolar. *Consejo Escolar del Estado de Madrid*, 15-20.
- UNESCO, e. (08 de 10 de 2025). *unesco.org*. Obtenido de <http://etico.iiep.unesco.org>: <https://etico.iiep.unesco.org/es/los-paises-europeos-avanzan-con-la-transparencia-en-la-educacion-mediante-datos-escolares-abiertos>
- FasterCapital, E. (06 de Mayo de 2025). *FasterCapital*. Obtenido de <http://FasterCapital.com>: <https://fastercapital.com/es/contenido/Toma-de-decisiones-basada-en-datos--Educacion-basada-en-datos--Dando-forma-al-futuro--Decisiones-basadas-en-datos-en-la-educacion.html>
- Developers, G. (01 de Octubre de 2025). *developers.google.com*. Obtenido de <http://developer.es.google.com>: <https://developers.google.com/machine-learning/crash-course/classification/accuracy-precision-recall?hl=es-419>
- Sahlaoui, H. (2023). Education and information technologies. En H. Sahlaoui, *Education and information technologies* (págs. 5447-5483). Springer.
- Powers, D. (2021). Evaluation: From precision, Recall and F-factor to ROC, informedness, markedness and correlation. *School of Informatics and Engineering Flinders University - Australia*, 13.
- Bowyer, K. (2002). *SMOTE: Synthetic Minority Over-sampling Technique*. California: Journal of Artificial Intelligence Research.
- Gómez, L. (2025). Innovación pedagógica mediante análisis de datos. *Universidad Nacional Abierta y a Distancia de Colombia*, 10-15.
- Siemens, G., & Long, P. (2011). Learning Analytics: The emergence of a discipline. En G. Siemens, & P. Long, *Learning Analytics* (págs. 31-40). EDUCASE.
- Vieira, L., & Soares, F. (2018). Técnicas de Clustering aplicadas a la educación de la minería de datos. En L. Vieira, & F. Soares, *Técnicas de Clustering aplicadas a la educación de la minería de datos* (págs. 1-15). Journal of Education Technology in Higher education.
- Rodriguez, M., & García, J. (2019). Aplicación de modelos predictivos en educación secundaria argentina. *Revista Iberoamericana de Tecnología Educativa*, 45-60.
- López, E., Vásquez, E., & Gonzáles, M. (2020). Educación de minería de datos y analítica de aprendizaje . En E. López, E. Vásquez, & M. Gonzáles, *Educación de minería de datos y analítica de aprendizaje* (págs. 148-152). Education Sciences.
- García, F. (2021). Educational data mining: an updated overview. *Springer*, 1-15.
- Pedregosa, F., Varoquaux, G., & Gramfort, A. (2011). Scikit-learn: Machine learning in Python. En F. Pedregosa, G. Varoquaux, & A. Gramfort, *Scikit-learn: Machine learning in Python* (págs. 2825-2830). Journal of Machine learning Research.

- Rousseuw, P. (1987). Silhouettes: A graphical aid to the interpretation and validation of cluster analysis. En P. Rousseuw, *Silhouettes: A graphical aid to the incorporation and validation of cluster analysis* (págs. 53-65). Journal of Computational and Applied Mathematics.
- Davies, D., & Bouldin, D. (1979). A Cluster Separation Measure. En D. Davies, & D. Bouldin, *A Cluster Separation Measure* (págs. 224-227). IEEE Transactions on Pattern Analysis.
- Mundial, B. (2022). Learning recovery to accelerate progress. *worldbank organization*, 5-10.
- Forero-Corba, W., & Negre Bennasar, F. (2024). Técnicas y aplicaciones del Machine Learning e Inteligencia Artificial en educación: una revisión sistemática. *RIED-Revista Iberoamericana de Educación a Distancia*, 35-40.
- Posgrados, V. d. (03 de Marzo de 2025). *Tecnológico Monterrey*. Obtenido de maestriasydiplomados.tec.mx: https://blog.maestriasydiplomados.tec.mx/pandas-numphy-fundamentos-analisis-datos?utm_source=copilot.com
- Contreras Garcia, J. M., & Cabrera Lozano, R. (2024). Visualización de datos con Power Bi. *Epsilon*, 69-79.
- Guffante Salazar, C. R., & Logroño Naranjo, S. I. (2025). Minería de datos aplicada a la segmentación de estudiantes y atracción de nuevos perfiles a través de técnicas de clustering. *Revista Tecnológica Ciencia y Educación Edwards Deming*, 33-47.
- Vaca Escobar, P. (2025). El uso de analíticas del aprendizaje para la identificación temprana de estudiantes en riesgo. *Instituto Superior Universitario Japón*, 30-35.
- Fawcett, T. (2006). Introducción al análisis ROC. *Pattern Recognition Letters*, 10-15.
- Bradley, A. (1997). El uso del área debajo de la curva ROC en la evaluación de algoritmos de machine learning. *Pattern Recognition*, 7-15.
- Cox, D. (1998). El análisis de regresión de secuencias binarias. *Journal of the Royal Statistical Society*, 21-34.
- Terven, J., & Cordova-Esparza, D. (2023). Loss Functions and Metrics in Deep Learning. *arXiv preprint*, 5-18.
- Calinski, T., & Harabasz, J. (1989). A dendrite method for cluster analysis. *Communications in Statistics*, 1-27.

ANEXOS

Anexo 1. Recopilación de datos



Archivos recibidos que se transformaron en formato CSV

Ubicación del archivo: Drive/Proyecto de grado

Ubicación del archivo en CD: Proyecto/Set de datos del colegio

Enlace link Drive: https://drive.google.com/drive/folders/1Vv8fhtfcPsn_omTnZwTBVB6nNLNU993d?usp=sharing

Anexo 2. Unificación de los datos

```
MODULO 2-PYTHON > [icon] notas_unidas.csv > [icon] data
1 AÑO,CURSO,ESTUDIANTE, LENGUAJE T1, LENGUAJE T2, LENGUAJE T3, INGLES T1, INGLES T2, I
2 2021,1 PRIM,AGUIRRE PANIAGUA ALEXANDER ELOY,75,65,70,68,60,67,86,59,66,83,82,8
3 2021,1 PRIM,ALARCON CHILA DARA MAGDIEL,94,89,93,100,100,100,95,86,90,90,83,82,
4 2021,1 PRIM,ANGULO QUINTEROS SOPHIE ELEONORA,91,87,91,72,79,84,92,88,90,87,87,
5 2021,1 PRIM,APAZA AYMA NATALY JHAJAIRA,91,64,77,87,72,76,94,65,72,87,82,82,58,
6 2021,1 PRIM,CASTELLON QUISPE PEDRO STEPHEN,97,93,99,100,100,97,97,93,98,90,90,
7 2021,1 PRIM,COLQUE GARNICA KATHERINE SOFIA,83,76,91,80,75,71,86,82,88,83,88,87
8 2021,1 PRIM,CORRALES MONTECINOS ADRIAN FABRICIO,100,97,100,100,100,100,100,97,
9 2021,1 PRIM,ITURRI ANDRADE ANGELES ITZEL,86,81,69,65,65,71,89,69,64,83,83,82,8
10 2021,1 PRIM,LIZARAZU GUTIERREZ ZOBEIDA GUEIZA,98,89,95,95,98,95,98,93,94,87,82
11 2021,1 PRIM,LOPEZ CADIMA DYLAN ZAID,85,64,69,82,64,67,83,66,72,85,78,75,86,74,
12 2021,1 PRIM,LOZANO ALMANZA LEYA MASSIEL,89,70,79,93,93,73,83,72,80,87,83,82,64
13 2021,1 PRIM,MENDOZA RAMIREZ EMILY SHARON,85,77,84,90,82,72,87,76,79,87,83,80,9
14 2021,1 PRIM,MERCADO AQUINO MATIAS,85,83,93,80,82,77,86,89,94,83,82,82,93,90,94
15 2021,1 PRIM,MOJICA HEREDIA GRACIELA,95,83,92,100,79,71,97,81,91,90,87,87,62,68
16 2021,1 PRIM,PADILLA MORA CATALEYA GUADALUPE,85,86,90,100,89,92,90,85,90,87,80,
17 2021,1 PRIM,PAREDES HEREDIA ANGELICA CAMANTA,91,90,90,83,82,91,90,96,87,88,
18 2021,1 PRIM,ROJAS BUSTAMANTE GA Col 3: ESTUDIANTE 80,89,100,97,88,92,75,89,83,8
19 2021,1 PRIM,ROJAS VARGAS ZAHIR ANDY,82,66,82,92,84,72,83,70,81,80,67,80,64,76,
20 2021,1 PRIM,TERAN ZOLA JUAN DARIO,81,68,70,79,73,72,84,62,64,78,73,75,67,60,67
21 2021,1 PRIM,TRONCOSO ORELLANA FERNANDA,97,84,89,100,100,100,96,80,85,83,88,82
22 2021,1 PRIM,ZAMBRANA VERA SHERISE AINHOA,90,90,91,91,71,81,92,87,85,87,83,82,6
23 2021,2 PRIM,ALVAREZ LOZA JHOSUA ANTHONY,82,80,83,100,89,83,85,84,86,87,90,83,8
24 2021,2 PRIM,APARICIO BLACUTT ARACELY JANDIRA,90,92,89,74,74,72,90,90,90,87,77,
25 2021,2 PRIM,ARIAS COCA ALISON GERALDINA,87,92,92,100,100,92,93,92,90,85,83,85,
26 2021,2 PRIM,CASILLA VALENZUELA OLIVER SALVADOR,81,80,87,94,88,65,81,80,86,85,5
27 2021,2 PRIM,CHOQUE LIMPIAS LEANDRO,77,81,83,100,93,87,78,81,86,90,88,85,82,100
28 2021,2 PRIM,CORDOVA CENTELLAS RAFAEL ENRIQUE,91,93,93,100,100,100,91,93,93,87,
29 2021,2 PRIM,GALINDO MERIDA SOFIA,89,95,94,99,100,93,91,93,91,87,90,93,81,90,68
30 2021,2 PRIM,GARCIA CHOQUE ADRIAN VICENTE,88,93,87,100,100,100,90,92,88,87,93,9
31 2021,2 PRIM,HEREDIA STACHE ANDREA VALENTINA,88,84,83,100,100,87,83,83,88,87,83
```

Captura parcial de la planilla en formato CSV

Ubicación del archivo: Drive/Proyecto de grado

Ubicación del archivo en CD: Proyecto/Set de datos del colegio

Enlace link Drive: https://drive.google.com/drive/folders/1Vv8fhtfcPsn_omTnZwTBVB6nNLNU993d?usp=sharing

Anexo 3. Tratamiento y limpieza de los datos

PROYECTO DE DIPLOMADO: NOTAS DE COLEGIO



1. EXPORTACIÓN DE DATOS

```
import pandas as pd
from pathlib import Path

ruta_base = Path("C:/MODULO 2-PYTHON/NOTAS COLEGIO")
años = ["2021", "2022", "2023", "2024"]

dataframes = []

for año in años:
    archivo = ruta_base / f"NOTAS_{año}.csv"
    if archivo.exists():
        print(f" Leyendo: {archivo.name}")
        df = pd.read_csv(archivo)
        df["AÑO"] = año # Agrega columna de año si no está
        dataframes.append(df)
    else:
        print(f" No se encontró el archivo: {archivo.name}")

if dataframes:
    df_unido = pd.concat(dataframes, ignore_index=True)
    df_unido.to_csv("notas_unidas.csv", index=False)
    print(" Archivo final generado: notas_unidas.csv")
else:
    print(" No se encontró ningún archivo para unir")
```

Captura parcial de la limpieza de datos en VSCode

Ubicación del archivo: Drive/Proyecto de grado

Ubicación del archivo en CD: Proyecto/Análisis, limpieza y tratamiento de datos

Enlace link Drive: https://drive.google.com/drive/folders/1Vv8fhtfcPsn_omTnZwTBVB6nNLNU993d?usp=sharing

Anexo 4. Modelo Supervisado: Regresión Logística

```
# Crear y entrenar el modelo
log_reg = LogisticRegression()
log_reg.fit(X_train, y_train)

# Predicciones
y_pred = log_reg.predict(X_test)
```

c:\Users\Admin\AppData\Local\Programs\Python\Python313\Lib\site-packages\sklearn\STOP: TOTAL NO. OF ITERATIONS REACHED LIMIT.

Increase the number of iterations (max_iter) or scale the data as shown in:

<https://scikit-learn.org/stable/modules/preprocessing.html>

Please also refer to the documentation for alternative solver options:

https://scikit-learn.org/stable/modules/linear_model.html#logistic-regressor

```
n_iter_i = _check_optimize_result(
```



```
print("Accuracy:", accuracy_score(y_test, y_pred))
print("Matriz de confusión:\n", confusion_matrix(y_test, y_pred))
print("Reporte de clasificación:\n", classification_report(y_test, y_pred))
```

Accuracy: 0.8654970760233918

Matriz de confusión:

```
[[125  12]
```

```
 [ 11  23]]
```

Reporte de clasificación:

	precision	recall	f1-score	support
0	0.92	0.91	0.92	137
1	0.66	0.68	0.67	34

Captura parcial del modelo predictivo supervisado en VSCode

Ubicación del archivo: Drive/Proyecto de grado

Ubicación del archivo en CD: Proyecto/Modelos de predicción de rendimiento académico

Enlace link Drive: https://drive.google.com/drive/folders/1Vv8fhtfcPsn_omTnZwTBVB6nNLNU993d?usp=sharing

Anexo 5. Modelo no supervisado: K-means

MODELO NO SUPERVISADO: K-MEANS

```
0] columnas_notas_validas = [col for col in columnas_notas if col in df_prim.columns]
X = df_prim[columnas_notas_validas]
```

```
1] from sklearn.preprocessing import StandardScaler

scaler = StandardScaler()
X_scaled = scaler.fit_transform(X)
```

```
from sklearn.cluster import KMeans
import matplotlib.pyplot as plt

inercia = []
for k in range(1, 10):
    kmeans = KMeans(n_clusters=k, random_state=42)
    kmeans.fit(X_scaled)
    inercia.append(kmeans.inertia_)

plt.plot(range(1, 10), inercia, marker="o")
plt.xlabel("Número de clusters (k)")
plt.ylabel("Inercia")
plt.title("Método del codo")
plt.show()
```

Captura parcial del modelo predictivo no supervisado en VSCode

Ubicación del archivo: Drive/Proyecto de grado

Ubicación del archivo en CD: Proyecto/Modelos de predicción de rendimiento académico

Enlace link Drive: https://drive.google.com/drive/folders/1Vv8fhtfcPsn_omTnZwTBVB6nNLNU993d?usp=sharing

Anexo 6. Cuadro de la variación porcentual por materia

Año - Materia	Promedio general por materia	Recuento de estudiantes	Variación Porcentual por Materia
2022	74,47	306	
Artes	74,64	306	-2,59%
Biología	74,39	306	0,27%
Deportes	86,56	306	6,59%
Filosofía	73,23	159	1,55%
Física	61,81	190	0,75%
Ingles	65,22	306	-7,45%
Lenguaje	71,74	306	-7,71%
Matemáticas	65,96	306	-3,39%
Música	90,35	306	19,56%
Química	61,91	190	-0,28%
Religión	83,31	306	6,66%
Sociales	70,11	306	-8,72%
Técnica Tecnológica	78,77	306	3,62%
2023	75,57	298	
Artes	71,26	298	-4,53%
Biología	77,34	298	3,96%
Deportes	86,98	298	0,49%
Filosofía	80,94	158	10,53%
Física	62,96	183	1,86%
Ingles	67,85	298	4,02%
Lenguaje	69,65	298	-2,91%
Matemáticas	69,36	298	5,16%
Música	88,93	298	-1,56%
Química	70,31	183	13,57%
Religión	79,42	298	-4,67%
Sociales	71,46	298	1,92%
Técnica Tecnológica	81,54	298	3,52%
2024	77,27	311	
Artes	73,44	311	3,06%
Biología	77	311	-0,44%
Deportes	89,39	311	2,76%
Filosofía	82,99	163	2,53%
Física	66,95	188	6,34%
Ingles	73,95	311	9,00%
Lenguaje	68,62	311	-1,48%
Matemáticas	71,25	311	2,72%
Música	83,83	311	-5,74%
Química	76,08	188	8,21%
Religión	85,44	311	7,58%
Sociales	72,27	311	1,14%
Técnica Tecnológica	81,43	311	-0,14%

Tabla completa de la variación porcentual de las materias

Ubicación del archivo: Drive/Proyecto de grado

Ubicación del archivo en CD: Proyecto/Visualización de dashboards en power bi

Enlace link Drive: https://drive.google.com/drive/folders/1Vv8fhfcpSn_omTnZwTBVB6nNLNU993d?usp=sharing

Anexo 7. Dashboards realizados en Power Bi



Captura parcial del dashboard en Power Bi

Ubicación del archivo: Drive/Proyecto de grado

Ubicación del archivo en CD: Proyecto/Visualización de dashboards en power bi

Enlace link Drive: https://drive.google.com/drive/folders/1Vv8fhtfcPsn_omTnZwTBVB6nNLNU993d?usp=sharing

Anexo PRINCIPAL: CD

Revisar el CD adjunto o visitar el siguiente enlace:

https://drive.google.com/drive/folders/1Vv8fhtfcPsn_omTnZwTBVB6nNLNU993d?usp=sharing

<https://github.com/benjamin-sn-cell/Proyecto-de-modelos-predictivos.git>



QR DRIVE



QR GITHUB



**Análisis, limpieza
y tratamiento de
datos**



**Modelos de
predicción de
rendimiento
académico**



**Visualización de
dashboards en
power bi**



**Set de datos del
colegio**

Contenido del CD:

- Análisis, limpieza y tratamiento de datos: En esta carpeta se encuentra el código en VSCode donde hacemos la limpieza del set de datos.
- Modelos de predicción de rendimiento académico: En esta carpeta se encuentran los modelos de predicción en formato .ipynb realizados en VSCode como ser el modelo supervisado y no supervisado.
- Visualización de dashboards en power bi: En esta carpeta se encuentra el archivo realizado en power bi, se encuentran 4 dashboards separados en: general, nivel primario, nivel secundario y materias.
- Set de datos del colegio: En esta carpeta se encuentran los archivos excels, recibidos del colegio y también el set de datos ya limpio, también de manera separada de acuerdo al nivel educativo (primaria y secundaria).